

时间序列模型和 LSTM 模型在水质预测中的应用研究

胡衍坤^{1,2}, 王 宁², 刘 枢³, 姜秋俚³, 张 楠⁴

¹(中国科学院大学, 北京 100049)

²(中国科学院 沈阳计算技术研究所, 沈阳 110168)

³(辽宁省生态环境监测中心, 沈阳 110161)

⁴(阜新市生态环境保护服务中心, 辽宁 阜新 123000)

E-mail: h19801235207@163.com

摘 要: 针对传统河流水质预测模型预测精度较低, 泛化能力弱的问题. 本文在基于传统的时间序列模型进行水质预测的基础上, 引入了 LSTM 神经网络, 建立了 ARIMA 和 LSTM 组合模型以及 SARIMA 和 LSTM 组合模型用于河流水质预测的研究. 结果表明, ARIMA 和 LSTM 组合模型的预测精度比单一的 ARIMA 模型提高了约 7%, SARIMA 和 LSTM 组合模型比单一的 SARIMA 模型的预测精度提高了约 6%, 比 ARIMA 和 LSTM 组合模型的预测精度提高了约 2%. 本文建立的组合模型算法, 使得河流水质预测精度得到明显的提高, 并且能够较好的应对复杂河流环境的变化.

关键词: 水质预测; ARIMA 模型; SARIMA 模型; LSTM 神经网络; 组合模型

中图分类号: TP391

文献标识码: A

文章编号: 1000-4220(2021)08-1569-05

Research on Application of Time Series Model and LSTM Model in Water Quality Prediction

HU Yan-kun^{1,2}, WANG Ning², LIU Shu³, JIANG Qiu-li³, ZHANG Nan⁴

¹(University of Chinese Academy of Sciences, Beijing 100049, China)

²(Environmental Resources Business Department, Shenyang Institute of Computing Technology, Shenyang 110168, China)

³(Liaoning Ecological Environment Monitoring Center, Shenyang 110161, China)

⁴(Fuxin Ecological Environment Protection Center, Fuxin 123000, China)

Abstract: In view of the low prediction accuracy and weak generalization ability of the traditional river water quality prediction model. Based on the traditional time series model for water quality prediction, this paper introduces LSTM neural network, establishes ARIMA and LSTM combined model and SARIMA and LSTM combined model for river water quality prediction. The results show that the prediction accuracy of ARIMA and LSTM combination model is about 7% higher than that of single ARIMA model, the prediction accuracy of SARIMA and LSTM combination model is 6% higher than that of single SARIMA model, and 2% higher than that of ARIMA and LSTM combination model. The combined model algorithm established in this paper can improve the accuracy of river water quality prediction obviously, and can better cope with the changes of complex river water environment.

Key words: water quality prediction; ARIMA model; SARIMA model; LSTM neural network; model merging

1 引言

河流为人类提供了赖以生存的水资源以及水产资源. 工业化进程的不断加快, 导致河流环境受到严重破坏. 由于河流水质变化与气候环境、季节更替以及人类活动密切相关, 因此河流水质变化呈现出渐变性、非线性、和不确定性等特点^[1]. 水质预测能够帮助我们更好地了解河流水质变化, 从而更好的保护河流水资源. 近年来, 国内外很多专家学者已针对水质预测做了大量的研究, 并取得了较好的成果. 传统的水质预测模型主要包括时间序列模型、灰色系统理论模型、回归分析模型以及神经网络模型等. 谢建辉等人^[2]将 ARIMA 模型应用到对河流水质主要监测指标化学需氧量和氨氮的预测分析上, 较为准确的反映了河流水质的变化趋势. 赵林等

人^[3]使用 BP 神经网络模型对桃林口水库出库站 7 项水质指标进行预测, 效果良好. 此外, 随着深度学习以及人工智能的快速发展, 深度学习模型也越来越多的应用到水质预测研究中. 涂吉昌等人^[4]应用基于门控型循环神经网络(GRU) 的水质预测模型进行水质预测, 显著提高了水质预测精度. 除单一模型外, 组合模型也被应用到水质预测的研究. 肖荣平等人^[5]使用多算法组合的河流水质预测方法进行水质预测, 结果表明, 组合模型的预测精度显著提高, 能够更好的适用于复杂水域的水质预测.

ARIMA 模型是经典的时间序列预测方法, 能够较好的体现时间序列数据中的线性特征. 但是, 单一的 ARIMA 模型对河流水质的非线性变化难以充分有效的处理, 需要结合其他算法. 在深度学习算法中, LSTM 模型由于其特殊的网络结

收稿日期: 2020-07-10 收修改稿日期: 2020-08-31 基金项目: 国家水体污染控制与治理科技重大专项(2018ZX07601001) 资助. 作者简介: 胡衍坤, 男, 1994 年生, 硕士研究生, 研究方向为神经网络和数据挖掘; 王 宁, 男, 1974 年生, 研究员, CCF 会员, 研究方向为计算机应用; 刘 枢, 男, 1980 年生, 高级工程师, 研究方向为环境监测; 姜秋俚, 男, 1981 年生, 博士, 高级工程师, 研究方向为环境监测; 张 楠, 女, 1982 年生, 硕士, 工程师, 研究方向为环境监测.

构,在处理时间序列问题时,比传统的神经网络更快更易收敛到最优解,非常适合处理河流水质指标这种时序数据^[3]。李艳萍等人^[4]基于 LSTM 神经网络模型较为准确的预测了空气质量 AQI 指数。因此,本文建立了 ARIMA 与 LSTM 组合模型以及 SARIMA 与 LSTM 组合模型进行河流水质预测的研究,并结合实际河流监测数据,分析河流水质变化趋势。通过比较两种组合模型对河流水质预测的结果,探究更好的河流水质预测方法,从而更好的保护河流水环境。

2 研究方法

2.1 ARIMA 和 SARIMA 模型

ARIMA 模型全称为差分自回归移动平均模型(Autoregressive Integrated Moving Average Model,简记为 ARIMA)。其中 AR 是自回归, p 为自回归项; MA 为移动平均, q 为移动平均项数;把非平稳的时间序列转化为平稳序列需要进行 d 阶差分^[5]。ARIMA 模型的一般形式为:

$$y_t = \mu + \sum_{i=1}^p \gamma_i y_{t-i} + \epsilon_t + \sum_{i=1}^q \theta_i \epsilon_{t-i} \quad (1)$$

该模型中包括自回归 AR(p) 和移动平均回归 MA(q) 两个过程。在上式中, γ_i ($i=0,1,2,\dots,p$) 和 θ_i ($i=0,1,2,\dots,q$) 是待求参数, p 为自回归过程的滞后阶数, q 为移动平均过程的滞后阶数, μ 为常数项系数, ϵ_t 为随机扰动项序列,通常要求为白噪声序列,表示为 $\epsilon_t \sim WN(0, \sigma_t^2)$ 。ARIMA 模型在建模时要求时间序列必须为平稳序列,对于非平稳时间序列数据要进行 d 阶差分后再进行建模。所以,完整的差分自回归移动平均过程 ARIMA(p,d,q) 在引入滞后因子后的模型表示为:

$$(1 - \sum_{i=1}^p \phi_i L^i)(1 - L)^d y_t = c + (1 + \sum_{i=1}^q \theta_i L^i) \epsilon_t \quad (2)$$

式(2)中 L 表示滞后因子,其定义为 $L^n y_t = y_{t-n}$, $(1-L)^d$ 为 d 阶差分运算。在建立 ARIMA 模型时首先要检测数据的平稳性,对于非平稳时间序列首先进行差分操作,从而确定 d 的值;然后根据自相关函数(ACF)和偏自相关函数(PACF)的截尾和拖尾性确定 p 值和 q 值;然后采用最小二乘法对参数进行估计;最后根据 AIC、BIC、残差检验等方式确定最优的 p 、 q 值用于模型的训练。

SARIMA 模型是在 ARIMA 模型的基础上添加了季节项,主要针对具有季节性或周期性变化的时间序列进行建模^[6]。SARIMA 乘积模型的一般表达式为:

$$SARIMA = (p,d,q) \times (P,D,Q)_s \quad (3)$$

式(3)中 p 为自回归阶数, q 为移动平均阶数, d 为差分阶数, P, Q, D 分别为季节求和自回归移动平均模型中的自回归、移动平均回归和差分的值, s 为季节周期和循环长度。在进行 SARIMA 建模时,首先进行差分操作,从而确定 d 和 D 的值;然后通过 ACF 来确定 p 和 P 的值,通过 PACF 来确定 q 和 Q 的值;然后采用平均法或者移动平均趋势剔除法对季节性时间序列数据进行分解,从而确定 s 的值;最后在得到所有参数后,使用参数估计模型进行模型校验,得到最终模型。

2.2 LSTM 模型

长短期记忆网络是一种改进后的循环神经网络,可以解决 RNN 无法处理长距离依赖的问题,并且由于其特殊的网络结构,LSTM 在时间序列预测上也有着广泛的应用^[4]。LSTM

神经网络结构图^[4]如图 1 所示。




图 1 LSTM 神经网络

Fig. 1 LSTM neural network

LSTM 模型在 RNN 的基础上添加了 3 个门控结构,分别为“遗忘门”、“输入门”和“输出门”^[4]。LSTM 的第一步是确定将从节点状态中丢弃哪些信息,该判定由称为“遗忘门”的 Sigmoid 层决定。它查看 h_{t-1} 和 X_t ,并为单元状态 C_{t-1} 中的每个数字输出 0-1 之间的数字,0 代表“不允许任何量通过”,1 代表“允许任何量通过”。Sigmoid 函数的输出值决定前一个状态的值是否丢弃,表达式为:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (4)$$

下一步是确定我们将在单元节点状态中存储哪些信息,包含两个部分。“输入门”的 sigmoid 函数决定将更新哪些值, tanh 函数创建可以添加到状态的新候选值 C_{t-1} 的向量(一个在 -1 与 1 之间的值)并与 sigmoid 函数的值相乘,最后输出确定要输出的那部分。其表达式为:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (5)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (6)$$

最后我们需要通过“输出门层”来决定输出的内容。首先运行一个 sigmoid 层,它决定我们要输出的单元状态的哪些部分。然后将单元状态置于 tanh(将值推到介于 -1 和 1 之间)并将其乘以 sigmoid 们的输出,最终得到将要输出的部分。其表达式为:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (7)$$

$$h_t = o_t * \tanh(C_t) \quad (8)$$

2.3 组合预测模型

河流水质预测组合模型设计图如图 2 所示。




图 2 组合模型

Fig. 2 Combination model

2.3.1 数据预处理

数据预处理过程主要处理原始数据中的缺失值以及异常值,首先对数据进行离群点检测,将异常值视为缺失值,从而使用拉格朗日插值法对缺失值进行填补。

水质监测数据具有线性特征以及非线性特征^[3],将水质

数据记为 Z_t , 则可将其分解为线性部分 X_t 和非线性部分 Y_t , 记为:

$$Z_t = X_t + Y_t \quad (9)$$

2.3.2 组合模型建模分析

1) 时间序列模型建模

首先使用 ARIMA 模型和 SARIMA 模型分别对数据进行建模, 然后将训练数据进行拟合并进行预测, 输出预测结果记为 X'_t , 计算残差可得 E_t :

$$E_t = Z_t - X'_t \quad (10)$$

2) LSTM 残差预测

水质数据中的非线性分成隐藏在残差序列 E_t 中, 使用 LSTM 模型对残差序列进行训练和预测, 得到残差序列的预测值 E'_t .

3) 模型组合

结合时间序列模型线性预测值 X'_t 与 LSTM 模型非线性预测值 E'_t , 得到最终预测值 Z'_t 为:

$$Z'_t = X'_t + E'_t \quad (11)$$

2.3.3 模型评价指标

本文对于 ARIMA 模型和 SARIMA 模型以及组合模型分别计算模型预测结果的均方误差 (MSE)、均方根误差 (RMSE) [4] 和平均绝对百分比误差 (MAPE), 来量化模型预测的准确性.

MSE 计算公式为:

$$MSE = \frac{1}{n} \sum_{i=1}^n (p_i - x_i)^2 \quad (12)$$

RMSE 计算公式为:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (p_i - x_i)^2} \quad (13)$$

MAPE 计算公式为:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{p_i - x_i}{x_i} \right| \times 100\% \quad (14)$$

其中 p_i 为模型预测值, x_i 为训练集真实值, n 为训练集个数.

3 实验分析

3.1 实验环境介绍

本次实验基于 Windows 操作系统, 使用 python 语言进行编码, 版本为 python3.7, 编程工具使用 Jupyter Notebook, 其中 ARIMA 与 SARIMA 模型使用 statsmodels 包实现, LSTM 模型使用 TensorFlow 框架实现.

3.2 实验数据

实验水质数据来源于辽宁省阜新市细河高台子断面 2013 年 1 月-2020 年 3 月监测数据, 选取的污染物指标为化学需氧量 (COD) 和氨氮 ($\text{NH}_3\text{-N}$). 取 2013 年 1 月-2018 年 12 月数据作为模型的训练集, 2019 年 1 月-12 月数据作为模型的测试集, 2020 年 1 月-3 月数据作为模型预测的验证集.

3.3 ARIMA 与 LSTM 组合模型建模实例

在 ARIMA 模型建模时, 首先对时间序列训练数据进行 ADF 检测和白噪声检验, 接下来绘制原始时间序列的自相关 (ACF) 图和偏自相关 (PACF) 图, 观察可知模型 p 值为 1, q 值也为 1. 最后确定模型为 $\text{ARIMA}(1, 0, 1)$, 进行模型训练、检验、评估及预测, 得到 ARIMA 的拟合预测序列, 然后使用

原始数据减去拟合的预测数据得到 ARIMA 模型预测后的残差序列, 并以滑动窗口的方式将残差序列切分成 n 段长度为 t 的序列, 然后应用 LSTM 模型进行残差序列模型的训练和预测得到预测结果, 最后将 ARIMA 模型预测结果与 LSTM 残差预测结果相加得到最终预测结果. 结果如图 3、图 4 所示.




图 3 ARIMA-LSTM 模型预测结果

Fig. 3 Prediction results of ARIMA-LSTM model

计算可得组合模型化学需氧量预测值均方误差和均方根误差分别为 5.13 和 2.26, 平均百分比误差为 4.77%. 氨氮预




图 4 ARIMA-LSTM 模型预测结果

Fig. 4 Prediction results of ARIMA-LSTM model

测值均方误差为 0.14, 均方根误差为 0.19, 平均百分比误差为 5.26%, 说明 ARIMA 和 LSTM 组合模型预测相较于单独使用 ARIMA 模型得到了很好的预测结果.

3.4 SARIMA 与 LSTM 组合模型实例

在进行 SARIMA 建模时需要先提取时间序列数据中的趋势、季节和随机效应, 从而判断残差序列的稳定性以及确定季节项系数. 由 ARIMA 模型建模过程可知, 原始化学需氧量和氨氮数据均为平稳数据; 根据化学需氧量和氨氮数据自相关图和偏自相关可知, p 值分别为 1 和 2, q 值都为 1; 根据从数据中提取的季节性可知, 季节项系数都为 12. 通过网格搜索并依据 AIC 准则, 可以得到化学需氧量序列 SARIMA 模型最优参数组合为 $\text{SARIMA}(1, 0, 1) \times (1, 0, 1, 12)$, 氨氮序列 SARIMA 模型最优参数组合为 $\text{SARIMA}(2, 0, 1) \times (2, 0, 1, 12)$. 进行 SARIMA 模型训练和预测得到预测值序列, 并计算预测得到的残差序列, 在此基础上继续建立 SARIMA 与 LSTM 组合模型进行预测, 预测结果如图 5、图 6 所示.

经计算可得 SARIMA 和 LSTM 组合模型对化学需氧量预测值的均方误差为 3.17, 均方根误差为 1.37, 平均百分比误差为 2.81%, 氨氮预测值的均方误差为 0.10, 均方根误差为 0.13, 平均百分比误差为 3.16%. 各模型预测结果对比如

图 7、图 8 和表 1 所示。




图 5 SARIMA-LSTM 模型预测结果

Fig. 5 Prediction results of SARIMA-LSTM model




图 6 SARIMA-LSTM 模型预测结果

Fig. 6 Prediction results of SARIMA-LSTM model




图 7 各模型预测结果对比

Fig. 7 Comparison of prediction results of each model




图 8 各模型预测结果对比

Fig. 8 Comparison of prediction results of each model

综上可知,组合模型相较于单一时间序列模型在对河流

水质指标中的化学需氧量和氨氮进行预测时的精度都有了明显提高. 其中 ARIMA 和 LSTM 组合模型比 ARIMA 模型的预

表 1 各模型预测精度对比

Table 1 Comparison of prediction accuracy of each model

模型	化学需氧量			氨氮		
	MSE	RMSE	MAPE	MSE	RMSE	MAPE
ARIMA	11.05	4.59	12.03%	0.22	0.47	13.16%
SARIMA	9.34	3.68	10.96%	0.18	0.28	9.24%
ARIMA-LSTM	5.13	2.26	4.77%	0.14	0.19	5.26%
SARIMA-LSTM	3.17	1.37	2.81%	0.10	0.13	3.16%

测精度提高了约 7%, SARIMA 和 LSTM 组合模型比 SARIMA 模型的预测精度提高了约 6%, SARIMA 和 LSTM 组合模型的预测精度比 ARIMA 和 LSTM 组合模型的预测精度提高了约 2%. 所以,经过试验分析,在本次试验数据集的基础上得到的河流水质预测最优模型为 SARIMA 和 LSTM 组合模型,该模型预测准确度较高,泛化能力强.

4 结 论

传统的时间序列模型 ARIMA 和 SARIMA 能够较好的体现时间序列数据中的线性特征, LSTM 模型能够很好的处理时间序列数据中的非线性特征, 本文在使用 ARIMA 模型和 SARIMA 模型建模的基础上提出了 ARIMA 和 LSTM 组合模型以及 SARIMA 和 LSTM 组合模型, 并进行了实验分析. 经过实验分析可知, 组合模型对于河流水质指标中的化学需氧量和氨氮的预测精度优于单一时间序列模型的预测精度. SARIMA 模型在 ARIMA 模型的基础上增加了季节项, 由于考虑了季节性因素对河流水质变化的影响, SARIMA 模型的预测精度优于 ARIMA 模型. SARIMA 与 LSTM 组合模型的预测精度比 ARIMA 模型的预测精度提高了 10% 左右, 能够较为准确的拟合以及预测河流水质参数指标, 从而为保护河流水环境提供较为准确的参考依据.

References:

- [1] Liu Jing-jing, Zhuang Hong, Tie Zhi-xin, et al. Water quality multi-factor prediction model using LSTM neural network based on k-similarity noise reduction [J]. Computer Systems & Application, 2019, 28(2): 226-232.
- [2] Xie Jian-hui, Yan Xue-jun, Sun Kai-zheng, et al. Application of ARIMA model in river water quality prediction [C] // Chinese Society of Environmental Sciences, China Everbright International Ltd. Proceedings of 2015 Annual Meeting of Chinese Society of Environmental Sciences (Volume I), 2015: 1239-1243.
- [3] Zhao Lin, Dai Tian-jiao, Chen Liang, et al. Prediction of water quality in taolinkou reservoir based on BP neural network model [J]. Journal of Anhui Agricultural Sciences, 2019, 47(24): 73-77.
- [4] Tu Ji-chang, Chen Chao-bo, Wang Jing-cheng, et al. Research on water quality prediction model based on deep learning [J]. Automation and Instrumentation, 2019, 34(6): 96-100.
- [5] Xiao Rong-ping, Ge Hui-ben, Sun Xin. Study on river water quality prediction method based on multi algorithm combination [J]. Technical Supervision in Water Resources, 2020, 28(2): 136-139.

- [6] Wang Yuan-yuan. Research of water quality prediction methods [D]. Nanjing: Nanjing University of Posts and Telecommunications, 2019.
- [7] Li Yan-ping, Zhao Xiao-yu. Air quality prediction method based on LSTM [J]. Science and Technology & Innovation, 2020, 46(7): 7-9.
- [8] Raghavendra Kumar, Pardeep Kumar, Yugal Kumar. Time series data prediction using IoT and machine learning technique [J]. Procedia Computer Science, 2020, 167: 373-381.
- [9] Wei Ye, Arsen V Melkumian. Forecasting australian red wine sales with SARIMA and ANNs [C] // Clausius Scientific Press ed. Proceedings of 2020 International Symposium on Frontiers of Economics and Management Science (FEMS 2020), 2020: 147-151.
- [10] Wei Shao-jie, Zhou Yong-xia. Human body fall detection model combining alphapose and LSTM [J]. Journal of Chinese Computer Systems, 2019, 40(9): 1886-1890.
- [11] Wang Hai-tao, Song Wen, Wang Hui. Text classification method based on hybrid model of LSTM and CNN [J]. Journal of Chinese Computer Systems, 2020, 41(6): 1163-1168.
- [12] Ding Rui, Li Wei, Wang Ruo-zhou. Combined forecasting model based on SARIMA and LSTM [J]. Computer & Digital Engineering, 2020, 48(2): 304-307.
- [13] Tong Jun. Prediction of ammonia nitrogen in jinze reservoir based on SVR-ARIMA combination model [J]. Microcomputer Applications, 2020, 36(4): 4-6.
- [14] Kang Duo, Xu Ji-ping, Zhao Shi-yao, et al. Research on water quality combination forecasting method based on Adaboost algorithm [J]. Computer Measurement & Control, 2018, 26(8): 41-45.

附中文参考文献:

- [1] 刘晶晶, 庄红, 铁治欣, 等. K-Similarity 降噪的 LSTM 神经网络水质多因子预测模型 [J]. 计算机系统应用, 2019, 28(2): 226-232.
- [2] 谢建辉, 闫学军, 孙开争, 等. ARIMA 模型在河流水质预测中的应用 [C] // 中国环境科学学会, 中国光大国际有限公司, 2015 年中国环境科学学会学术年会论文集(第 1 卷), 2015: 1239-1243.
- [3] 赵林, 戴天骄, 陈亮, 等. 基于 BP 神经网络的桃林口水库水质预测 [J]. 安徽农业科学, 2019, 47(24): 73-77.
- [4] 涂吉昌, 陈超波, 王景成, 等. 基于深度学习的水质预测模型研究 [J]. 自动化与仪表, 2019, 34(6): 96-100.
- [5] 肖荣平, 葛卉桦, 孙新. 多算法组合的河流水质预测方法研究 [J]. 水利技术监督, 2020, 28(2): 136-139.
- [6] 王嫚嫚. 基于 LSTM 的水质预测方法研究 [D]. 南京: 南京邮电大学, 2019.
- [7] 李艳萍, 赵晓宇. 基于 LSTM 的空气质量预测方法 [J]. 科技与创新, 2020, 46(7): 7-9.
- [10] 卫少洁, 周永霞. 一种结合 Alphapose 和 LSTM 的人体摔倒检测模型 [J]. 小型微型计算机系统, 2019, 40(9): 1886-1890.
- [11] 王海涛, 宋文, 王辉. 一种基于 LSTM 和 CNN 混合模型的文本分类方法 [J]. 小型微型计算机系统, 2020, 41(6): 1163-1168.
- [12] 丁锐, 李伟, 王若舟. 基于 SARIMA 和 LSTM 组合预测模型 [J]. 计算机与数字工程, 2020, 48(2): 304-307.
- [13] 童俊. 基于 SVR-ARIMA 组合模型的金泽水库氨氮预测研究 [J]. 微型电脑应用, 2020, 36(4): 4-6.
- [14] 康铎, 许继平, 赵峙尧, 等. 基于 Adaboost 算法的水质组合预测方法研究 [J]. 计算机测量与控制, 2018, 26(8): 41-45.

~~~~~

## 本刊检索与收录

### 国内

中文核心期刊

中国学术期刊文摘(中英文版) 收录

中国科学引文数据库(CSCD) 来源期刊

中国科技论文统计源期刊

中国期刊全文数据库(CJFD) 收录期刊

中国科技期刊精品数据库收录期刊

中国学术期刊综合评价数据库(CAJCED) 收录期刊

中国核心期刊(遴选) 数据库收录期刊

中文科技期刊数据库收录期刊

### 国际

英国《科学文摘》(INSPEC)

荷兰《文摘与引文数据库》(SCOPUS)

俄罗斯《文摘杂志》(AJ, VINITI)

美国《剑桥科学文摘(自然科学)》CSA(NS); Cambridge Scientific Abstracts(Natural Science)

美国《剑桥科学文摘》CSA(T); Cambridge Scientific Abstracts(Technology)

美国《乌利希期刊指南》UPD(Ulrich's Periodicals Directory)

日本《日本科学技术振兴机构中国文献数据库》(JST, China)

波兰《哥白尼索引》(IC, Index of Copernicus)