

Python 实现 BOA 蝴蝶优化算法优化随机森林回归模型(RandomForestRegressor
算法) 项目实战

1. 项目背景

蝴蝶优化算法(butterfly optimization algorithm, BOA)是 Arora 等人于 2019 年提出的一种元启发式智能算法。该算法受到了蝴蝶觅食和交配行为的启发,蝴蝶接收/感知并分析空气中的气味,以确定食物来源/交配伙伴的潜在方向。

蝴蝶利用它们的嗅觉、视觉、味觉、触觉和听觉来寻找食物和伴侣,这些感觉也有助于它们从一个地方迁徙到另一个地方,逃离捕食者并在合适的地方产卵。在所有感觉中,嗅觉是最重要的,它帮助蝴蝶寻找食物(通常是花蜜)。蝴蝶的嗅觉感受器分散在蝴蝶的身体部位,如触角、腿、触须等。这些感受器实际上是蝴蝶体表的神经细胞,被称为化学感受器。它引导蝴蝶寻找最佳的交配对象,以延续强大的遗传基因。雄性蝴蝶能够通过信息素识别雌性蝴蝶,信息素是雌性蝴蝶发出的气味分泌物,会引起特定的反应。

通过观察,发现蝴蝶对这些来源的位置有非常准确的判断。此外,它们可以辨识出不同的香味,并感知它们的强度。蝴蝶会产生与其适应度相关的某种强度的香味,即当蝴蝶从一个位置移动到另一个位置时,它的适应度会相应地变化。当蝴蝶感觉到另一只蝴蝶在这个区域散发出更多的香味时,就会去靠近,这个阶段被称为全局搜索。另外一种情况,当蝴蝶不能感知大于它自己的香味时,它会随机移动,这个阶段称为局部搜索。

本项目通过 BOA 蝴蝶优化算法优化随机森林回归模型。

2. 数据获取

本次建模数据来源于网络(本项目撰写人整理而成),数据项统计如下:

编号	变量名称	描述
1	x1	
2	x2	
3	x3	
4	x4	
5	x5	

6	x6	
7	x7	
8	x8	
9	x9	
10	x10	
11	y	因变量

数据详情如下(部分展示)：

x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	y
-0.66	-0.46	0.78	0.22	-0.82	0.97	-1.66	-0.18	0.45	0.82	55.06
1.08	-0.44	1.12	-1.77	0.04	-0.19	0.82	1.57	-1.39	-0.39	-25.48
-1.48	-0.73	-0.33	0.62	-0.22	-2.05	0.44	0.22	0.52	-0.7	-284.67
-2.15	0.01	0.04	1.12	-0.65	0.58	1.87	-0.55	-0.64	-1.69	-248.06
-0.15	-0.23	-1.06	1.53	-0.52	0.06	-1.2	0.83	-0.79	-1.39	-98.73
-0.47	-0.98	0.15	0.97	-0.5	0.01	2.75	0.9	-0.32	-0.06	-20.05
-0.54	1.5	0.55	-0.61	-1.01	-0.05	-0.04	2.3	0.54	0.24	127.01
0.01	-1.98	0.1	0.48	-0.91	0.96	-1.88	-0.47	-1.4	0.8	-176.75
0.27	-1.29	0.89	-0.23	-0.53	-0.76	0.75	-2.75	-0.45	2.12	-208.71
-0.26	0.46	0.08	-0.69	1.33	2.39	1.1	1.16	0.8	-1.25	330.14
-0.75	-0.21	-0.77	-1.33	-0.36	0.73	-0.78	0.24	-0.46	-0.86	-272.41

3. 数据预处理

3.1 用 Pandas 工具查看数据

使用 Pandas 工具的 head() 方法查看前五行数据：

```
*****查看数据前5行*****
      x1      x2      x3      x4      x5      x6      x7      x8      x9      x10      y
0 -0.66 -0.46  0.78  0.22 -0.82  0.97 -1.66 -0.18  0.45  0.82  55.06
1  1.08 -0.44  1.12 -1.77  0.04 -0.19  0.82  1.57 -1.39 -0.39 -25.48
2 -1.48 -0.73 -0.33  0.62 -0.22 -2.05  0.44  0.22  0.52 -0.70 -284.67
3 -2.15  0.01  0.04  1.12 -0.65  0.58  1.87 -0.55 -0.64 -1.69 -248.06
4 -0.15 -0.23 -1.06  1.53 -0.52  0.06 -1.20  0.83 -0.79 -1.39 -98.73
```

关键代码：

```
print('*****查看数据前5行*****')
print(df.head())
```

3.2 数据缺失查看

使用 Pandas 工具的 info() 方法查看数据信息：

*****数据缺失值统计*****

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 2000 entries, 0 to 1999

Data columns (total 11 columns):

#	Column	Non-Null Count	Dtype
0	x1	2000 non-null	float64
1	x2	2000 non-null	float64
2	x3	2000 non-null	float64
3	x4	2000 non-null	float64
4	x5	2000 non-null	float64
5	x6	2000 non-null	float64
6	x7	2000 non-null	float64
7	x8	2000 non-null	float64
8	x9	2000 non-null	float64
9	x10	2000 non-null	float64
10	y	2000 non-null	float64

dtypes: float64(11)

memory usage: 172.0 KB

None

从上图可以看到，总共有 11 个变量，数据中无缺失值，共 2000 条数据。

关键代码：

```
print('*****数据缺失值统计*****')  
print(df.info())
```

3.3 数据描述性统计

通过 Pandas 工具的 describe() 方法来查看数据的平均值、标准差、最小值、分位数、最大值。

	x1	x2	...	x10	y
count	2000.000000	2000.000000	...	2000.000000	2000.000000
mean	-0.007775	0.003455	...	0.024095	-0.418470
std	0.998895	0.997126	...	0.982390	213.474926
min	-2.770000	-3.260000	...	-3.390000	-715.260000
25%	-0.660000	-0.702500	...	-0.660000	-146.305000
50%	0.000000	-0.010000	...	0.040000	1.645000
75%	0.682500	0.690000	...	0.670000	141.232500
max	3.700000	3.170000	...	3.330000	697.910000

[8 rows x 11 columns]


关键代码如下：

```
print(df.describe())
print('*****')
```


4. 探索性数据分析

4.1 y 变量分布直方图

用 Matplotlib 工具的 hist() 方法绘制直方图：



4.2 相关性分析



从上图中可以看到，数值越大相关性越强，正值是正相关、负值是负相关。

5. 特征工程

5.1 建立特征数据和标签数据

关键代码如下：

```
y = df.y
X = df.drop('y', axis=1)
```

5.2 数据集拆分

通过 `train_test_split()` 方法按照 80%训练集、20%测试集进行划分，关键代码如下：

```
# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

6. 构建 BOA 蝴蝶优化算法优化随机森林回归模型

主要使用 BOA 蝴蝶优化算法优化随机森林回归算法，用于目标回归。

6.1 BOA 蝴蝶优化算法寻找最优参数值

最优参数：

```
-----BOA蝴蝶优化算法优化随机森林回归模型-最优结果展示-----
The best max_depth is 13
The best n_estimators is 600
```

6.2 最优参数值构建模型

编号	模型名称	参数
1	随机森林回归模型	max_depth=best_max_depth
2		n_estimators=best_n_estimators

7. 模型评估

7.1 评估指标及结果

评估指标主要包括 R 方、均方误差、解释性方差、绝对误差等等。


模型名称	指标名称	指标值
测试集		
随机森林回归模型	R 方	0.8129
	均方误差	9214.8446
	解释方差分	0.813
	绝对误差	74.0079

从上表可以看出，R 方分值为 0.8129，说明模型效果比较好。

关键代码如下：

```
print('随机森林回归模型-最优参数-R方值: {}'.format(round(r2_score(y_test, y_pred), 4)))
print('随机森林回归模型-最优参数-均方误差: {}'.format(round(mean_squared_error(y_test, y_pred), 4)))
print('随机森林回归模型-最优参数-可解释方差值: {}'.format(round(explained_variance_score(y_test, y_pred), 4)))
print('随机森林回归模型-最优参数-平均绝对误差: {}'.format(round(mean_absolute_error(y_test, y_pred), 4)))
```

7.2 真实值与预测值对比图



从上图可以看出真实值和预测值波动基本一致，模型效果良好。

8. 结论与展望

综上所述，本文采用了 BOA 蝴蝶优化算法寻找随机森林回归算法的最优参数值来构建回归模型，最终证明了我们提出的模型效果良好。此模型可用于日常产品的预测。