

中图分类号：

密级：公 开

学科分类号：

论文编号：212214072

山东财经大学

硕士学位论文

（专业学位）

基于代谢相关指标的颈动脉粥样硬化发生 风险预测研究

作者姓名：唐川平

学科专业：应用统计学硕士

指导教师：张霄帅（副教授）

培养学院：统计与数学学院

二〇二三年五月二十日

Risk prediction of carotid atherosclerosis based on metabolic related indicators

A Dissertation Submitted for the Degree of Master

Candidate: Tang Chuanping

Supervisor: Prof.Zhang Xiaoshuai

School of Statistics and Mathematics

Shandong University of Finance and Economics

中图分类号：

密级：公 开

学科分类号：

论文编号：212214072

硕 士 学 位 论 文

基于代谢相关指标的颈动脉粥样硬化发生风险预测研究

作 者 姓 名： 唐川平

申请学位级别：经济学硕士

指导教师姓名： 张霄帅

职 称：副教授

学 科 专 业： 应用统计学

研 究 方 向：医学统计

学 习 时 间： 自 2021 年 9 月 1 日 起至 2023 年 6 月 30 日 止

学位授予单位： 山东财经大学

学位授予日期：2023 年 6 月

摘要

近年来,随着生活水平质量的提升,颈动脉粥样硬化发病率逐年递增。颈动脉粥样硬化是指颈动脉在年龄增长、糖和脂质代谢异常以及高血压等因素综合影响下,逐渐出现粥样硬化病变。颈动脉粥样硬化早期一般是无症状,而其持续发展是导致缺血性脑卒中的重要原因。据相关调查显示,我国无症状的颈动脉粥样硬化标准发病率高达 36.2%。因此建立有效的颈动脉粥样硬化发病风险预测模型,及早预测颈动脉粥样硬化的发生,积极推动一级预防,对防止颈动脉粥样硬化及心脑血管事件的发生具有重要意义。

因此本研究利用队列研究设计,以未患颈动脉粥样硬化的人群作为研究对象,采用机器学习领域的 stacking 集成学习方法并结合医院的电子体检信息,建立一个可以识别颈动脉粥样硬化高危人群的模型。旨在为颈动脉粥样硬化的发病风险提供一种更为准确、更方便快捷的计算方法。本文主要的研究内容和结论如下:

(1) 查阅了有关颈动脉粥样硬化相关研究文献,将影响颈动脉粥样硬化的特征按照人口学指标、化验指标、临床病史进行整理分类。在山东省某三甲医院医疗数据库中收集 1669 个样本,主要获取其基线中相关代谢体检数据及后期的疾病发生结局,通过不同的特征选择方法构建了颈动脉粥样硬化相关代谢指标体系。

(2) 首先分别采用多因素逻辑回归、支持向量机、随机森林、XGBoost、GBDT 算法建立颈动脉粥样硬化发病风险的单一预测模型,利用 AUC 值、混淆矩阵等指标进行模型预测效果优良判别,结果显示五种模型都存在一定程度上的拟合问题,且发病风险预测能力一般。然后采用 super learner 集成算法将逻辑回归、随机森林、支持向量机、XGBoost、GBDT 进行加权,结果显示 super learner 集成模型解决了单一模型的过拟合和欠拟合问题,且预测效果更优,具备对颈动脉粥样硬化发病风险的预测能力,可以有效识别出潜在的高危人群。

(3) 利用 SHAP 框架解决了机器学习模型尤其是复杂模型的“黑盒”问题。对模型的各个特征进行解释,包括在全样本角度下的特征重要性排序,以及针对个体特征方向和特征大小的解释,实现了对每个样本个案的个性化评估,以此可以针对性提出干预方案,从而降低颈动脉粥样硬化高危人群的发病风险。

总之,不同于以往研究多聚焦于对颈动脉粥样硬化患者的诊断,本研究以健康人群作为研究对象,采用集成学习算法构建了颈动脉粥样硬化发生风险预测模型,提高

了模型的预测能力；丰富了颈动脉粥样硬化疾病预测模型的研究，进一步对模型做出个性化解释，对个体提出针对性的干预方案降低颈动脉粥样硬化高危人群的发病风险，具有一定的实用价值。

关键词：颈动脉粥样硬化；风险预测；集成学习；Super learner 模型；SHAP 框架

Abstract

In recent years, with the improvement of living standards and quality, the incidence of carotid atherosclerosis increases year by year. Carotid atherosclerosis refers to the gradual development of atherosclerotic lesions in the carotid arteries under the combined influence of aging, abnormal sugar and lipid metabolism, and high blood pressure. The early stage of carotid atherosclerosis is usually asymptomatic, and its progression is an important cause of ischemic stroke. According to relevant surveys, the standard incidence of asymptomatic carotid atherosclerosis in China is as high as 36.2%. Therefore, the establishment of an effective risk prediction model for carotid atherosclerosis, early prediction of the occurrence of carotid atherosclerosis, and active promotion of primary prevention are of great significance to prevent the occurrence of carotid atherosclerosis and cardiovascular and cerebrovascular events.

Therefore, in this study, the population without carotid atherosclerosis was selected as the research object using a cohort study design. The integrated learning method in the field of machine learning was used in combination with electronic physical examination information of the hospital to establish a model that can identify carotid atherosclerosis high-risk populations. The aim is to provide a more accurate and convenient method for calculating the risk of carotid atherosclerosis. The main research contents and conclusions of this paper are as follows:

(1) The literature related to carotid atherosclerosis was reviewed, and the characteristics affecting carotid atherosclerosis were sorted and classified according to demographic indicators, laboratory indicators and clinical history. A total of 1669 samples were collected from the medical database of a third-class hospital in Shandong Province. The baseline metabolic physical examination data and the later disease outcomes were mainly obtained, and the metabolic index system related to carotid atherosclerosis was constructed by different feature selection methods.

(2) Firstly, multi-factor logistic regression, support vector machine, random forest, XGBoost and GBDT algorithms were used to establish a single prediction model for the risk of carotid atherosclerosis, and the AUC value, confusion matrix and other indicators were

used to distinguish the model prediction effect. The results showed that the five models all had a certain degree of fitting problems. And the ability to predict the risk of disease is not so good. Then, super learner integration algorithm is used to weight logistic regression, random forest, support vector machine, XGBoost, GBDT. The results show that super learner integration model solves the problem of overfitting and underfitting of a single model, and the prediction effect is better. The ability to predict the risk of carotid atherosclerosis can effectively identify potential high-risk groups.

(3) Using SHAP framework to solve the "black box" problem of machine learning models, especially complex models. Each feature of the model was explained, including the feature importance ranking from the perspective of the whole sample, as well as the interpretation of the direction and size of individual features, so as to realize the personalized evaluation of each sample case, so as to give targeted intervention programs, so as to reduce the risk of carotid atherosclerosis in high-risk groups.

In conclusion, different from previous studies, which mostly focused on the diagnosis of patients with carotid atherosclerosis, this study took healthy people as the research object, adopted integrated learning algorithm to build a carotid atherosclerosis risk prediction model, and improved the prediction ability of the model. It has enriched the research on the prediction model of carotid atherosclerosis disease. It is of certain practical value to further make personalized interpretation of the model and carry out targeted intervention programs for individuals to reduce the risk of carotid atherosclerosis in high-risk groups.

Key words: Carotid atherosclerosis; Risk prediction; Ensemble learning; Super learner; SHAP framework

目 录

第 1 章 绪论.....	1
1.1 研究背景和研究意义.....	1
1.1.1 研究背景.....	1
1.1.2 研究意义.....	2
1.2 文献综述.....	3
1.2.1 颈动脉粥样硬化的影响因素研究.....	3
1.2.2 颈动脉粥样硬化的预测研究.....	5
1.2.3 机器学习算法在疾病预测模型的应用研究	6
1.2.4 简要评述.....	7
1.3 研究思路、方法、主要内容和框架	8
1.3.1 研究思路.....	8
1.3.2 研究方法.....	8
1.3.3 主要内容和框架.....	8
1.4 创新点.....	10
第 2 章 相关理论和方法	11
2.1 疾病预测相关理论和方法	11
2.1.1 临床疾病预测模型基本概念.....	11
2.1.2 临床预测模型的研究思路和流程.....	12
2.2 疾病预测模型相关理论和方法	12
2.2.1 经典疾病预测模型介绍.....	12
2.2.2 基于 stacking 思想的 super learner 算法	15
2.3 疾病预测模型评价理论和方法	17
2.4 本章小结.....	18
第 3 章 颈动脉粥样硬化样本选取及其代谢指标体系构建	20
3.1 颈动脉粥样硬化样本的选取	20
3.1.1 实验设计说明.....	20
3.1.2 实验数据的收集和说明.....	21
3.1.3 数据预处理.....	21
3.2 颈动脉粥样硬化相关代谢指标体系的构建	22
3.2.1 基于文献研究的指标选取.....	22
3.2.2 基于机器学习算法的指标选取.....	25
3.2.3 颈动脉粥样硬化相关代谢指标体系的确定	29
3.3 本章小节.....	31
第 4 章 颈动脉粥样硬化发生风险预测模型构建	32

4.1 颈动脉粥样硬化发病风险预测模型建立	32
4.1.1 数据不平衡处理	32
4.1.2 样本划分说明	32
4.1.3 单一模型的训练和评价	33
4.1.4 基于 stacking 思想集成模型的训练和评价	36
4.2 基于 SHAP 框架的模型解释	37
4.3 本章小结	40
第 5 章 研究结论与展望	41
5.1 研究结论	41
5.2 展望	42
参考文献	44

第1章 绪论

1.1 研究背景和研究意义

1.1.1 研究背景

近年来,随着医疗卫生水平的提高以及生活水平质量的提升,人口老龄化情况越来越严重。据第七次全国人口普查数据显示,2020年我国60岁及以上人口2.64亿,65岁及以上人口1.9亿,占比达到13.5%。根据国际一般公认标准,一个国家或地区65岁及以上人口比例达到14%即为中度老龄化社会,因此我国目前的人口老龄化问题不容小觑。而因为年龄增长导致的一系列中老年人疾病也越发突出,给医疗卫生系统带来了不小的压力。其中心脑血管类疾病是在中老年人中最常见的疾病之一,与糖尿病、肿瘤并称当代三大严重威胁人类健康的慢性非传染疾病。《健康中国行动(2019—2030年)》围绕疾病预防和健康促进两大核心,提出将开展15个重大专项行动。心脑血管类疾病防治行动是其中重要的一个,其行动主要针对一般成年人、心脑血管疾病高危人群和患者,给出日常自我健康管理,自我健康监测等建议。目的是促进以治病为中心向以人民健康为中心转变,努力使群众不生病、少生病。

动脉粥样硬化性心血管疾病是目前人类致死致残的首要原因。颈动脉作为动脉粥样硬化最常累积的部位,因其位置表浅易于检测,常作为反映全身动脉粥样硬化病变的窗口,能够有效预测冠心病、脑卒中等心脑血管疾病。颈动脉粥样硬化(Carotid atherosclerosis, CAS)是指颈动脉受年龄增长、糖和脂质代谢异常、吸烟、高血压等因素综合影响,逐渐出现粥样硬化病变。颈动脉粥样硬化作为动脉粥样硬化在局部血管的表现,其持续发展是缺血性脑卒中的重要原因,如何及早预测颈动脉粥样硬化的发展对预防缺血性脑卒中具有重要价值。根据相关调查显示,目前中国无症状性颈动脉粥样硬化标准化发病率为36.2%,并且处于早期的颈动脉粥样硬化患者并不会会有较大的症状,例如只会偶尔出现头晕或轻度头痛,往往容易被忽视,但是一旦情况加重,将严重损害患者的身体健康和精神健康,同时也给患者家庭造成了巨大的经济负担。因此,如何及早预测颈动脉粥样硬化的发生,积极推动一级预防,对防止颈动脉粥样硬化及心脑血管事件的发生具有重要意义。

目前,对于颈动脉粥样硬化的研究主要集中在影响因素分析层面,常见的危险因素包括年龄、吸烟、血糖血脂代谢异常、高血压等。在医学领域中,常使用预测模型

来预测未来一段时间内某种状态（健康 / 疾病 / 死亡）的发生情况。疾病预测模型相关的建立方法已经发展得较为成熟，预测模型在健康人群和发病人群中均有应用。其中，部分模型已被推荐或已被纳入疾病防治指南，因此疾病预测模型的重要地位可见一斑。现有研究中对颈动脉粥样硬化预测模型较少，且主要是基于横断面数据构建预测模型对疾病进行诊断，或采用的模型较为简单，预测效果一般。

随着互联网以及计算机的发展，机器学习算法逐渐被应用在医学疾病预测模型中。集合学习是机器学习中的一类方法，其思想是将一系列弱分类器集成成强分类器的过程。相比较于传统的预测模型，其不仅能够处理大量的缺失值数据，在解决模型的泛化能力方面也比较突出，在模型的预测准确率上也同样有优势。目前在某些疾病领域已经有了采用集合学习的方法进行预测研究的案例，且模型预测效果显著，适用性广泛。

因此，本研究拟将尚未患动脉粥样硬化的健康体检人群作为研究对象，获取其基线数据并随访其疾病发生结局。建立颈动脉粥样硬化相关代谢指标体系，采用集成学习算法构建发病风险预测模型，用于对颈动脉粥样硬化发病风险的评估。进一步根据预测风险识别高危人群，结合 SHAP 可解释性框架，针对高危人群提出干预措施，为心脑血管疾病的预防提供科学依据。

1.1.2 研究意义

1.理论意义：

（1）本文建模丰富了颈动脉粥样硬化疾病预测模型的研究

在以往的颈动脉粥样硬化的发病风险研究中，多数是基于横断面的数据，即数据集中既有发病也有不发病的样本，此时构建预测模型的目的是对疾病进行诊断或筛检。而本研究是面向健康人群队列的颈动脉粥样硬化发病风险预测研究，所有样本基线都是健康人群，通过建立预测模型用于评估个体未来发生颈动脉粥样硬化的风险。

（2）建立了颈动脉粥样硬化相关代谢指标体系

在以往的颈动脉粥样硬化影响因素研究中，对代谢相关指标并未过多涉及。因此本文所构建的颈动脉粥样硬化相关代谢指标体系丰富了颈动脉粥样硬化影响因素领域内的研究。

（3）利用 SHAP 框架对颈动脉粥样硬化的重要特征进行个性化解释

在以往的机器学习模型中存在着无法对结果进行合理解释的问题，尤其是在复杂

模型中，无法解释特征之间的关联。而本研究利用 SHAP 框架可以对这些特征做出个性化解释，并根据结果提出针对性的干预方案来改善潜在颈动脉粥样硬化患者的身体状况，降低其发生颈动脉粥样硬化的风险。

（4）在颈动脉粥样硬化风险预测领域采用 stacking 集合学习的方法进行研究

在以往的颈动脉粥样硬化发病风险预测研究中，所用的模型较为单一。而本研究首先采用多种机器学习单一模型，然后再利用 stacking 方法集合各个模型，用于提升其预测准确率。为其他研究者提供了一种计算疾病发病风险的思路，也丰富了 stacking 集合方法在相关领域的应用。

2.现实意义：

（1）发掘潜在影响颈动脉粥样硬化的相关因素

目前对颈动脉粥样硬化传统危险因素的研究已经比较完善。但除了传统危险因素以外，对新危险因素的持续识别和理解能够进一步提高对未来颈动脉粥样硬化发病风险的预测能力。因此，本研究通过较高的指标覆盖率，利用模型进行重要因素的发掘。这对识别颈动脉粥样硬化的早期危险信号具有重要意义，为颈动脉粥样硬化的发病机制和预防策略提供新的见解，对于控制心脑血管疾病的发生发展也是至关重要的。

（2）本研究所构建的模型可以为临床医生提供一种发病风险辅助计算工具

本研究所构建的风险预测模型一定程度上可以降低预测错误率，提高了医生对颈动脉粥样硬化发生的把控能力，可以避免重复和耗时的人力事务，提高了医生的工作效率，使有限的医疗资源得到合理配置。

（3）识别高危人群并及时进行干预

本研究所构建的风险预测模型可以有效识别出高危人群，及时针对高危个体的危险因素进行干预，避免因病情进一步发生发展而增加其精神上 and 物质上的双重负担压力，这对于维护人们群众的身心健康有着重要意义。

1.2 文献综述

1.2.1 颈动脉粥样硬化的影响因素研究

目前大多数研究集中在颈动脉粥样硬化的发病机制和危险因素，并且一致认为造成颈动脉粥样硬化的原因是来源于多种因素的共同作用。目前已确定的颈动脉粥样硬化的危险因素主要包括年龄、性别、高血糖、高血脂、高血压、糖尿病、肥胖、吸烟、

饮酒、炎症水平的升高。其中主要代表有：Fine-Edelstein et al. (1994) 研究发现，平均每天吸 10 支烟，颈动脉粥样硬化的风险增加 1.3-1.5 倍^[1]。李莉(1996)，卫华(2001) 研究发现高血压是颈动脉粥样硬化的重要影响因素^[2,3]。Kiechl et al. (1998) 的研究表明经常饮酒与早期的颈动脉粥样硬化的关系呈“J”形关系，酒精消耗量<50g/d 是保护作用，经常饮酒与晚期的颈动脉粥样硬化，呈现“U”形关联^[4]。Lakka et al. (2001) 研究发现腹型肥胖与颈动脉粥样硬化进程加速相关^[5]。喻雪红(2006) 通过文献搜索发现年龄、性别、吸烟、饮酒、肥胖、血压、血脂、糖尿病、高血糖、血浆同型半胱氨酸、炎症这些词语在有关颈动脉粥样硬化影响因素的研究文献中出现次数较多^[6]。张东平等(2009)对重庆市中老年钢铁工人颈动脉粥样硬化的流行病学调查发现年龄、吸烟、高血压、糖尿病、高敏 C 反应蛋白、高胆固醇血症和高低密度脂蛋白血症是影响颈动脉粥样硬化的主要危险因素^[7]。王薇等(2010)基于横截面数据证实有高血压、糖尿病、超重、高 LDL 胆固醇血症者会导致其颈动脉内膜中膜厚度及斑块发病率增加，并且年龄是颈动脉粥样硬化的重要危险因素^[8]。Taylor et al. (2014) 通过对马拉松运动员颈动脉粥样硬化的分析研究发现慢性耐力运动虽然改善了心血管危险因素，但并不降低与年龄和心血管危险因素相关的颈动脉粥样硬化程度^[9]。王琪等(2019) 通过研究发现年龄、收缩压升高、低密度脂蛋白升高是男性和女性发病的共同危险因素，空腹血糖升高和甘油三酯升高仅与男性发病有关，腹型肥胖仅与女性发病有关^[10]。王瑞星(2019)通过对比糖尿病合并高血压患者与高血压患者之间颈动脉粥样硬化的情况，发现总胆固醇是颈动脉粥样硬化的危险因素^[11]。Yuan et al. (2019) 研究发现糖尿病患者脑血管疾病发生率远高于非糖尿病人群，长期的高血糖水平引起的血管内皮氧化应激和炎症会加速动脉粥样硬化发生^[12]。万密密等(2021)、鲁明等(2020) 研究发现动脉粥样硬化病因复杂，吸烟、饮酒、高血压、高血脂、糖尿病均是该病的重要危险因素^[13,14]。丁瑶等(2020) 利用北京市某医院青年体检人群的横断面数据，结果显示年龄、腰高比、高密度脂蛋白胆固醇对预测青年人群颈动脉粥样硬化具有一定可行性^[15]。赵春燕等(2021) 通过测量颈动脉粥样硬化患者与非颈动脉粥样硬化患者之间的各项体检指标后，认为颈动脉硬化发生与性别、年龄、糖尿病史、收缩压相关^[16]。孙靖伦(2021) 对朝阳农村地区的脑卒中高危人群颈动脉硬化进行横断面研究，发现男性、高龄、高血压、糖尿病、吸烟是脑卒中高危人群颈动脉粥样硬化的危险因素^[17]。潘雯等(2021)通过对无心血管危险因素的中老年人群进行研究发现，高年龄、男性、高糖化血红蛋白、高脉压差和升高的高密度脂蛋白胆固醇与这类人群中患动脉

粥样硬化具有高度相关性^[18]。Wu et al. (2021) 认为血压变异性 (BPV) 在颈动脉不同节段的早期颈动脉粥样硬化进展中起着明显的作用,特别是对高血压伴糖尿病和不伴糖尿病的患者^[19]。Hollander et al. (2002) 研究认为吸烟、低体力活动、高血压、糖尿病或高脂血症是无症状颈动脉粥样硬化患者中最显著的危险因素^[20]。

除了上述被多次证实的危险因素外,也有部分其他新风险因素的研究。Luedemann et al. (2002) 研究表明,体力活动缺乏者颈动脉粥样硬化的发病风险增加 1.9 倍^[21]。王宁等 (2010) 在研究原高血压患者人群中发现血浆同型半胱氨酸是原发性高血压患者颈动脉粥样硬化的一种新的独立危险因素^[22]。罗国刚等 (2012) 在研究缺血性脑血管病患者血浆同型半胱氨酸水平与颈动脉粥样硬化斑块的关系中发现高同型半胱氨酸血症是颈动脉粥样硬化斑块形成的独立危险因素^[23]。陈英等 (2017) 采用应用酶联免疫吸附试验得出肿瘤坏死因子- α (TNF- α)、白细胞介素 6 (IL-6)、白细胞介素 17 (IL-17) 在类风湿关节炎早发动脉粥样硬化患者中均高表达,可能共同参与了此类患者中动脉粥样硬化的发病过程^[24]。郑迪等 (2019) 研究发现检测血清胱抑素 C 和视黄醇结合蛋白参与了原发性高血压患者颈动脉粥样硬化的发生和发展,并且可作为动脉硬化的危险因素^[25]。顾叶青 (2020) 研究发现甲状腺功能指标可以作为预测颈动脉粥样硬化的重要手段^[26]。李佳等 (2020) 研究发现肱踝脉搏波传导速度是早期 H 型高血压患者颈动脉粥样硬化的危险因素^[27]。杨帆等 (2021) 研究发现颈动脉超声 Crouse 积分法和血浆致动脉硬化指数相结合可以作为慢性精神分裂症患者颈动脉粥样硬化的“风向杆”^[28]。邱雪婷等 (2021), 胡培章等 (2021) 对二型糖尿病患者人群研究发现血清半乳糖凝集素-3 是其颈动脉粥样硬化的重要相关因素^[29,30]。尹建红等 (2022) 研究发现血清白脂素是颈动脉粥样硬化重要影响因素^[31]。

基于上述研究,可以发现大部分研究识别的影响因素之间有重合。总结出目前影响颈动脉粥样硬化的危险因素主要有:年龄、性别、吸烟、饮酒、高血压、高血糖、高血脂、血浆同型半胱氨酸、运动、糖尿病、低密度脂蛋白胆固醇、高密度脂蛋白胆固醇、肿瘤坏死因子- α (TNF- α)、白细胞介素 6 (IL-6)、白细胞介素 17 (IL-17)、血清胱抑素 C、视黄醇结合蛋白、甲状腺功能指标、肱踝脉搏波传导速度、血清半乳糖凝集素-3、血清白脂素等。

1.2.2 颈动脉粥样硬化的预测研究

除了上述对颈动脉粥样硬化的影响因素研究外,也有少数对颈动脉粥样硬化进行

风险预测的研究。其中主要的模型构建方法有: Logistic 模型、机器学习算法模型等。

邹晓璇(2010)利用 Logistic 模型对北京石景山区和首钢的中老年队列人群颈动脉粥样硬化进行风险预测^[32]。梁蕴瑜等(2021)也采用 Logistic 回归方法对原发性高血压患者颈动脉粥样硬化的发生进行预测,并且认为外周血同型半胱氨酸、血小板淋巴细胞比值、C 反应蛋白三个指标结合可以大大提高预测结果准确率^[33]。Fan et al.(2021)基于横断面数据,通过比较机器学习算法对无症状颈动脉粥样硬化的识别效果时发现随机森林的预测识别效果最好^[34]。王娇娇等(2022)通过对重庆市钢铁工人人群的颈动脉粥样硬化横断面研究结果显示支持向量机的综合预测效果较好^[35]。丁瑶等(2020)采用基于横断面数据的 CatBoost 模型预测了中青年颈动脉粥样硬化的发病情况^[15]。

根据研究目的,疾病预测模型可分为诊断模型、疾病发生模型和预后模型。以上论文中所构建的颈动脉粥样硬化预测模型,主要是基于横断面研究的疾病诊断模型。即研究对象中已有颈动脉粥样硬化的患者和非患者,多是根据研究对象的症状和特征,利用 Logistic 模型或其他机器学习算法识别危险因素,并估计每个研究对象此刻的发病概率。而疾病发生模型,是在队列研究的设计下,基于健康人群的基线信息预测其未来发生疾病的概率,对疾病预防方面更具现实意义。现有文献对相关人群的颈动脉粥样硬化发生风险预测研究较少,并且预测模型较为简单,预测效果一般。因此,本研究是面向健康人群队列的风险研究,采取多种方法综合选取最优发病风险预测模型,并针对高危人群及时提出干预措施,降低其颈动脉粥样硬化的发生风险。

1.2.3 机器学习算法在疾病预测模型的应用研究

随着技术的进步以及各领域的交叉发展,关于疾病预测的研究方法层出不穷,机器学习中的集合学习方法因为其巨大的优势被广泛运用于疾病辅助诊断。近年来众多研究学者们使用机器算法构建疾病预测的推理模型用以辅助医生诊断分析^[36]。徐继伟等人等(2018)系统的论述了集合学习在时间序列、医疗应用和系统入侵检测领域的应用^[37]。兰欣等(2019)也阐述了机器学习的定义及分类,介绍了决策树、贝叶斯网络、人工神经网络、支持向量机、深度学习等经典算法,分析了机器学习在疾病预测、疾病辅助诊断、疾病预后评估等领域的作用^[38]。胡满满等(2019)采用一种基于动态采样和迁移学习的方法对疾病进行预测,解决了数据不平衡问题,提高了模型的准确率^[39]。郑晓燕(2018)利用随机森林、逻辑回归和决策树算法建立慢性疾病预测

模型^[40]。赵丹丹（2019）采用 RUSBoost 算法解决样本不平衡问题，再利用支持向量机算法建立结直肠癌预测模型^[41]。Shim et al.（2020）分别采用 k 近邻、决策树、随机森林、梯度推进、支持向量机、人工神经网络和逻辑回归方法对绝经后妇女骨质疏松症进行风险预测^[42]，还利用这些模型对慢性下腰痛进行预测^[43]。Jamthikar et al.（2021）采用支持向量机、随机森林、XGBoost 三种多类机器学习算法对 CVD/卒中风险进行评估^[44]。武海滨等（2019）采用神经网络结合替换切点技术建立的人群糖尿病 5 年发病风险模型^[45]。黄雪倩等（2021）采用 stacking 集成方法构建了弥漫大 B 细胞淋巴瘤患者疾病进展阶段的层次多分类预测模型^[46]。李英杰等（2022）也采用 stacking 集成学习构建了辽宁省肾综合征出血热发病情况的预测模型^[47]。

因此基于以上研究，可以将机器学习算法应用到疾病风险预测模型中。通过结合医学领域的研究以及样本数据建立的数据库系统，对医疗数据进行信息挖掘和知识构建，应用于疾病风险推断的深入研究，为辅助计算提供了参考，建立个性化的风险预测模型，同时也为提高疾病发生风险评估准确性提供数据支持^[36]。

1.2.4 简要评述

从国内外目前的研究成果中，可以总结出以下几点贡献：（a）证实了有关颈动脉粥样硬化的重要影响因素，包括：年龄、性别、吸烟、高血压、高血糖、高血脂等指标。（b）目前用于分析颈动脉粥样硬化的危险因素大都采用传统的基础统计分析和统计模型，例如单因素方差分析、多元线性回归、Logistic 回归等。（c）目前也有将机器学习算法例如随机森林、支持向量机等用于颈动脉粥样硬化的风险预测。但其主要是基于横断面研究的疾病诊断模型，即根据研究对象的症状和特征，识别出每个研究对象是否在此时刻为颈动脉粥样硬化患者。

目前还存在的问题有：（a）在相关指标的选取上覆盖程度较低，对潜在与颈动脉粥样硬化发生相关的影响因素还未发掘完，尤其缺少代谢相关指标。（b）部分研究往往存在数据量少，数据质量不理想，并且缺失值多的情况。因此针对这些情况，如何合理地进行数据清洗和特征选择是一个需要进一步研究的问题。（c）基于 stacking 集合学习方法对疾病进行风险预测的文章较少。（d）目前基于队列研究设计，面向健康人群的颈动脉粥样硬化风险预测研究较少，且模型较为简单，预测效果一般，还没有一个更高效、准确的预测工具。

1.3 研究思路、方法、主要内容和框架

1.3.1 研究思路

本研究以在医院体检的健康人群作为研究对象,首先采用文献研究的方式围绕着颈动脉粥样硬化的影响因素和风险预测模型两方面展开,确定研究方法。针对样本数据缺失、样本指标变量冗杂等问题,运用机器学习中的变量筛选策略确定影响因子,建立颈动脉粥样硬化相关代谢指标体系。然后通过机器学习算法建立单一模型,再使用 **stacking** 方法提高对颈动脉粥样硬化发病风险的预测能力,用于识别高危人群。最后利用 **SHAP** 框架对颈动脉粥样硬化的发生做出个性化解释,为制定高危人群的干预措施提出合理建议,降低一般人群颈动脉粥样硬化发病的风险。

1.3.2 研究方法

(1) 真实世界研究法。本研究是利用医院真实的体检数据,包含了病人全面体检的各种指标,具有真实性和实用性,对辅助医生测算颈动脉粥样硬化的发病风险具有一定的参考性和应用价值。

(2) 文献研究法。本研究通过查询颈动脉粥样硬化重要影响因素方面的文献整理出了各种危险因素,再通过查询颈动脉粥样硬化风险预测模型的相关文献,总结出其中的不足之处和可以借鉴的地方,最终确定本文所采用的研究思路和方法。

(3) 统计分析法。本研究利用统计方法进行了数据的统计整理和筛选,对样本队列人群基线数据特征进行了统计分析。

(4) 机器学习算法。本研究不但利用了机器学习方法进行特征选择,并且利用逻辑回归、随机森林、支持向量机、GBDT、XGBoost 这五种机器学习算法分别建立了颈动脉粥样硬化的发生风险预测单一模型,再利用 **stacking** 集合各个模型用于提高预测效果,最终构建了高效的颈动脉粥样硬化发病风险预测模型。

1.3.3 主要内容和框架

本研究根据图 1-1 的技术路线展开,主要内容包括:

第一章绪论部分主要阐明了有关颈动脉粥样硬化的研究背景、研究意义、文献综述和研究内容以及创新点。叙述了国内外对颈动脉粥样硬化的研究现状,其中搜集整理了颈动脉粥样硬化的重要危险因素以及有关颈动脉粥样硬化的风险预测模型。最后

确定本文的研究路线、研究内容和结构框架。

第二章相关理论和方法部分主要阐述了本文所用到的理论方法。包括疾病预测概念、疾病预测模型、模型评价体系的理论方法。

第三章颈动脉粥样硬化样本选取及其代谢指标体系构建部分主要进行了样本的选取说明和颈动脉粥样硬化相关代谢指标体系的建立。包括对实验设计、实验数据的收集和说明以及数据预处理,以及基于文献研究和机器学习方法对原始特征进行变量选择,从而找出有效的颈动脉粥样硬化发生影响因子,建立颈动脉粥样硬化代谢相关指标体系。

第四章颈动脉粥样硬化发生风险预测模型构建部分主要包括建立颈动脉粥样硬化发生的单一预测模型和 **stacking** 集合模型以及对所建模型的解释。具体包括分别建立多因素逻辑回归、随机森林、支持向量机、XGBoost、GBDT 的单一模型用于对颈动脉粥样硬化的风险预测,然后将其加权成 **stacking** 集合模型,通过准确率、召回率、精度、AUC、F1 五种指标来评价模型的预测效果,最后结合 **SHAP** 框架对各个特征变量进行个性化解释。目的是识别出高危人群并对其提出合理的措施进行干预,降低其发病的风险。

第五章研究结论与展望部分主要对本文的研究方法和研究成果进行总结。包括叙述了本文的研究成果以及对后续研究的展望。




图 1-1 本文的技术路线

1.4 创新点

1.本研究的实验设计与以往的研究不同

以往关于颈动脉粥样硬化的研究主要是基于流行病学横断面研究设计，构建的是疾病诊断模型，目的是对人群进行诊断，从而判定其是否为颈动脉粥样硬化患者。而本研究利用队列研究设计，以尚未患颈动脉粥样硬化的人群作为研究对象，构建疾病发生模型来预测其未来发生颈动脉粥样硬化的风险，在疾病预防方面更具现实意义。

2.本研究所使用的集合模型与以往对颈动脉粥样硬化风险预测模型不同

以往对颈动脉粥样硬化的风险预测研究主要是构建颈动脉粥样硬化的诊断模型，多采用逻辑回归方法进行研究，少部分学者采用随机森林、支持向量机、神经网络等单个机器学习方法进行研究。而本研究不仅分别使用逻辑回归、随机森林、支持向量机、GBDT、XGBoost 方法建立颈动脉粥样硬化发病风险预测模型，而且使用 stacking 方法集成这五种模型来提升模型的预测效果，用于提高对颈动脉粥样硬化发病风险概率计算的准确程度，因此具有一定的创新性。

第2章 相关理论和方法

本章首先简要阐述了疾病预测领域里的相关理论和方法,具体包括临床疾病预测模型的基本概念以及研究思路和研究流程。其次阐述了部分疾病预测模型的原理和方法,具体包括逻辑回归、支持向量机、随机森林、梯度提升树、极致梯度提升树、super learner 超级学习器共六种算法。最后论述了模型评价的相关指标,具体包括对准确率、精度、召回率、F1、AUC 值的介绍。为后续构建颈动脉粥样硬化相关代谢指标体系和发病风险预测模型奠定了理论基础。

2.1 疾病预测相关理论和方法

2.1.1 临床疾病预测模型基本概念

通常情况下的临床疾病预测研究,是指利用数学模型(参数/半参数/非参数)计算研究对象当前或者将来发生某种结局(一般指的是疾病)的概率。预测模型是通过整合各种已知特征来预测未来,而模型就是一个数学公式,也就是把已知的特征通过这个模型计算出未知结局发生的概率^[48]。

依据研究的临床问题,临床预测模型包括:诊断模型、预后模型和用于预测疾病是否发生的模型^[48]。三种临床预测模型领域都有各自相对完备的理论和方法,其中:诊断模型一般情况下多关注的是基于所研究对象的临床症状和特征(样本中存在已经被确诊为某种疾病的个体),多见于横断面研究,计算的是个体当前患有某种疾病的概率,以此来判断该个体是否具有该种疾病,被称为诊断模型;而预后模型多关注的是基于当前的状态下,计算未来一段时间内(根据不同疾病时间会有所不同,一般是一年、三年、五年)疾病复发、死亡、伤残以及出现并发症等结局的概率,多见于队列研究。而队列研究需要事先设置好队列基线和随访时间,相比于诊断模型,预后模型的实验设计要更加繁琐和精确。并且与诊断模型不同的是,预后模型的研究内容侧重于疾病在未来的发生情况。因此两种模型的主要区别在于是否有生存时间(基线到结局发生的时间);还有一类研究根据研究对象的一般特点预测未来是否会发生某种特定的疾病,被称为疾病发生模型,也常见于队列研究。诊断模型、预后模型与疾病发生模型有很多相同的地方:他们的事件结局多为二分类指标;都是计算事件发生的概率,代表着结局出现的绝对风险;在模型的构建过程中,也都需要进行特征选择、建模方法选取、所建模型性能的评价与验证等环节。

通过查阅颈动脉粥样硬化相关文献,发现绝大部分有关颈动脉粥样硬化的研究都是疾病诊断模型,而针对颈动脉粥样硬化未来是否发生的研究较少。因此本研究建立疾病发生模型用于识别出颈动脉粥样硬化发病高危人群。

2.1.2 临床预测模型的研究思路和流程

临床预测模型长时间作为生物医学领域内重要的工具,在医学研究尤其在医疗实践中应用非常广泛。它可以提高相关卫生部门管理医疗服务质量,从而使医疗资源得到合理的配置。通常情况下临床预测模型的研究流程由图 2-1 所示。临床预测模型并不是局限于构建一个数学模型那样简单,从模型方法的选取,到模型建立,再到模型综合评价,最后到实际验证和应用,临床预测模型都有一套完备的研究方法。




图 2-1 临床预测模型的研究流程

2.2 疾病预测模型相关理论和方法

2.2.1 经典疾病预测模型介绍

在现有与疾病预测相关的研究中,最常采用的是逻辑回归、随机森林、支持向量机等单一算法,在模型预测效果上表现良好,即对疾病预测具有较高的准确率。本文首先采用了逻辑回归、随机森林、支持向量机、XGBoost 和 GBDT 五种算法预测颈动脉粥样硬化的发病风险。具体如下:

1. 逻辑回归算法 (Logistics Regression, LR)

逻辑回归算法是机器学习领域内非常经典的一个方法,常用于分类问题。尤其是

在处理二分类变量时有良好的分类效果，因此在生物医学统计领域被广泛使用。其公式如下：

$$M_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}} \quad (2.1)$$

逻辑回归本质上是将一般线性函数转化成 S 形函数，而 S 形函数的输出值介于 0 到 1 之间，因此 $M_{\theta}(x)$ 的输出结果就可以代表所属某一类别的概率，并可以以 0.5 作为分界线，超过 0.5 则被预测为 A 类，低于 0.5 则被预测为 B 类。

2. 支持向量机算法 (Support Vector Machine, SVM)

支持向量机算法指的是寻找一个最优的超平面，从而将两类样本数据分离开。并且，支持向量机相比与逻辑回归在处理高维数据时的优势更大。因为在高维空间中，数据相对分散，因此用超平面将其分离更加容易。超平面方程 L 可写为：

$$\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p = \beta_0 + \beta'x = 0 \quad (2.2)$$

则划分样本点 (x_i, y_i) 到超平面 L 的几何距离可以写为：

$$d(x_i, y_i | L) = \frac{y_i(\beta_0 + \beta'x_i)}{\|\beta\|} \quad (2.3)$$

其中 β_0 为位移项，代表原点与超平面之间的距离； β 为垂直于超平面 L 的法向量，表示超平面 L 的方向。支持向量机算法就是通过调整 β_0 和 β ，来实现最大化几何间隔，目的是将更多的样本点分离开。

但是，在通常情况下，数据是线性不可分的，从而需要找出非线性的决策边界。通常采用核函数将其映射到另一个线性可分的空间，如何选取合适的核函数是影响支持向量机模型好坏的重要因素。本文所采用的是径向核函数 (Radial kernel)，由于径向核函数非常接近于正态分布的密度函数，于是又称为高斯核函数。径向核函数可表示为：

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2), \gamma > 0 \quad (2.4)$$

其中 γ 为径向核的参数， $\|\cdot\|$ 为 $L2$ 范数，又称欧氏距离。

3. 基于 bagging 思想的随机森林算法

随机森林属于 bagging 思想的集成学习方法。具体做法是：假设原始数据集中有 M 个数据样本个案和 N 个特征，随机从原始数据集 M 中通过 bootstrap 有放回重采样得到 m 个数据集，然后从 N 个特征中随机抽取 $n < N$ 个特征作为分裂节点组成决策树，最后通过投票或者取平均值的方式得到最终预测值，整个流程可以通过图 2-2 所

表示。




图 2-2 随机森林算法基本原理

本文所采用的随机森林是基于 cart 树原理，即每次都将数据集切分成两份，如图 2-3 所示。相较于其他算法，随机森林算法通过自助抽样能够降低偶然性所导致的预测误差大小，通常在处理多变量和多数据时更具优势。随机森林一个显著的劣势是在处理异常值（噪声）较多的数据上容易过拟合，即在训练集上的预测效果要远远高于测试集或者验证集，因此在建立随机森林模型之前需要对数据进行异常值的处理。




图 2-3 决策树示例

4. 基于 boosting 思想的梯度提升决策树（Gradient Boosting Decision Tree, GBDT）和极致梯度提升树（Extreme Gradient Boosting, XGBoost）算法

Boosting 方法与 bagging 都是属于集成类算法,都是将多个模型进行融合而成的。不同的地方在于, bagging 中基模型的权重都一样,而 boosting 是通过不断迭代,使得一系列弱分类器训练成强分类器。Boosting 算法先利用相同权重的训练集训练得到一个弱分类器,然后每一次新分类器都是在前一个旧分类器的基础上进行的,并且不断调整权重,从而使其逐渐分类正确。Boosting 算法的流程如图 2-4 所示。




图 2-4 boosting 基本流程

（1）梯度提升决策树（GBDT）

GBDT 算法模型引入了损失函数这一概念,通过不断迭代来降低损失函数大小,从而提升模型的预测效果。GBDT 的优势是可以在花费较少时间来调参的情况下,也可以获得较高的正确率。GBDT 的劣势是容易产生过拟合,因此为了降低过拟合程度,通常需要对 GBDT 进行正则化。本文通过调整步长 ρ_m 和最大迭代次数 n 以及子采样比 (bag.fraction) 来防止过拟合。步长的取值范围是(0,1],值越小意味着需要迭代的次数越多;子采样比指的是从全部样本中抽取的比例,取值为(0,1]。

（2）极致梯度提升树（XGBoost）

XGBoost 集成学习算法是在 GBDT 基础上改进的。其依旧使用梯度提升法,但是在具体的算法上做了许多改进,包括使用牛顿下降法(二阶泰勒展开)、改进决策树的算法等,从而提高了算法性能。并且还通过稀疏矩阵和并行的方式提高了运算速度,因此在 kaggle 比赛中被广泛运用。

2.2.2 基于 stacking 思想的 super learner 算法

Bagging 和 boosting 思想主要是通过训练一系列同质或者强相关的分类器进行提

升。与 bagging 和 boosting 不同的是, stacking 通常采用并行的方式训练不同质或弱相关的分类器从而发挥“集百家之长”的优势,因此又被称为堆叠模型。在通常情况下, stacking 模型的预测效果要优于基学习器。

本文使用了一种被称为 super learner 的 stacking 堆叠方法。Super learner 是 Van der Laan et al.(2007)提出的一种基于损失函数的组合预测的学习算法^[49]。Super learner 算法基于交叉验证理论,通过加权的方式组合多种候选算法,从而构造一种最小交叉验证风险的算法组合。

假定当前数据结构为 $O=(S,Y)\sim P_n$, O 是由观测值组成的数据集, P_n 代表其概率分布; S 代表预测因子向量矩阵; Y 代表分类结局,例如在本文中指的是体检人群最终是否患颈动脉粥样硬化。通常在研究中,更关注的是如何计算 P_n 即发病风险,并且在构建模型之前并不会事先知道哪种算法的效果会更好。Van der Laan et al.(2007)证明了在大样本中,可以构建一个包含所有算法加权平均值的算法库,该算法的性能至少会与包括在整体中的最佳个体一样好^[49]。基于此,选择不同的权重系数用于加权组合各种算法(例如选择支持向量机、随机森林、逻辑回归等机器学习算法),发挥出 super learner 算法模型的优势,提高模型的预测性能。这里,最佳是根据有界损失函数定义的,它允许我们定义和量化给定算法在预测或解释数据方面的表现。本文采用的是最大化受试者操作特征曲线(Receiver Operating Characteristic Curve, ROC)下面积(Area Under Curve, AUC)值作为交叉验证风险。

Super learner 算法的基本步骤可以归纳为:①首先,随机将数据集分为 k 组,本文的 k 为 5,然后选择不同的预测算法。②然后遍历每一种算法用于训练集数据,计算在验证集上的发病概率 S 。③在验证集中,通过事件结局和发病概率计算风险,于是得到每一种算法的平均预测风险。④加权不同的预测算法进行组合,更新权重 α 从而得到最小交叉验证风险的算法组合。⑤最后在完整的数据集中拟合每个预测算法,构建 super learner 模型。图 2-5 为利用 super learner 进行生存预测的简要示意图。




图 2-5 Super learner 算法原理图

2.3 疾病预测模型评价理论和方法

模型评价属于机器学习中的重要一环，并且在同一个模型中，必须要求在每轮的迭代中保持评价指标的一致性。本文选取准确率、精度、召回率、F1 和 AUC 值用于模型评价。

1. 混淆矩阵

混淆矩阵适用于分类模型的预测结果，如表 2-1 所示。混淆矩阵可以包括所有的样本。对于二分类问题，有以下四种类型，由于本文的研究对象中颈动脉粥样硬化患者属于少数类样本，因此被划分为正类样本。

表 2-1 二分类问题的混淆矩阵示例

预测值	实际值	
	正样本	负样本
正样本	TP	FP
负样本	FN	TN

(1) 准确率 (accuracy): 准确率指的是所有预测正确的样本占总样本的比例，值越高代表预测能力越强，其计算公式为：

$$accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (2.5)$$

(2) 精度 (precision): 灵敏度指的是在实际为正的样本中占有所有被预测为正的比例, 精度是用来衡量“将多数类判错后所付出代价”。其计算公式为:

$$precision = \frac{TP}{TP + FP} \quad (2.6)$$

(3) 召回率 (recall): 召回率指的是预测为正的样本占有所有实际为正的样本, 衡量的是对少数类样本的识别能力, 其计算公式为:

$$recall = \frac{TP}{TP + FN} \quad (2.7)$$

(4) F1 分数 (F1 score): F1 同时兼顾了精度和召回率两者, 通常用来衡量二分类模型的预测精确程度, 它的计算方式是精度和召回率的调和平均值, 其计算公式为:

$$F1 = 2 * \frac{precision * recall}{precision + recall} \quad (2.8)$$

2. ROC 曲线和 AUC 值

在通常情况下, 二分类界限以 0.5 进行判别, 但是在某些条件下, 分类器的阈值是可以浮动的。ROC 曲线将真正率 (True positive ratio, TPR) 作为纵轴和假正率 (False positive ratio, FPR) 作为横轴所构成的坐标以二维平面的形式展现出来。其中:

真正率 (TPR): 指的是分类正确的正样本占整个正样本个数的比例

$$TPR = \frac{TP}{TP + FN} \quad (2.9)$$

假正率 (FPR): 指的是分类错误的负样本占整个负样本个数的比例

$$FPR = \frac{FP}{FP + TN} \quad (2.10)$$

ROC 曲线越靠近左上角说明模型预测效果越好, 而 AUC 值就是 ROC 曲线下的面积。AUC 值一般在 0 到 1 之间, 并且越接近 1, 说明模型的预测效果越好。在二分类模型中 AUC 值等于 0.5, 则表示跟随机猜测的效果一样。AUC 值具有一个显著的优点是不受不平衡样本的影响, 其适用能力更为广泛, 常作为模型训练和评价的指标。

2.4 本章小结

本章系统性地阐述了相关理论和方法。包括疾病预测相关理论和方法、疾病预测模型理论和方法、模型评价理论和方法共三个部分。具体有: 第一部分简明阐述了临床疾病预测领域的基本概念、研究思路 and 流程; 第二部分阐述了疾病预测领域里的五

种经典算法，分别是逻辑回归、随机森林、支持向量机、GBDT、XGBoost，并简单论述了不同算法之间的优缺点。最后重点介绍了 **super learner** 超级学习器算法的理论和方法；第三部分阐述了基于混淆矩阵的准确率、精度、召回率、F1 以及 ROC 曲线和 AUC 值的基本概念。

第3章 颈动脉粥样硬化样本选取及其代谢指标体系构建

上一章系统性地阐述了疾病预测概念,疾病预测模型和模型评价相关理论和方法。本章将采用这些算法找出有关颈动脉粥样硬化发生的影响因子。一方面发掘出影响颈动脉粥样硬化发生的指标,从而建立起颈动脉粥样硬化影响因素指标体系,提高颈动脉粥样硬化发病风险评估的准确程度。另一方面去除部分冗杂的变量,降低模型的复杂化程度,减弱后续发病风险预测模型中可能存在的过拟合问题,同时还可以减少运行时间,提高效率。

3.1 颈动脉粥样硬化样本的选取

3.1.1 实验设计说明

通过查询相关文献,发现现有对颈动脉粥样硬化发病风险的研究主要是基于横断面研究的疾病诊断模型,即根据研究对象的症状和特征,用于识别出每个研究对象是否在此时刻为颈动脉粥样硬化患者。旨在为临床医生提供一种颈动脉粥样硬化辅助诊断方法,从而降低临床医生误诊的概率。

本研究目的是针对健康体检人群的代谢相关类指标建立起高效的颈动脉粥样硬化高危人群识别模型,并提出相应措施进行干预,降低其颈动脉粥样硬化的发病概率。本文的核心是在预防而不是诊断,同时发掘出目前还未被纳入颈动脉粥样硬化的影响因素。基于此,本文的实验设计不同与现有的研究,具体如下:

- 1.通过山东省某三甲医院的医疗数据库采集到人群的体检数据。其中所有被纳入的研究样本其基线体检数据是尚未被诊断为颈动脉粥样硬化患者(采用**b**型超声检查,如果颈动脉内膜-中膜厚度 $\geq 1.0\text{ mm}$ 或斑块形成则诊断为颈动脉粥样硬化患者)。颈动脉粥样硬化隶属于心脑血管大类疾病,与部分疾病之间存在一定的关联性。为了降低样本在基线时刻其体检特征表达水平除受颈动脉粥样硬化外其他疾病的影响,所有被纳入的样本都排除了以下疾病:冠心病、既往冠心病、**ce_c**脑缺血、脑梗塞、大脑血管狭窄、脑血管痉挛、冠状动脉狭窄、冠状动脉粥样硬化性心脏病。

- 2.在随访截止日期之前确定每个样本是否确诊为颈动脉粥样硬化患者。其中确诊为颈动脉粥样硬化患者标记为1,未确诊为颈动脉粥样硬化人群标记为0。

3.1.2 实验数据的收集和说明

本研究所采用的数据来自山东省某三甲医院的医疗数据库,囊括了体检人群多种代谢类相关指标,主要包括各种化验指标(例如血小板计数,红细胞计数等)、以及基本人口学资料内容(年龄、性别,身高、体重),共计 1192 个指标。

山东省某三甲医院的体检部门服务于整个医院就诊人群,由于体检对象的检查项目数量相差较大,常规体检项目仅有不到 100 个,其余大多数指标存在较多的缺失值。因此本文剔除掉缺失样本个案比例超过 50%的体检项目,同时删除体检项目不足 20 的样本个案。

根据上文的实验设计本研究最终共搜集到 1669 个样本和 59 个指标,其中男性 1426 名,女性 243 名,最终 1669 个人中有 441 个人发病。男性中发病人数为 395,男性累积发病率约为 27.70%,女性发病人数为 46,女性累积发病率约为 18.93%。年龄这一重要指标的计算方法是体检年减去出生日期;对于大于 18 岁的人群,取这个人的两次体检的身高的平均值作为其基线的身高;其余代谢相关类指标都是在实验室仪器下按照《全国医用临床检验实验室和体外诊断系统标准化技术》和《健康体检中心管理规范(试行)——国卫医发》相关标准进行测量和记录。

3.1.3 数据预处理

1.缺失值的处理

在现实研究中,通常数据集中会存在一定数量的缺失值,而缺失值具有以下影响:(a)失有用信息,可能导致错过重要特征。(b)数据的不确定性增加,如果随意的填补可能会加大样本偏差,导致模型的结果不可靠。因此如何填补缺失值需要根据造成缺失值的原因和缺失个数比例而定。鉴于本文所选取的数据来自山东省某三甲医院医疗数据库,出现缺失值的很大部分原因来自于人群的体检项目不统一,出现缺失值的特征都属于数值型指标,并且缺失值个数占比不到 1%,因此本文采用均值填补缺失值。

2.异常值的处理

异常值指的是部分个案严重偏离其他观测值。异常值同样对模型的结果有较大影响。本文采用箱线图法对异常值进行判断,并且采用就近替代法对异常值进行填补。

3.数据标准化处理

数据标准化处理是数据预处理中的重要环节,旨在消除指标之间量纲的影响。常

见的标准化方法有两种，一、Z-score 标准化，利用样本均值和方差将所有观测值构造具有均值为 0，方差为 1 的分布特征。二、min-max 标准化，目的是将所有观测值缩小到 0 和 1 之间。Z-score 标准化适用于样本分布较离散的情况，因此本文数据采用 Z-score 标准化方式进行处理。

3.2 颈动脉粥样硬化相关代谢指标体系的构建

通常情况下，在建立预测模型之前需要进行特征选择。特征选择指的是从原始特征中尽可能找出最有用的特征。一方面可以减少指标数量，以降低模型复杂度，防止过拟合情况的发生，避免出现“维数灾难”；另一方面能够选取最优特征子集，以提高模型性能。

3.2.1 基于文献研究的指标选取

在现有颈动脉粥样硬化相关的研究中，多集中于影响因素层面，且在指标选取上的覆盖程度较低，尤其较少涉及到代谢相关类指标。表 3-1 展示了目前对颈动脉粥样硬化影响因素的部分研究成果。但研究显示，人体新陈代谢系统紊乱与颈动脉粥样硬化发生存在一定的关联，同时考虑到本研究所收集到数据的可获得性，因此在现有研究成果中添加了代谢相关指标。与现有研究的主要区别在于，本研究所选取的指标多集中于代谢相关类，可以用图 3-1 所表示。

表 3-1 颈动脉粥样硬化影响因素主要研究成果

类别	影响因素
化验指标	血糖、血脂、血压、血浆同型半胱氨酸、低密度脂蛋白胆固醇、高密度脂蛋白胆固醇、肿瘤坏死因子- α (TNF- α)、白细胞介素 6 (IL-6)、白细胞介素 17 (IL-17)、血清胱抑素 C、视黄醇结合蛋白、甲状腺功能指标、血清半乳糖凝集素-3、血清白脂素
临床病史	糖尿病、高血脂、腹部肥胖、高血压
人口学	性别、体重、年龄、身高
生活方式	运动、酗酒、吸烟

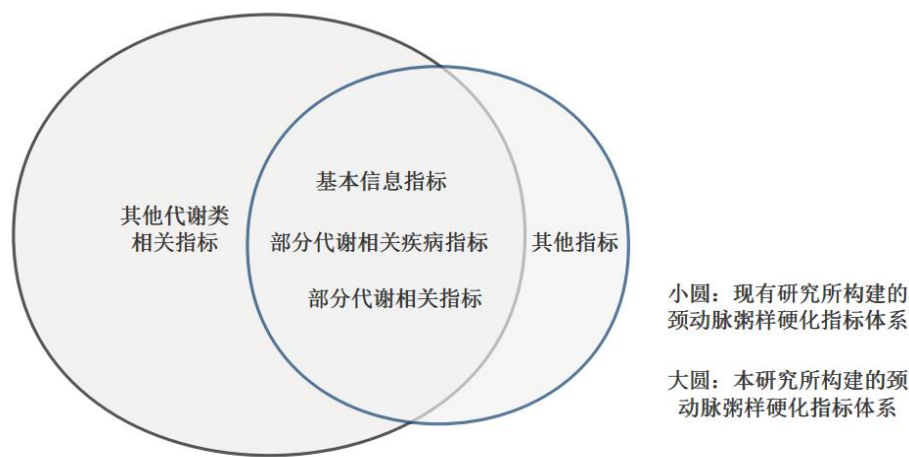


图 3-1 颈动脉粥样硬化指标体系的构建

（1）基本信息指标：基本信息指标反映了体检人群的基本信息。现有的研究一般将年龄、身高、体重、性别纳入为颈动脉粥样硬化的影响因素，其中大部分研究结论显示年龄这一指标对颈动脉粥样硬化的影响最大。因此本文不仅将这些指标纳入研究中，还用身体质量指数（BMI）来衡量样本的胖瘦情况，相比于仅仅使用身高和体重，身体质量指数所包含的信息更多更科学。具体的指标如表 3-2 所示。

表 3-2 基本信息指标

指标	代号
年龄	age
性别	sex
身高	height
体重	weight
身体质量指数	BMI

（2）相关疾病指标：相关疾病指标反映了体检人群的身体健康状况。由于颈动脉粥样硬化这一疾病并不是独立存在的，往往伴随着其他并发症出现，部分疾病的出现可能预示着颈动脉粥样硬化的发生。因此本研究添加了体检人群所患有的相关疾病作为预测指标，从而提高对颈动脉粥样硬化发生风险的计算能力。具体指标如表 3-3 所示。

表 3-3 相关疾病指标

代谢类疾病		非代谢类疾病	
中文名称	代号	中文名称	代号
高血糖	hyperglycemia	脂肪肝	fatty liver
糖尿病	DM	胆囊结石	cholelithiasis
甲状腺结节	nodular	肝囊肿	hepatic
高血压	hypertension	慢性胆囊炎	chronic cholecystitis
骨质疏松	osteoporosis	肝钙化灶	calcification
颈动脉狭窄	CS	肺结节病	sarcoidosis
后天性肾囊肿	kidneycyst	胃炎	gastritis

(3) 相关化验指标：相关化验指标反映了体检人群的各项代谢水平。由于代谢类指标相对比较广泛，因此普遍能够反映其身体健康状况。具体的指标如表 3-4 所示。

表 3-4 代谢相关化验指标

代谢相关指标			
中文名称	代号	中文名称	代号
红细胞分布宽度	rdw-cv	空腹血糖	glu
淋巴细胞计数	ymphocyte	嗜酸性粒细胞绝对值	eosimophil
血尿素氮	bun	血红蛋白	hgb
淋巴细胞百分比	p.ymphocyte	血小板计数	plt
单核细胞绝对值	monocytes	血小板压积	pct
总胆固醇	tc	尿亚硝酸盐	nit
谷丙转氨酶	alt	中性粒细胞绝对值	p.granulocyte
谷草转氨酶	ast	中性粒细胞百分数	p.granulocyte
红细胞分布宽度	rdw-sd	总蛋白	tp
红细胞计数	rbc	甘油三酯	tg
红细胞压积血常规%	hct	尿糖	glycosuria
尿比重	sg	嗜酸性粒细胞百分数	p.eosimophil
血尿酸	bua	低密度脂蛋白胆固醇	ldl-c
尿酸碱度 PH	ph	高密度脂蛋白胆固醇	hdlc-c
平均血红蛋白含量	mch	谷草/谷丙	ast/alt
平均血红蛋白浓度	mchc	癌胚抗原	cea
平均红细胞体积	mcv	平均血小板体积	mpv
白蛋白/球蛋白	alb/glb	白蛋白	alb
γ 谷氨酰转肽酶	γ -gt	碱性磷酸酶	alp
血白细胞计数	wbc	尿素氮/肌酐	urea/crea

3.2.2 基于机器学习算法的指标选取

机器学习中常见的特征选择方法有三个。分别是：过滤式、封装式、嵌入式。由于本文的主要研究内容是通过找出有关颈动脉粥样硬化的影响因子，选择最优子集以此提高模型的预测性能，从而建立起更高效准确的颈动脉粥样硬化发生风险预测模型。因此适合采用过滤式和嵌入式方法。图 3-2 为本文特征选择的具体流程。




图 3-2 特征选择流程

1. 过滤式特征选择

由于原始数据集中的特征较多，样本个案相对较少，并且样本中还存在较多的冗余特征。因此首先采用过滤式特征选择方法对数据集进行初步的降维，而在生物医学领域内常用单因素 Logistic 回归排除掉部分特征，以保留大部分有用特征信息。

将 59 个指标纳入 Logistic 回归模型，以体检人群结局是否发生颈动脉粥样硬化作为响应变量，其余体检指标分别作为解释变量，做单因素 Logistic 回归。为尽可能发掘出潜在与颈动脉粥样硬化相关的影响因素，因此本文给定一个较大的阈值 $P=0.1$ ，即选取 P 值 <0.1 的指标，指标结果如表 3-5 所示。共计 28 个指标入选，其中包括 2 个基本信息指标（年龄、性别）、20 个代谢相关化验指标、6 个相关疾病指标（高血压、糖尿病等）。

表 3-5 变量单因素 Logistic 回归结果

代号	Pr(> z)	OR	代号	Pr(> z)	OR
age	<0.001	1.966	plt	0.044	0.892
sex	0.004	0.609	granulocyte	0.002	1.178
bun	0.02	1.134	p-granulocyte	0.013	1.149
ymphocyte	0.001	0.833	p-eosimophil	0.034	1.118
alt	0.001	0.777	wbc	0.015	1.142
ast	0.002	0.799	ast/alt	0.083	1.105
rdw-sd	<0.001	1.209	cea	0.06	1.109
rbc	0.012	0.870	urea/crea	0.063	1.107
mch	<0.001	1.259	nodular	0.03	1.275
mchc	0.03	1.131	hepatic	0.08	1.271
mcv	0.002	1.196	CS	<0.001	3.454
mpv	0.014	1.146	DM	<0.001	2.220
glu	<0.001	1.307	hypertension	<0.001	1.960
eosimophil	0.024	1.127	cholelithiasis	0.001	2.147

2. 嵌入式特征选择

随着技术的进步以及各领域的交叉发展,关于疾病影响因素的研究方法层出不穷,机器学习中的集合学习方法因为其巨大的优势被广泛运用,其中基于 cart 树的随机森林、XGBoost、GBDT 是最常用的特征选择方法。于是本文利用这三种不同的嵌入式机器学习方法进行特征重要性排序,并将不同算法得到的重要特征进行统计,综合选取最优的特征。XGBoost 和 GBDT 算法都是通过 5 折交叉验证和随机搜索 1000 次以 AUC 值作为模型优良的评价标准的方式进行。最终将三种不同机器学习算法所得到的重要特征取其交集,统计每个重要特征的出现情况,共计 22 个特征入选。具体过程和结果如下所示。

(1) 基于随机森林的特征选择:随机森林的超参数调节如表 3-6 所示。

表 3-6 随机森林的超参数调节

超参数	超参数含义	超参数取值范围	最优超参数取值
mtry	随机特征选择数	1~28	2

结果显示当 mtry=2 时, AUC 值最大为 0.731, 用基尼 (Gini) 作为节点不纯度的衡量方式。特征重要性排序如图 3-3 所示。可以看出, 年龄 (age) 是作为颈动脉粥样硬化的第一重要影响因子, 且远远高于其他特征。




图 3-3 随机森林重要特征排序

(2) 基于 XGBoost 的特征选择：XGBoost 的超参数调节如表 3-7 所示。

表 3-7 XGBoost 的超参数调优结果

超参数	超参数含义	超参数取值范围	最优超参数取值
eta	学习率	0.01~1	0.012
max_depth	决策树的最大深度	1~5	1
min_child_weight	划分节点最小杂质程度	1~8	3
subsample	决策树随机抽样的样本比例	0.5~1	0.625
colsample_bytree	决策树采样预测变量的比例	0.5~1	0.691
nrounds	决策树数量	500	500
objective	损失函数	binary:logistic	binary:logistic

结果显示当：eta=0.012；max_depth=1；min_child_weight=3；subsample=0.625；colsample_bytree=0.691；nrounds=500 时，AUC 值最大为 0.744。特征重要性排序如图 3-4 所示。XGBoost 方法一共输出 28 个特征，由于最后几个特征的重要性明显低于前面的特征，因此取前 22 个特征。同样地，年龄（age）依旧是作为颈动脉粥样硬化的第一影响因子，且远高于其他特征。




图 3-4 XGBoost 重要特征排序

(3) 基于 GBDT 的特征选择：GBDT 的超参数调节如表 3-8 所示。

表 3-8 GBDT 的超参数调优结果

超参数	超参数含义	超参数取值范围	最优超参数取值
shrinkage	学习率	0.01~1	0.011
interaction.depth	交互深度	1~5	2
n.minobsinnode	终结点最小规模观测值	5~10	9
bag.fraction	子抽样比例	0.5~1	0.868
n.trees	决策树数量	500	500
distribution	损失函数	bernoulli	bernoulli

结果显示当：shrinkage=0.011；interaction.depth=2；n.minobsinnode=9；bag.fraction=0.868；n.tree=500 时，AUC 值最大为 0.803。特征重要性排序如图 3-5 所示。GBDT 方法一共输出 25 个特征。同样地，年龄（age）依旧是作为颈动脉粥样硬化的第一影响因子，且远高于其他特征。




图 3-5 GBDT 重要特征排序

3.相关性检验

通常情况下,如果变量之间有较强的相关性,表明信息存在冗杂,会造成模型的多重共线性。因此需要对机器学习算法所选择的特征之间进行相关性检验。连续型特征计算 Pearson 相关系数表示其相关程度,离散型特征之间用卡方检验表示其相关程度,结果如图 3-6 所示。按照特征重要性程度的先后顺序剔除掉相关性较高且重要性排序靠后的特征,最终删除掉谷丙转氨酶(alt)、中性粒细胞绝对值(granulocyte)、平均血红蛋白含量(mch)、平均红细胞体积(mcv)、嗜酸性粒细胞绝对值(eosimophil)共 5 个特征。




图 3-6 连续型特征的相关系数图

3.2.3 颈动脉粥样硬化相关代谢指标体系的确定

本研究通过文献研究、过滤式和嵌入式方法对代谢相关指标进行选取,确定了颈动脉粥样硬化的影响因素指标体系。体系中共选取了 17 个指标,具体如表 3-9 所示。这 17 个指标中既包含了体检人群的基本信息指标(年龄、性别),又包括了相关化验指标(红细胞计数、血小板计数等)和代谢相关疾病指标(糖尿病、高血压、颈动脉

狭窄), 并且指标多集中在代谢相关类指标上, 其中部分指标并未在现有的研究中出现, 说明本研究在发掘颈动脉粥样硬化影响因素方面具备一定的前沿性。

表 3-9 颈动脉粥样硬化影响因素指标体系

指标类型	指标名	代号
基本信息指标	年龄	age
	性别	sex
相关化验指标	血尿素氮	bun
	淋巴细胞百分比	lymphocyte
	谷草转氨酶	ast
	红细胞分布宽度	rdw-sd
	红细胞计数	rbc
	平均血红蛋白浓度	mchc
	平均血小板体积	mpv
	空腹血糖	glu
	血小板计数	plt
	嗜酸性粒细胞百分数	p-eosimophil
	血白细胞计数	wbc
	癌胚抗原	cea
相关疾病指标	颈动脉狭窄	CS
	糖尿病	DM
	高血压	hypertension

对于基本信息指标而言, 年龄通常作为众多疾病的重要影响因素, 也包括颈动脉粥样硬化。颈动脉粥样硬化的发生最早出现在青少年时期, 并随着年龄的增加, 身体机能下降, 在中老年时期出现频繁, 所以年龄这一指标是作为颈动脉粥样硬化的一个重要影响因素; 其次, 男女在新陈代谢水平或者身体激素水平上存在一定的差异, 因此通常会导致男女在颈动脉粥样硬化发生上有不同的表现, 所以将性别纳入颈动脉粥样硬化影响因素指标体系具有一定的合理性。

对相关化验指标而言, 现有的研究显示, 人体各项新陈代谢功能下降与颈动脉粥样硬化发生息息相关。本研究重点是发掘与颈动脉粥样硬化发生相关的代谢指标, 建立起基于代谢相关指标的颈动脉粥样硬化指标体系。最终目的是通过所建立的指标体系增强对颈动脉粥样硬化发生风险的预测效果, 从而提高对高危人群的识别能力, 因此将其纳入颈动脉粥样硬化影响因素指标体系中。

对相关疾病而言, 现有研究已经证实了颈动脉狭窄与颈动脉粥样硬化的密切联系。

颈动脉粥样硬化的发生往往是颈动脉狭窄进一步恶化的结果,因此常常将颈动脉狭窄视为颈动脉粥样硬化发生重要信号;同时高血压和糖尿病患者也是颈动脉粥样硬化的高发人群,因此将这三个指标纳入颈动脉粥样硬化影响因素指标体系中。

3.3 本章小节

本章阐述了本研究的实验设计说明、实验数据的收集和说明、数据预处理过程。通过查找相关研究文献,确定了与颈动脉粥样硬化发生紧密相关的危险因素。结合本文所搜集到的数据,将研究重心多集中在代谢相关指标上,共选取 59 个指标。介绍了过滤式和嵌入式方法进行特征选择的具体流程。首先在单因素 Logistic 回归中一共选择了 28 个 P 值 <0.1 的指标;其次分别采用三种机器学习算法(随机森林、XGBoost、GBDT)进一步进行特征选择,取其交集选取了 22 个最优指标;并计算了指标之间的相关系数,结合特征的重要性程度,删除重要程度靠后的特征。最终确定了 17 个颈动脉粥样硬化发生相关的影响因素,由此建立了颈动脉粥样硬化影响因素指标体系。

第4章 颈动脉粥样硬化发生风险预测模型构建

上一章通过综合不同的特征选择方法对数据进行了降维，建立了颈动脉粥样硬化影响因素指标体系。本章将利用所建指标体系，构建对颈动脉粥样硬化发生风险的预测模型，用于识别高危人群。最后利用 SHAP 可解释性框架对颈动脉粥样硬化发生风险概率进行解释，以解决传统机器学习所存在的“黑盒子”问题，针对样本个案提出个性化干预方案，以降低其颈动脉粥样硬化的发生风险。

4.1 颈动脉粥样硬化发病风险预测模型建立

4.1.1 数据不平衡处理

图 4-1 展示了样本中的颈动脉粥样硬化发生情况，其中队列中最终颈动脉粥样硬化发病人数为 441 人，不发病人数为 1228 人，两者比例约为 2.78:1。对于二分类预测模型，如果样本正负比例差距较大，会在训练过程中会偏向于多数类样本，容易造成模型对少数类样本的预测能力减弱。则需要通过重采样的方式对少数类样本（随访结束时间里诊断为患颈动脉粥样硬化患者）进行过采样，对多数类样本（随访结束时间里未被诊断为颈动脉粥样硬化患者）欠采样，使两者达到 1:1 平衡。本文所采用的重采样方法是“人工少数类过采样法”（Synthetic Minority Over-Sampling Technique, SMOTE），利用的是 DMwR 包中的 SMOTE 函数。



图 4-1 原始数据集中样本类别比例

4.1.2 样本划分说明

考虑到重采样在一定程度上会破坏数据的分布，会导致模型在外部数据集中的预测效果不佳。因此在进行重采样之前，需要留出部分原始数据集作为验证集用于进一

步评估模型拟合效果。如果在验证集中模型表现良好，则说明本文所建立的预测模型的泛化能力和实用性更强。

将原始数据中 1669 个样本个案按照图 4-2 进行划分，即事先随机抽取 5% 留作验证集，其中颈动脉粥样硬化发病人数有 22 人，未发病人数有 61 人，正负样本比例约为 2.77:1，与原始数据集中的正负样本比例大致相同。剩余 95% 作为内部训练和测试集，其中颈动脉粥样硬化发病人数有 419 人，未发病人数有 1167 人，正负样本比例约为 2.79:1。再利用 SMOTE 方法进行重采样，然后将重采样后的数据集随机划分 70% 作为训练集，30% 作为测试集，其中训练集中正负样本比例约为 1.03:1，测试集中正负样本比例约为 1.08:1。




图 4-2 建模过程中的数据集划分

4.1.3 单一模型的训练和评价

基于本文所构建的颈动脉粥样硬化相关代谢指标体系，分别构建了逻辑回归和支持向量机两种单模型，以及随机森林、XGBoost、GBDT 三种集成模型。为均衡不同超参数组合下模型的泛化效果，采用五折交叉验证的方式，并利用网格搜索和随机搜索法。网格搜索指的是遍历所有超参数组合，从而选择使模型效果最佳的超参数组合；而随机搜索指的是给定超参数取值范围，通过随机搜索在超参数范围内的超参数组合来使模型的效果最优，当搜索次数足够多时，可以达到网格调参的效果。因此相比于网格调参，随机搜索调参方式更加节约计算时间和计算机资源。具体调参过程和结果如下。

1. 单一模型的训练

(1) 随机森林的调参过程和结果

随机森林模型的超参数调节方式采用网格调参，在超参数调节中以 AUC 值作为模型评价指标，采用 5 折交叉验证的方式进行，调优结果如表 4-1 所示。

表 4-1 随机森林的超参数调优结果

超参数	超参数含义	超参数取值范围	最优超参数取值
mtry	随机特征选择数	1-17	2

(2) 支持向量机的调参过程和结果

支持向量机模型的超参数调节方式采用随机搜索参数组合,在超参数调节中以 AUC 值作为模型评价指标,采用 5 折交叉验证的方式进行,随机搜索超参数 1000 次,调优结果如表 4-2 所示。

表 4-2 支持向量机的超参数调优结果

超参数	超参数含义	超参数取值范围	最优超参数取值
kernel	核函数	radial、polynomial、 liner、sigmoid	radial
C	惩罚系数	0.01-100	67.8
gamma	支持向量辐射范围的倒数	0.01-100	0.442

(3) GBDT 的调参过程和结果

GBDT 模型的超参数调节方式采用随机搜索参数组合,在超参数调节中以 AUC 值作为模型评价指标,采用 5 折交叉验证的方式进行,随机搜索超参数 1000 次,调优结果如表 4-3 所示。

表 4-3 GBDT 的超参数调优结果

超参数	超参数含义	超参数取值范围	最优超参数取值
shrinkage	学习率	0.01-0.5	0.276
interaction.depth	交互深度	1-5	5
n.minobsinnode	终结点最小规模观测值	1-10	9
bag.fraction	子抽样比例	0.5-1	0.87
n.trees	决策树数量	300	300
distribution	损失函数	bernoulli	bernoulli

(4) XGBoost 的调参过程和结果

XGBoost 模型的超参数调节方式采用随机搜索参数组合,在超参数调节中以 AUC 值作为模型评价指标,采用 5 折交叉验证的方式进行,随机搜索超参数 1000 次,调优结果如表 4-4 所示。

表 4-4 XGBoost 的超参数调优结果

超参数	超参数含义	超参数取值范围	最优超参数取值
eta	学习率	0.01-0.5	0.131
max_depth	决策树的最大深度	1-5	5
min_child_weight	划分节点最小杂质程度	1-8	2.22
subsample	决策树随机抽样的样本比例	0.5-1	0.763
colsample_bytree	决策树采样预测变量的比例	0.5-1	0.637
nrounds	决策树数量	300	300

2.单一模型的评价

本研究采用多种评价指标表示模型的预测效果，具体包括准确率、精度、召回率、AUC 值、F1 得分共五个指标，具体结果如表 4-5 所示。其中五种模型的 ROC 曲线及其曲线下面积 AUC 值如图 4-3 所示。




图 4-3 五种模型的 ROC 曲线

表 4-5 五种机器学习模型的预测效果

模型	准确率	精度	召回率	AUC	F1
LR	0.734(0.783)	0.732(0.563)	0.701(0.818)	0.797(0.857)	0.716(0.667)
RF	0.805(0.759)	0.783(0.528)	0.822(0.864)	0.891(0.848)	0.802(0.655)
SVM	0.825(0.602)	0.793(0.359)	0.859(0.636)	0.909(0.639)	0.825(0.459)
XGBoost	0.777(0.723)	0.761(0.487)	0.780(0.864)	0.872(0.817)	0.770(0.623)
GBDT	0.789(0.759)	0.771(0.529)	0.797(0.818)	0.866(0.828)	0.784(0.642)

附注 1：（括号里为验证集的预测效果）

从表 4-5 可以得知, 五种单一模型(逻辑回归、随机森林、支持向量机、XGBoost、GBDT)都存在不同程度的过拟合或者欠拟合问题。说明在重采样之前事先留出部分验证集的必要性, 如果没有验证集, 则会高估模型的预测效果。不同算法模型的预测效果优缺点也不同。其中, 逻辑回归在验证集中的 F1 得分和 AUC 值最高, 随机森林和 XGBoost 在验证集中的召回率最高, 支持向量机在测试集中的准确率、精度、召回率、AUC 值最高, 随机森林和 XGBoost 在验证集中的召回率最高。

因此综合来看, 随机森林模型的总体预测效果优于其他四种模型, 其次是 XGBoost、GBDT、逻辑回归模型, 最差的为支持向量机模型。

4.1.4 基于 stacking 思想集成模型的训练和评价

本文将上述五种模型作为基模型纳入 super learner 算法进行训练, 结果如表 4-6 所示。Super learner 算法会根据最小损失风险函数为每个基模型分配权重, 每个模型的权重系数越大, 说明其在 super learner 模型中所占的比重就越大。可以看出来, 逻辑回归和支持向量机的权重系数为 0, 说明在 super learner 模型中, 未使用逻辑回归和支持向量机算法。而随机森林的系数高达 0.820, 且远远高于其他四个模型, 说明 super learner 主要是基于随机森林模型改进的, 这也说明了随机森林模型在各单一模型之中是最优的。Super learner 模型的具体的测试集和验证集中的预测效果如表 4-7 所示。Super learner 模型在测试集和验证集的 ROC 曲线如图 4-4 所示。

表 4-6 Super learner 模型加权结果

模型	权重系数
RF	0.820
LR	0.000
SVM	0.000
GBDT	0.089
XGBoost	0.091




图 4-4 Super learner 模型的 ROC 曲线

表 4-7 Super learner 的预测效果

数据集	准确率	精度	召回率	AUC	F1
测试集	0.795	0.785	0.788	0.893	0.786
验证集	0.795	0.571	0.909	0.861	0.701

通过比较表 4-7 中 super learner 模型与表 4-5 中五种单一模型的结果发现，虽然在模型部分评价指标上并不是最优的，但是其测试集和验证集的预测效果（尤其准确率、AUC、F1 值）大致一致。可以说明 super learner 模型在一定程度上解决了单一模型所存在的过拟合或者欠拟合问题，其模型泛化能力更高。并且从验证集中的召回率来看，super learner 模型的召回率高达 0.909，远远高于其他五个模型。综合来看，super learner 模型的预测效果要优于随机森林模型，更优于其他四种模型。因此本文所构建的 super learner 模型具备颈动脉粥样硬化发病风险的预测能力。

4.2 基于 SHAP 框架的模型解释

在当前的机器学习应用领域里，绝大多数的研究方向和内容主要是提高预测模型的准确率，往往忽略了对模型预测结果的解释，比如深度学习模型就是典型的以牺牲解释性为代价来提高预测准确率。由于机器学习模型本身的复杂性，其预测过程的不透明，会导致输出结果难以解释，这种情况又被称为“黑盒”问题。但是对于终端用户（例如潜在的疾病患者）而言，患者希望理解自身各指标表达水平对于某疾病的影响大小和作用方向。因此，机器学习模型的可解释性与高准确性同样重要。如何就模

型尤其是复杂集成学习模型的输出结果给予正确合理的解释成为了近年来机器学习领域一个重要的课题。

Lundberg et al. (2017) 提出了 SHAP (Shapley Additive exPlanations) 框架, 它是基于博弈论思想的一种局部解释方法, 可用于解释复杂机器学习模型^[50]。通过计算每个特征对于全局特征的边际贡献, 得到的平均值称为 shapley 值。它可以用来衡量每个特征对于预测结果的影响方向和大小, shapley 绝对值越大, 说明其对输出结果的影响越大, 正负代表对输出结果的影响方向。该方法更接近人类的直觉且可以更好的识别模型的输出。

图 4-5 是样本中所有特征对模型输出的贡献程度, 可以看出来, 颈动脉狭窄(CS)、年龄(age)是最重要的两个特征。这两个特征对颈动脉粥样硬化发生的贡献程度超过四分之一, 符合生活中的实际情况。随着年龄的增加, 颈动脉粥样硬化的发病风险在增加, 而颈动脉粥样硬化是颈动脉狭窄进一步恶化的结果。




图 4-5 特征重要性排序

此外, shapley 值还可以对研究对象进行个性化评估, 即对个体的各个特征对结局的贡献进行解释。图 4-6 展示了其中两个样本个案 A (未发病) 和 B (发病) 两人各个特征的 shapley 值。左边蓝色部分 (shapley 值小于 0) 代表该变量会降低该个体被预测为颈动脉粥样硬化 (CAS) 的概率, 即为保护因素; 右边橙色部分 (shapley 值大于 0) 代表会增加该个体被预测为颈动脉粥样硬化 (CAS) 的概率, 即为危险因素, 并且面积越大说明其影响越大。




图 4-6 A 个体（左）B 个体（右）中各个特征对结局的贡献程度

对于 A 个体而言，其患有糖尿病（DM=1）和 空腹血糖（glu=10.05）较高是增加其颈动脉粥样硬化（CAS）发病风险的主要原因，但是由于其未患颈动脉狭窄（CS=0），并且年龄（age=49）较小，并未处于颈动脉粥样硬化高发风险期，这两个主要影响因素使得在总体上 A 个体颈动脉粥样硬化发生风险较低。

对于 B 个体而言，颈动脉狭窄（CS=1）是增加其颈动脉粥样硬化（CAS）发病风险的主要原因，但是由于其年龄（age=48）较小且未患糖尿病（DM=1），降低了其颈动脉粥样硬化（CAS）发生的概率，但是相对于年龄这个特征，颈动脉狭窄更为重要，即影响更大。因此总体上 B 个体颈动脉粥样硬化的发病风险较大。

通过 SHAP 框架和 shapley 值可以直观地找出增加个体颈动脉粥样硬化发病风险的主要原因，然后可以采取相应措施进行干预，降低其发病风险。例如 B 个体年龄较小，本身发生颈动脉粥样硬化的概率不高，但是因为其具有颈动脉狭窄这个危险因素使得其将来发生颈动脉粥样硬化的可能性增加，提示应该对该个体进行干预，可以通过增加体育锻炼或服用相关药物等途径降低其未来的发病风险。

4.3 本章小结

本章主要从队列人群发病风险预测、模型解释两个角度出发研究了颈动脉粥样硬化发病风险的预测模型，同时本章也是全文中最重要的章节。在颈动脉粥样硬化发病风险预测这一部分，首先针对数据不平衡问题采用了 SMOTE 重采样方法，同时为保证所构建模型能够还原原始数据，在重采样之前保留了部分数据集，由此模型在该数据集上的预测效果更具备说服力。本章还建立了五种不同的单一机器学习模型（逻辑回归、随机森林、支持向量机、XGBoost、GBDT），并对预测效果进行比较，进一步采用 super learner 集成学习算法将五种模型进行加权融合，结果显示 super learner 模型无论在测试集上还是验证集上的预测效果均较优，且不存在过拟合或者欠拟合问题。最后为解决机器学习模型的“黑盒”问题，利用 SHAP 框架对模型的各个特征进行解释，包括在全样本角度下的特征重要性排序，以及针对个体特征方向和特征大小的解释，实现了对每个样本个案的个性化评估，以此可以针对性提出干预方案，从而降低颈动脉粥样硬化高危人群的发病风险。

第5章 研究结论与展望

本文基于山东省某三甲医院体检人群的代谢相关类指标数据,构建了颈动脉粥样硬化相关代谢指标体系,然后采用集成学习算法建立颈动脉粥样硬化发病风险的预测模型。不仅丰富了机器学习在疾病预测领域的运用,还进一步为颈动脉粥样硬化的发病风险计算提供了一种新的方法和思路。对维护居民身体健康,防范颈动脉粥样硬化的发生具有重要的意义。最后,本文的主要研究结论和展望如下:

5.1 研究结论

1.发现了与颈动脉粥样硬化发生相关的代谢指标

本文通过特征选择方法,构建了颈动脉粥样硬化相关代谢指标体系。确定了年龄(age)、血尿素氮(bun)、淋巴细胞百分比(lymphocyte)、谷草转氨酶(ast)、红细胞分布宽度(rdw-sd)、红细胞计数(rbc)、平均血红蛋白浓度(mchc)、平均血小板体积(mpv)、空腹血糖(glu)、血小板计数(plt)、嗜酸性粒细胞百分数(P-eosimophil)、血白细胞计数(wbc)、癌胚抗原(cea)、颈动脉狭窄(CS)、高血压(hypertension)、性别(sex)、糖尿病(DM)共17个代谢相关类指标在随访结局为颈动脉粥样硬化人群和非颈动脉粥样硬化人群之间有显著性差异,可以作为颈动脉粥样硬化的影响因子。

2.增强了对颈动脉粥样硬化发病风险的预测能力

本文研究发现逻辑回归、随机森林、支持向量机、XGBoost、GBDT五种机器学习模型在对颈动脉粥样硬化的发病风险预测上优缺点不同,但都存在过拟合或者欠拟合问题。其中,随机森林模型的总体预测效果要优于其他四种算法模型,而支持向量机模型的预测效果最差,过拟合情况最为严重。为改善单一模型的过拟合问题,本文采用了一种基于stacking思想的super learner集成算法将五种模型(逻辑回归、随机森林、支持向量机、XGBoost、GBDT)进行加权融合。结果显示,super learner堆叠模型相比于单一模型而言,显著降低了这些模型所存在的过拟合问题。并且在测试集和验证集上AUC值和召回率都较高,表明在颈动脉粥样硬化高危人群的识别上具有较高的准确率,因此可以作为计算颈动脉粥样硬化发病风险的预测模型。

3.实现了对颈动脉粥样硬化相关特征重要性的个性化解释

通过计算shapley值发现,年龄(age)、颈动脉狭窄(CS)是影响颈动脉粥样硬化发生的重要危险因素。颈动脉粥样硬化的发病风险会随着年龄的增加而增大,尤其

是在 70 岁以后,其发病率成指数上升的趋势,属于颈动脉粥样硬化发生的危险时期;对于颈动脉狭窄(CS)患者而言,由于颈动脉粥样硬化是颈动脉狭窄的进一步症状,因此颈动脉狭窄是颈动脉粥样硬化发生的重要信号。这两类人群尤其需要采取相应的措施来防范颈动脉粥样硬化的发生。通过 shapley 值还可以看出各个特征如何影响个体被预测为颈动脉粥样硬化高危人群的概率大小,因此再结合每个体检人员自身的实际情况,就可以采取合理的措施进行人为干预,进一步降低其颈动脉粥样硬化的发病风险。

5.2 展望

1.计算颈动脉粥样硬化的发病时间

本文侧重的是通过基线体检队列数据,识别出颈动脉粥样硬化的高危人群,及时提出相应的干预措施,降低其发病概率。因此在未来对颈动脉粥样硬化的研究中,可以重新调整实验设计,收集到每个随访样本的具体发病时间,再采用 Cox 回归、随机生存森林等生存分析方法进行研究,从而可以更为精准地预测颈动脉粥样硬化的发病情况。

2.解决颈动脉粥样硬化发病风险单一预测模型的拟合问题

在建立颈动脉粥样硬化发病风险预测模型时,逻辑回归、随机森林、支持向量机、XGBoost、GBDT 五种模型都存在不同程度的过拟合或欠拟合问题。本文通过 super learner 集成学习的方式来改善拟合问题,但没有具体给出针对这五种模型本身的解决方法。在疾病预测领域,如果复杂模型与简单模型的预测能力差别不大,一般遵循的原则是简洁化,会优先采用简单模型替代复杂模型用于预测发病风险。虽然本研究目的是建立起高效准确的颈动脉粥样硬化发病风险预测模型,但是如果能够改善单一模型,例如随机森林模型可以通过“剪枝”等方式降低过拟合程度,则更具有实用性。因此如何解决单一模型的拟合问题可以进一步研究。

3.拓宽数据集的来源

本文所使用的数据集仅包含 1669 个样本量和 59 个特征,全都来源于山东省某三甲医院的医疗数据库,且基本都属于山东省内的人群,导致数据的来源地区过于单一。由于受到饮食习惯或者生活习惯影响,会导致一些体检指标水平可能在各地区之间存在差异,因此本文建立的颈动脉粥样硬化发病风险预测模型具有一定的局限性。在日后的颈动脉粥样硬化的研究中,可以使用更多更广范围的样本,不仅能提高准确性,

还能分地区进行研究。例如研究不同地区之间颈动脉粥样硬化发病风险的差异性,以丰富颈动脉粥样硬化相关领域的研究。

4.开展对其他相关疾病的研究

本文的数据集来自医院的电子体检信息库,覆盖了化验指标、临床病史、人口学资料三个方面。不仅可以用于预测颈动脉粥样硬化的发病风险,还可以用于其他疾病。对于一个样本个案,可通过多个预测模型预测该样本患有不同疾病的概率。因此后续研究可以基于本文的体检数据开展其他疾病的研究与分析,使其更加深入、更加多样化。

5.探索其他建立颈动脉粥样硬化发病风险预测模型的方法

本文研究所使用的样本数量不是很庞大,对模型速度要求不高。但是随着数据量的增多,就会对模型的运行速度有一定的要求。本文首先采用逻辑回归、随机森林、支持向量机、XGBoost、GBDT 五种算法建立起颈动脉粥样硬化的发病风险预测模型,其中随机森林和 GBDT 模型的运行速度较慢。Super learner 算法集成了这五种模型,提高了对颈动脉粥样硬化发病风险的预测能力,且解决了单一模型的过拟合或欠拟合问题。但是 super learner 方法中涉及交叉验证和两个阶段的模型训练,需要花费一定的时间。未来随着新方法的推出和旧方法的优化,可以探索其他建模方法的使用例如深度学习,使得模型不仅训练时间短,预测速度快,且预测效果良好。

参考文献

- [1] Fine-Edelstein J.S., Wolf P.A., O'Leary D.H., etc. Precursors of extracranial carotid atherosclerosis in the Framingham Study[J]. *Neurology*, 1994, 44(06): 1046-1050
- [2] 李莉, 姜玉新, 乌正赓, 等. 高血压及心脑血管疾病与颈动脉粥样硬化[J]. *中华心血管病杂志*, 1996, (02): 47-50
- [3] 卫华, 王拥军, 颜振瀛, 等. 脑血管病人颈动脉粥样硬化的相关性研究[J]. *中国全科医学*, 2001, (02): 107-109
- [4] Kiechl S., Willeit J., Rungger G., etc. Alcohol consumption and atherosclerosis: what is the relation? Prospective results from the Bruneck Study[J]. *Stroke*, 1998, 29(05): 900-907
- [5] Lakka T.A., Lakka H.M., Salonen R., etc. Abdominal obesity is associated with accelerated progression of carotid atherosclerosis in men[J]. *Atherosclerosis*, 2001, 154(02): 497-504
- [6] 喻学红, 曹秉振. 颈动脉内-中膜厚度的影响因素[J]. *中国临床康复*, 2006, (37): 120-123
- [7] 张东平, 李晋芳, 胡长林, 等. 重庆市中老年钢铁工人颈动脉粥样硬化的流行病学调查[J]. *中华流行病学杂志*, 2009, (04): 322-325
- [8] 王薇, 武阳丰, 赵冬, 等. 中老年人群颈动脉粥样硬化分布特点及影响因素分析[J]. *中华心血管病杂志*, 2010, (06): 553-557
- [9] Taylor B.A., Zaleski A.L., Capizzi J.A., etc. Influence of chronic exercise on carotid atherosclerosis in marathon runners[J]. *British Medical Journal*, 2014, 4(02): e004498
- [10] 王琪, 李娟生, 蒲宏全, 等. 某随访人群颈动脉硬化发生影响因素及风险预测能力研究[J]. *中华疾病控制杂志*, 2019, 23(04): 382-386
- [11] 王瑞星. 老年糖尿病合并高血压患者颈动脉粥样硬化影响因素分析[J]. *中西医结合心血管病电子杂志*, 2019, 7(31): 71-72
- [12] Yuan T., Yang T., Chen H., etc. New insights into oxidative stress and inflammation during diabetes mellitus-accelerated atherosclerosis[J]. *Redox Biology*, 2019, 20(01): 247-260
- [13] 万密密, 赵梓楠, 李婷, 等. 动脉粥样硬化治疗的新思路[J]. *江苏大学学报(医学版)*, 2021, 31(01): 1-5

- [14] 鲁明, 陆菁菁, 杨帆. 颈动脉夹层致急性缺血性卒中患者静脉溶栓一例[J]. 中国脑血管病杂志, 2020, 17(12): 758-760
- [15] 丁瑶, 张小玉, 许杨, 等. 基于 CatBoost 算法的中青年颈动脉粥样硬化预测方法[J]. 北京生物医学工程, 2020, 39(05): 470-476+522
- [16] 赵春燕, 彭军. 体检人群颈动脉、眼底动脉硬化的影响因素分析[J]. 中国当代医药, 2021, 28(23): 27-31+277
- [17] 孙靖伦. 朝阳农村地区脑卒中高危人群颈动脉硬化现状、特征及其影响因素分析[D]. 北京: 中国医科大学, 2021
- [18] 潘雯, 邢立莹, 张立敏, 等. 无心血管危险因素中老年人群颈动脉粥样硬化及其影响因素分析[J]. 中国慢性病预防与控制, 2021, 29(03): 183-186
- [19] Wu D., Li C., Chen Y., etc. Influence of blood pressure variability on early carotid atherosclerosis in hypertension with and without diabetes[J]. Medicine, 2016, 95(24): e3864
- [20] Hollander M., Bots M.L., Del Sol A.I., etc. Carotid plaques increase the risk of stroke and subtypes of cerebral infarction in asymptomatic elderly: the Rotterdam study[J]. Circulation, 2002, 105(24): 2872-2877
- [21] Luedemann J., Schminke U., Berger K., etc. Association between behavior-dependent cardiovascular risk factors and asymptomatic carotid atherosclerosis in a general population[J]. Stroke, 2002, 33(12): 2929-2935
- [22] 王宁, 余振球, 周子杰. 原发性高血压患者血浆同型半胱氨酸与颈动脉粥样硬化的关系研究[J]. 中国全科医学, 2010, 13(12): 1263-1265
- [23] 罗国刚, 韩建峰, 王琳, 等. 血浆同型半胱氨酸与缺血性脑血管病患者颈动脉粥样硬化斑块的关系[J]. 中国脑血管病杂志, 2012, 9(03): 123-127
- [24] 陈英, 张文玲, 黄涛, 等. 炎症因子 TNF- α 、IL-6、IL-17 与类风湿关节炎并发动脉粥样硬化的关系[J]. 免疫学杂志, 2017, 33(03): 268-272
- [25] 郑迪, 卢锦阳, 李文华, 等. 血清 Cys C 和 RBP4 水平对原发性高血压伴颈动脉粥样硬化的预测价值[J]. 江苏医药, 2019, 45(06): 579-581
- [26] 顾叶青. 天津成年人群中正常范围内甲状腺功能指标与颈动脉粥样硬化的关联性分析[D]. 天津: 天津医科大学, 2020

- [27] 李佳, 丁新梅, 牛姜水, 等. H 型高血压患者脉搏波传导速度、踝臂指数在颈动脉粥样硬化中的预测价值[J]. 中国医学创新, 2020, 17(12): 153-156
- [28] 杨帆, 王晓云, 黄莉, 等. 颈动脉超声 Crouse 积分法与血浆致动脉硬化指数对慢性精神分裂症患者颈动脉粥样硬化的预测价值[J]. 中国当代医药, 2021, 28(31): 132-134
- [29] 邱雪婷, 胡羽杰, 张紫晨, 等. 半乳糖凝集素-3 对中老年人颈动脉粥样硬化的预测价值[J]. 南京医科大学学报(自然科学版), 2021, 41(08): 1173-1177
- [30] 胡培章. 血清纤维蛋白胶凝素 3 对 2 型糖尿病患者颈动脉粥样硬化的预测效果[J]. 江西医药, 2021, 56(07): 1064-1067+1083
- [31] 尹建红, 刘鸣, 孙莉, 等. 山西省长治市社区老年 2 型糖尿病患者血清白脂素对颈动脉粥样硬化的风险评估[J]. 中华糖尿病杂志, 2022, 14(03): 253-259
- [32] 邹晓璇, 李莹, 张红菊, 等. 社区中老年人群代谢综合征与颈动脉粥样硬化的关系[J]. 中华流行病学杂志, 2010, (04): 361-365
- [33] 梁蕴瑜, 谢平畅, 钟言, 等. 外周血 HCY、PLR 及 hs-CRP 预测原发性高血压患者颈动脉粥样硬化的诊断效能[J]. 现代生物医学进展, 2021, 21(16): 3110-3114
- [34] Fan J., Chen M., Luo J., etc. The prediction of asymptomatic carotid atherosclerosis with electronic health records: a comparative study of six machine learning models[J]. BioMed Central Medical Informatics and Decision Making, 2021, 21(01): 115
- [35] 王娇娇, 陈圆煜, 郑子薇, 等. 三种风险预测模型预测钢铁工人颈动脉粥样硬化的效能比较[J]. 中国全科医学, 2022, 25(11): 1334-1339
- [36] 于建宇. 基于集成学习算法的妊娠期糖尿病预测模型研究[D]. 哈尔滨: 哈尔滨工业大学, 2019
- [37] 徐继伟, 杨云. 集成学习方法: 研究综述[J]. 云南大学学报(自然科学版), 2018, 40(06): 1082-1092
- [38] 兰欣, 卫荣, 蔡宏伟, 等. 机器学习算法在医疗领域中的应用[J]. 医疗卫生装备, 2019, 40(03): 93-97
- [39] 胡满满, 陈旭, 孙毓忠, 等. 基于动态采样和迁移学习的疾病预测模型[J]. 计算机学报, 2019, 42(10): 2339-2354

- [40] 郑晓燕. 基于机器学习的心血管疾病预测系统研究[D]. 北京: 北京交通大学, 2018
- [41] 赵丹丹. 基于特征选择的结直肠癌预测模型研究[D]. 济南: 山东师范大学, 2019
- [42] Shim J.G., Kim D.W., Ryu K.H., etc. Application of machine learning approaches for osteoporosis risk prediction in postmenopausal women[J]. Archives of Osteoporosis, 2020, 15(01): 169
- [43] Shim J.G., Ryu K.H., Cho E.A., etc. Machine Learning Approaches to Predict Chronic Lower Back Pain in People Aged over 50 Years[J]. Medicina(Kaunas), 2021, 57(11): 1230
- [44] Jamthikar A.D., Gupta D., Mantella L.E., etc. Multiclass machine learning vs. conventional calculators for stroke/CVD risk assessment using carotid plaque predictors with coronary angiography scores as gold standard: a 500 participants study[J]. International Journal of Cardiovascular Imaging, 2021, 37(04): 1171-1187
- [45] 武海滨, 李康, 杨丽, 等. 非平衡分类技术在人群糖尿病疾病风险预测模型中的应用[J]. 中国卫生统计, 2019, 36(04): 502-506
- [46] 黄雪倩, 张岩波, 王蕾, 等. 基于层次分类法的弥漫大细 B 细胞淋巴瘤的疾病进展阶段多分类预测研究[J]. 中国卫生统计, 2021, 38(02): 167-170+176
- [47] 李英杰, 王岩, 贾艺林, 等. 基于 Stacking 集成学习的肾综合征出血热发病数据预测模型研究[J]. 中国卫生统计, 2022, 39(06): 811-814
- [48] Zhou Z.R., Wang W.W., Li Y., etc. In-depth mining of clinical data: the construction of clinical prediction model with R[J]. Annals of Translational Medicine, 2019, 7(23): 796.
- [49] Van der Laan M.J., Polley E.C., Hubbard A.E. Super learner[J]. Statistical Applications in Genetics and Molecular Biology, 2007, 6(01): 25
- [50] Lundberg S.M., Lee S.I. A Unified Approach to Interpreting Model Predictions[R]. NY: University of Washington, 2017