

分类号: R195.1
密 级: 公开

单位代码: 10422
学 号: 201614252



山东大学
SHANDONG UNIVERSITY

硕士学位论文

Thesis for Master Degree

论文题目: 基于 Super learner 的结直肠癌
预后预测研究

Prognostic prediction of colorectal cancer based on Super
learner

作 者 姓 名	李吉庆
培 养 单 位	公共卫生学院
专 业 名 称	流行病与卫生统计学
指 导 教 师	薛付忠 教授
合 作 导 师	

2019 年 4 月 20 日

分类号：R95.1

单位代码：10422

密 级：公开

学 号：201614252



山东大学

SHANDONG UNIVERSITY

硕士学位论文

Thesis for Master Degree

论文题目：基于 Super learner 的结直肠癌预后预测研究

Prognostic prediction of colorectal cancer based on Super learner

作者姓名	李吉庆
学院名称	公共卫生学院
专业名称	流行病学与卫生统计学
指导教师	薛付忠 教授
合作导师	

2019 年 4 月 20 日

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的科研成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律责任由本人承担。

论文作者签名： 李吉庆 日期： 2019.05.19

关于学位论文使用授权的声明

本人同意学校保留或向国家有关部门或机构送交论文的印刷件和电子版，允许论文被查阅和借阅；本人授权山东大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或其他复制手段保存论文和汇编本学位论文。

(保密论文在解密后应遵守此规定)

论文作者签名： 李吉庆 导师签名：  日期： 2019.05.19

目录

中文摘要.....	1
符号说明.....	8
前 言.....	9
资料与方法.....	13
1. 产生模拟数据集.....	13
1.1 完整生存数据模拟生成的步骤.....	13
1.2 模拟生成含特定比例删失生存数据的方法和步骤.....	13
1.3 模拟产生生存数据集.....	14
2. 统计模拟试验设计.....	15
3. 实例验证.....	15
3.1 现实数据来源.....	16
3.2 结直肠癌预后预测模型的建模策略.....	17
4. 预测模型简介.....	18
4.1 Cox 比例风险模型.....	18
4.2 加法风险模型.....	19
4.3 指数回归模型.....	20
4.4 Weibull 回归模型.....	20
4.5 对数正态回归模型.....	21
4.6 对数 logistic 回归模型.....	21
4.7 随机生存森林.....	22
4.8 Super Learner.....	24
5. 统计分析工具.....	27
结果.....	28
1. 统计模拟结果.....	28
1.1 训练集中不同删失率对模型预测效果的影响.....	29
1.2 相同分布情况下不同模型的预测效果比较.....	30

1.3 不同分布情况下不同预测模型的预测效果比较.....32

1.4 不同预测模型综合预测效果的比较.....34

2. 结直肠癌预后预测模型的研究结果35

2.1 基于第一组结直肠癌预后队列的预测模型及其评价.....36

2.2 基于第二组结直肠癌预后队列的预测模型及其评价.....40

2.3 基于第三组结直肠癌预后队列的预测模型及其评价.....44

2.4 基于第四组结直肠癌预后队列的预测模型及其评价.....48

2.5 基于第五组结直肠癌预后队列的预测模型及其评价.....52

2.6 基于第六组结直肠癌预后队列的预测模型及其评价.....56

2.7 不同预测模型综合预测效果的比较.....60

讨论.....62

结论.....69

创新与不足.....70

参考文献.....71

致谢.....76

攻读学位期间发表的学术论文目录.....77

CONTENTS

Chinese Abstract	1
English Abstract	4
Symbol Description	8
Preface.....	9
Materials & Methods	13
1. Generating simulated data sets	13
1.1 Steps for generating complete simulated survival data.....	13
1.2 Steps of simulating censored survival data with specific proportions	13
1.3 Simulated Generation of Survival Data Set	14
2. Statistical simulation study design	15
3. Case verification.....	15
3.1 Real Data Sources	16
3.2 Modeling strategy of prognostic prediction model for colorectal cancer	17
4. Brief Introduction of Prediction Model	18
4.1 Cox proportional risk model	18
4.2 Additive Risk Model.....	19
4.3 Exponential regression model.....	20
4.4 Weibull regression model.....	20
4.5 Lognormal Regression Model.....	21
4.6 Logarithmic logistic regression model.....	21
4.7 Random Survival Forest	22
4.8 Super learner	24
5. Statistical analysis tools.....	27
Results.....	28
1. Statistical simulation results	28
1.1 The effect of different deletion rates of training sets on model prediction	29

1.2 Comparison of predicting effects of different models under the same distribution	30
1.3 Comparison of predicting effects of different models under different distributions.....	32
1.5 Comparion of comprehensive predicting effects of different models.....	34
2. Research results of prognostic prediction model for colorectal cancer.....	35
2.1 Prediction model and evaluation based on the first colorectal cancer prognostic cohorts	36
2.2 Prediction model and evaluation based on the second colorectal cancer prognostic cohorts	40
2.3 Prognostic model and evaluation based on the third colorectal cancer prognostic cohorts	44
2.4 Prognostic model and evaluation based on the fourth colorectal cancer prognostic cohort	48
2.5 Prognostic model and evaluation based on the fifth colorectal cancer prognostic cohort	52
2.6 Prognostic model and evaluation based on the sixth colorectal cancer prognostic cohort	56
2.7 Comparion of comprehensive predicting effects of different models.....	60
Discussion	62
Conclusions	69
Innovation and Deficiency	70
Reference	71
Acknowledgement	76
Publications.....	77

基于 Super Learner 的结直肠癌预后预测研究

专 业：流行病与卫生统计学

导 师：薛付忠 教授

硕士研究生：李吉庆

中文摘要

结直肠癌是危害人类健康的常见恶性肿瘤之一，其所造成的的疾病负担正在不断增加。在我国男性人群中结直肠癌发病率位居第三位，死亡率居第二位；而在女性人群中，其发病率与死亡率均位居第三位。实践证明，准确判断结直肠癌患者预后及其影响因素，进而及时调整治疗干预方案，是降低其死亡率和疾病负担的有效策略。然而，目前临床上判断结直肠癌预后往往仅基于 TNM 分期（包括肿瘤病理浸润深度、区域淋巴结转移数目及是否远处转移等），凭借医生经验进行评判，其评估准确性通常不高。为了提高预后预测准确性，增加预后判断的客观性，国内外已有研究在 TNM 分期的基础上增加其他常见的预后相关指标，采用常规的单一疾病预测模型（如 Weibull 回归、Cox 比例风险回归模型、基于机器学习的随机生存森林模型等）构建结直肠癌预后预测模型。然而，单一预测模型各有其局限性，针对不同人群、不同预测变量的情形时，其预测效果差异很大，必然严重影响模型外推预测的准确性。

为了提高结直肠癌预后预测的准确性和外推泛化能力，本研究在新近发展的 Super learner 理论方法框架下，组合运用 Cox 比例风险模型、随机生存森林、加法风险模型、Weibull 回归模型、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林共八种预测方法，构建新一代的结直肠癌预后预测模型。首先，通过理论模拟系统比较 Super learner 与 8 个传统单一预测模型在不同类型数据中的预测准确性和精确性。然后，利用来自不同种族、不同地区真实世界研究的 6 个结直肠癌预后队列，分别建立了基于 Super learner 的组合预测模型和 8 个单一预测模型，并进行了实效性比较和验证。

研究结果:

1.统计模拟结果显示,在数据结构相对简单和预测变量数目较少的模拟情境下, Super learner 预测效果较好,其判别准确性(C-index)均值为0.715,而校准能力(O/E)的综合评价指标 $|1-O/E|$ 均值为0.069。Super learner 组合预测模型表现出校准能力(O/E)接近1的稳健校准能力;而其它单一预测模型在不同结构的外推预测集中表现出校准能力(O/E)不稳健的状态。

2.在不同真实世界研究的6组结直肠癌预后队列组合中, Super learner 组合预测模型均表现出较为稳健的预测效果,具有稳定的外推泛化能力;而其它单一预测模型在不同分布特征的结直肠癌预后队列中,表现不稳健,预测能力的一致性较差。具体表现为:

(1)在第一组队列(本课题组构建的结直肠癌预后队列为训练集,TCGA-COADREAD 队列为验证集)中,C-index 依次为对数正态回归模型(0.819)、对数 logistic 回归模型(0.815)、Super learner (0.813),位居第三位;O/E 比依次为Cox 比例风险模型(1.086)、指数回归模型(1.087)、Weibull 回归模型(1.088)、随机条件推理森林(1.111)、Super learner (1.113),位居第五位。

(2)在第二组队列(“survival”包里的结肠癌预后队列作为训练集,本课题组构建的结直肠癌预后队列为验证集)中,C-index 依次为加法风险模型(0.819)、对数正态回归模型(0.730)、对数 logistic 回归模型(0.729)、Weibull 回归模型(0.727)、指数回归模型(0.727)、Super learner (0.723),位居第六位;O/E 比依次为随机条件推理森林(1.213)、Weibull 回归模型(1.216)、指数回归模型(1.235)、加法风险模型(1.252)、对数正态回归模型(1.269)、对数 logistic 回归模型(1.277)、Super learner (1.292),位居第七位。

(3)在第三组队列(本课题组构建的结直肠癌预后队列为训练集,TCGA-COADREAD 队列为验证集)中,C-index 依次为 Super learner (0.816)、对数正态回归模型(0.816),位居第一位;O/E 比依次为 Weibull 回归模型(1.053)、对数 logistic 回归模型(1.054)、指数回归模型(1.054)、随机条件推理森林(1.070)、对数正态回归模型(1.071)、Super learner (1.077),位居第六位。

(4)在第四组队列(GEO 数据库中下载的 GSE40967 数据作为训练集,GSE41258 数据作为验证集)中,C-index 依次为随机条件推理森林(0.822)、加

法风险模型 (0.820)、Super learner (0.818), 位居第三位; O/E 比依次为随机生存森林 (0.929)、随机条件推理森林 (0.886)、Super learner (0.878), 位居第三位。

(5) 在第五组队列 (GEO 数据库中下载的 GSE40967 数据作为训练集, TCGA-COAD 数据作为验证集) 中, C-index 依次为加法风险模型 (0.790)、Super learner (0.820), 位居第二位; O/E 比依次为随机条件推理森林 (0.981)、Cox 比例风险模型 (0.980)、随机生存森林 (0.979)、加法风险模型 (0.975)、Super learner (0.973), 位居第五位。

(6) 在第六组队列 (本课题组构建的结肠癌预后队列为训练集, GEO 数据库中下载的 GSE40967 数据作为验证集) 中, C-index 依次为随机条件推理森林 (0.733)、Super learner (0.725), 位居第二位; O/E 比依次为对数正态回归模型 (0.998), Super learner (0.990), 位居第二位。

(7) 对预测模型在六组队列组合中的预测效果进行综合评价, 在内部验证中, C-index 均值依次为随机生存森林 (0.929)、随机条件推理森林 (0.800)、Super learner (0.795), 位居第三位; 校准能力 (O/E) 的综合评价指标 $|1-O/E|$ 依次为随机条件推理森林 (0.041)、随机生存森林 (0.042)、加法风险模型 (0.042)、Super learner (0.046), 位居第四位。在外部验证中, Super learner 的 C-index 均值 0.780, 位居第一位; 校准能力 (O/E) 的综合评价指标 $|1-O/E|$ 为随机生存森林 (0.079)、Weibull 回归模型 (0.081)、指数回归模型 (0.083)、加法风险模型 (0.071)、Super learner (0.092), 位居第五位。

研究结论:

1. 在数据结构相对简单和预测变量数目较少的模拟情境下, Super learner 预测效果较好。

2. 在较为复杂的真实世界结直肠癌预后队列中, 单一预测模型表现较不稳定, 其预测准确性呈忽高忽低的趋势; 而 Super learner 组合预测模型无论在何种情况下均表现出较为稳健的预测效果, 外推泛化能力稳定。

3. 基于 Super learner 组合预测策略的结直肠癌预后预测模型, 具备稳健性强、准确性高以及外推泛化能力强的优良特征, 为临床结直肠癌预后预测提供了新方法。

关键词: 结直肠癌; 预后预测; Super learner 组合预测模型

Prognostic prediction of colorectal cancer based on Super learner

Major: Epidemiology and Biostatistics

Advisor: Prof. Fuzhong Xue

Student: Jiqing Li

ABSTRACT

Colorectal cancer is one of the most common malignant tumors endangering human health. The burden of disease caused by colorectal cancer is increasing. In China, the incidence of colorectal cancer ranks third and the mortality rate ranks second among males, while among females, the incidence and mortality rate rank third. Practice has proved that accurate judgment of prognosis and influencing factors of patients with colorectal cancer and timely adjustment of treatment and intervention programs are effective strategies to reduce their mortality and disease burden. However, the current methods of judge clinical prognosis for colorectal cancer are only based on TNM staging (including the depth of pathological invasion, the number of regional lymph node metastases and whether distant metastasis). The accuracy of the assessment is often not high based on the experience of doctors. In order to improve the accuracy of prognostic prediction and increase the objectivity of prognostic judgement, other common prognostic indicators have been added on the basis of TNM staging. A prognostic prediction model of colorectal cancer has been constructed by using conventional single disease prediction models (such as Weibull regression, Cox proportional risk regression model, random survival forest model based on machine learning, etc.). However, each of these single prediction models has its own limitations. In the case of different population and different prediction variables, the prediction effect is often very different, which seriously affects the accuracy of extrapolation prediction.

In order to improve the accuracy and generalization ability of prognosis prediction

for colorectal cancer, this study aims to combine Cox proportional risk model, random survival forest, additive risk model, Weibull regression model, exponential regression model, lognormal regression model, logarithmic logistic regression model and random conditional reasoning forest under the framework of the newly developed Super learner theory to construct a new generation of prognostic prediction model for colorectal cancer. Firstly, the prediction accuracy and stability of Super learner and traditional single prediction model in different types of data are systematically compared and evaluated by theoretical simulation. Then, using six real-world prognostic cohorts from different races and regions, a combination prediction model based on Super learner and single prediction model were established, and the effect of prediction was compared and validated.

The results of the study are as follows:

1. Statistical simulation results show that Super learner has a better prediction effect in the situation of relatively simple data structure and fewer predictive variables. The mean of C-index is 0.715, while the mean of comprehensive evaluation index $|1 - O/E|$ of calibration ability (O/E) is 0.069, Super learner combined predicting model shows robust calibration ability (O/E) close to 1, while other single predicting models show a unstable calibration ability (O/E) in extrapolation predicting of different structures.

2. Among the 6 groups of colorectal cancer prognostic cohorts in different real-world studies, Super learner combination prediction model showed more robust predictive effect and stable extrapolation generalization ability, while other single prediction model showed less robust performance and poor consistency in heterogeneous colorectal cancer prognostic cohorts with different distribution characteristics. The concrete manifestations are as follows:

(1) In the first group of cohorts (the prognostic cohort of colorectal cancer constructed by our research group as training set and TCGA-COADREAD as validation set), the order of C-index is lognormal regression model (0.819), logarithmic logistic regression model (0.815), Super learner (0.813), which ranked third; the order of O/E ratio is Cox proportional risk model (1.086), exponential regression model (1.087),

respectively. Weibull regression model (1.088), random conditional reasoning forest (1.111), Super learner (1.113), which ranked fifth.

(2) In the second group of cohorts (the colon cancer prognosis cohort in the "survival" package as the training set, and the colon cancer prognosis cohort constructed by our group as the validation set), the order of C-index was the additive risk model (0.819), the logarithmic normal regression model (0.730), the logarithmic logistic regression model (0.729), the Weibull regression model (0.727), and the exponential regression model (0.727), Super learner (0.723), ranked sixth; the order of O/E ratio was random conditional reasoning forest (1.213), Weibull regression model (1.216), exponential regression model (1.235), additive risk model (1.252), lognormal regression model (1.269), logarithmic logistic regression model (1.277), Super learner (1.292), ranked seventh.

(3) In the third group of cohorts (the prognostic cohort of colorectal cancer constructed by our research group is listed as training set and TCGA-COADREAD as validation set), C-index of Super learner was 0.816, which ranked first; the order of O/E ratio was Weibull regression model (1.053), logarithmic logistic regression model (1.054), exponential regression model (1.054), and logarithmic regression model (0.816), respectively. Random conditional reasoning forest (1.070), lognormal regression model (1.071), Super learner (1.077), ranked sixth.

(4) In the fourth group of cohorts (GSE40967 data downloaded from GEO database as training set and GSE41258 data as validation set), the order of C-index was random conditional reasoning forest (0.822), additive risk model (0.820), Super learner (0.818); the order of O/E ratio was random survival forest (0.929), random conditional reasoning forest (0.886), Super learner (0.878), ranked third.

(5) In the fifth group of cohorts (GSE40967 data downloaded from GEO database as training set and TCGA-COAD data as validation set), the order of C-index was additive risk model (0.790) and Super learner (0.820); the order of O/E ratio was random conditional reasoning forest (0.981), Cox proportional risk model (0.980), random survival forest (0.979) and additive risk model (0.975), Super learner (0.973), ranked fifth.

(6) In the sixth group of cohorts (the colon cancer prognosis cohort constructed by our research group as training set, and the GSE40967 data downloaded from GEO database as validation set), the order of C-index was random conditional reasoning forest (0.733), Super learner (0.725), and the order of O/E ratio was lognormal regression model (0.998), Super learner (0.990), ranked second.

(7) In the internal validation, the C-index means of Super learner ranked third in the order of random survival forest (0.929), random conditional reasoning forest (0.800), Super learner (0.795), and the order of the comprehensive evaluation index $|1-O/E|$ was random conditional reasoning forest (0.041), random survival forest (0.042), additive risk model (0.042), Super learner (0.046), ranked fourth. In external validation, Super learner's C-index average is 0.780, ranking first; the comprehensive evaluation index of $|1-O/E|$ is random survival forest (0.079), Weibull regression model (0.081), exponential regression model (0.083), additive risk model (0.071), Super learner (0.092), ranking fifth.

Conclusion:

1. In the simulation scenario where the data structure is relatively simple and the number of predictive variables is relatively small, Super learner has a good prediction effect.

2. In more complex real-world queues, the single prediction model is often unstable, and its prediction accuracy fluctuates greatly in different data sets; while Super learner combined prediction model shows a more robust prediction effect in any case, and its extrapolation generalization ability is stable.

3. The prognostic prediction model of colorectal cancer based on Super learner combination prediction strategy has the excellent characteristics of strong robustness, high accuracy and strong extrapolation generalization ability, which provides a new method for clinical prognosis prediction of colorectal cancer.

Key words: colorectal cancer; prognosis prediction; Super learner

符号说明

CRC	Colorectal cancer	结直肠癌
C-index	Harrell concordance index	Harrell 一致性指数
UICC	International Union Against Cancer	美国国际联合抗癌委员会
AJCC	American Joint Committee on Cancer	美国癌症联合委员会
CEA	Carcinoembryonic antigen	癌胚抗原
CA19-9	Carbohydrate antigen 19-9	糖类抗原 19-9
CRP	C-reactive protein	C 反应蛋白
GPS	Glasgow prognostic score	Glasgow 预后评分
PLR	Platelet-to-lymphocyte	血小板与淋巴细胞比值
LMR	Lymphocyte-to-monocyte	淋巴细胞与单核细胞比值
MSI	Microsatellite instability	微卫星不稳定性
CIN	Chromosomal instability	染色体不稳定性
CIMP	CpG island methylator phenotype	CpG 岛甲基化表型
TCGA	The Cancer Genome Atlas	美国癌症基因组图谱计划
NCBI	National Center for Biotechnology Information	美国国立生物技术信息中心
GEO	Gene Expression Omnibus	基因表达数据库
CART	Classification and regression tree	分类回归树
RF	Random forests	随机森林
OOB	Out-of-bag data	袋外数据
RSF	Random survival forests	随机生存森林
ROC	Receiver operator characteristic curve	受试者工作特征曲线

基于 Super Learner 的结直肠癌预后预测研究

专 业：流行病与卫生统计学

导 师：薛付忠 教授

硕士研究生：李吉庆

前 言

结直肠癌 (colorectal cancer, CRC) 是影响人类健康的重大恶性肿瘤之一, 其发病率和死亡率均位居恶性肿瘤前列, 其所造成的人群疾病负担日趋加重。研究表明, 结直肠癌发病率居全球恶性肿瘤第三位, 年均结直肠癌病例可达 120 万例, 其中有 60 万人死于结直肠癌^[1]。近年来结直肠癌发病及死亡水平仍在不断攀升, 据权威预测, 至 2030 年, 全球新增结直肠癌病例将达 220 万例, 死亡病例 110 万例^[2]。据中国 2015 年癌症统计报告, 每年新发结直肠癌病例 38 万, 近 20 万人死于该病^[3]; 而且, 随着我国经济发展和人民生活水平的不断提高以及人口老龄化的加剧, 结直肠癌发病率和死亡率也在逐年增加, 且其发病和死亡趋于年轻化, 表现为中青年患者发病率和死亡率呈明显上升趋势^[4, 5]。

理论上, 降低人群结直肠癌疾病负担的策略和方法有一级预防、二级预防和三级预防。一级预防是预防结直肠癌的发生, 二级预防重在其早诊早治, 而三级预防则侧重于病后康复干预和延长复发转移时间, 增加生存期。然而, 在目前结直肠癌病因仍不十分明确的前提下, 一级预防措施效果不佳。虽然目前推行的早诊早治二级预防措施效果较好, 但由于筛查费用昂贵、耗时, 人群覆盖面有限, 因而整体收益不佳。因此, 侧重于病后康复和复发预防的三级预防, 对于降低结直肠癌人群疾病负担而言, 仍是十分重要的策略。故在结直肠癌治疗的早期阶段, 及时准确的预测患者病情预后, 以便制定实施有效的个性化干预措施, 是当前临床工作中必须解决的关键科学问题之一。

由美国国际联合抗癌委员会 (International Union Against Cancer, UICC) 和美国癌症联合委员会 (American Joint Committee on Cancer, AJCC) 制定的 TNM 分期, 目前仍是临床上制定患者辅助化疗方案、手术方案以及预后判断的主要依据^[1, 6-8]。然而, TNM 分期仅包含肿瘤未经治疗时浸润深度、区域淋巴结转移数目

及是否远处转移三个方面的信息,未能全面反映肿瘤的异质性。临床实践表明该分期系统预后预测效果较差,同一病理分期的患者其临床结果可显著不同^[9],如部分晚期癌症患者存活年限较长,甚至可以达到部分或完全康复,而有研究报道约有 25%的 I 期或 II 期结直肠癌患者在行完全切除术后,肿瘤进展迅速,短时间内复发或死亡^[10]。

除 TNM 分期外,结直肠癌患者的其他特征变量也可用于预后预测,如肿瘤位置、组织学类型、分化程度、脉管浸润等临床病理学指标。肿瘤标志物对于恶性肿瘤的诊断、治疗、检测有无转移或复发具有重要意义^[11],其主要代表为癌胚抗原(carcinoembryonic antigen, CEA)和糖类抗原 19-9(carbohydrate antigen 19-9, CA19-9)。欧洲肿瘤组织标记指南与美国国立综合癌症网络指南推荐术前 CEA 可作为独立的预后预测因子用于结直肠癌预后检测^[12, 13];部分研究认为术后 CEA 持续升高的患者复发及死亡风险高,预后结局较差^[14]。CA19-9 也可用于 CRC 预后预测,虽其敏感性和特异性较低,但其水平升高可用于识别淋巴结转移阴性但高风险的患者^[15]。有研究表明,结直肠癌患者预后与个体炎症反应相关^[16, 17]。个体炎症反应水平可通过检测血液中淋巴细胞、白细胞、中性粒细胞、C 反应蛋白(C-reactive protein, CRP)及白蛋白含量进行评价,依据这些检测指标构建的 Glasgow 预后评分(Glasgow prognostic score, GPS)^[18]、血小板与淋巴细胞比值(platelet-to-lymphocyte, PLR)及淋巴细胞与单核细胞比值(lymphocyte/monocyte, LMR)与结直肠癌患者的生存率有关^[19, 20]。结直肠癌的发生通常伴有染色体改变,包括染色体不稳定性(chromosomal instability, CIN)、微卫星不稳定性(microsatellite instability, MSI)和 CpG 岛甲基化表型(CpG island methylator phenotype, CIMP),其中 MSI 和 CIMP 的临床应用较为广泛,如多项研究表明微卫星高度不稳定(MSI-H)的结直肠癌患者预后优于微卫星稳定(MSS)患者^[21-23],P16CpG 区甲基化患者的生存期较未甲基化患者短^[24, 25]。在基因水平上与结直肠癌发生发展密切相关的基因主要有 p53 基因、APC 基因、K-ras 基因和 B-raf 基因等,但结直肠癌的发生是众多癌基因激活及抑癌基因失活的结果,单个基因的预后预测能力有限。近年来,许多研究从基因表达层面研究建立了一系列与结直肠癌预后相关的分子标志群^[26-36],但不同研究确定的分子标志群间重叠基因极少,这提示基于预后分子标志群构建的预后预测模型在不同人群中预后

预测稳定性较差,加之现阶段基因检测技术复杂且费用相对较高,故其临床应用价值较低。

为了提高结直肠癌预后预测效果,许多研究利用常见的结直肠癌预后指标构建预后预测模型^[37-42]。目前用于生存预测的算法主要有三类:1)参数方法,根据样本数据估计分布模型参数,从而获得生存时间的概率分布模型,如基于Weibull分布的Weibull回归、基于指数分布的指数回归模型、基于对数正态分布的对数正态回归和基于对数logistic分布的对数logistic回归等;2)半参数法,该方法不需事先假定生存时间的分布类型,最常用的是Cox比例风险回归模型,此外还有加法风险回归模型;3)机器学习方法,如随机生存森林、条件推理树、生存支持向量机及贝叶斯加权回归树等机器学习方法。其中,参数法因要求数据服从某特定的分布,限制了其应用。大量研究构建Cox比例风险模型进行预后预测,其建模流程基本为首先整理数据并进行变量赋值,然后利用单因素Cox比例风险模型或者log-rank检验进行变量筛选,进而将单因素回归分析中有意义的变量纳入多因素Cox比例风险模型,构建预后预测列线图,并对模型进行评价。如Valentini等^[43]利用2795例直肠癌患者的资料,以年龄、性别、T分期、N分期、辅助化疗、手术方式及放疗剂量等常见临床病理学指标构建Cox比例风险回归模型,并建立了针对欧洲人群的直肠癌预后预测列线图,其训练组和验证组的模型一致性系数在分别为0.680和0.700;Peng等^[43]利用883例直肠癌患者生存数据开发了一个针对中国人群的结直肠癌预后列线图来预测II-III期直肠癌患者的生存预后,训练集和验证集中模型C-index分别为0.700和0.760。也有部分研究应用机器学习的方法进行结直肠癌预后预测研究^[44, 45],如洪远芳^[44, 45]利用随机生存森林进行结直肠癌预后预测,并与Cox比例风险回归模型比较,发现随机生存森林预测准确性优于后者。上述预测模型或机器学习算法在不同数据集的预测表现各不相同,如Cox比例风险模型泛化外推能力较强,预测表现较为稳定,而某些机器学习算法在训练集中预测表现较好,但容易导致过拟合,泛化外推能力较差。从理论上讲,各种预测算法的预测表现取决于其逼近真实数据生成分布的效果,而在实际应用过程中,对于给定的数据集,何种预测模型或机器学习算法表现最好通常未知,大多直接选择最为常用的Cox比例风险模型或某种机器学习算法。

为了充分利用各单一模型的特定优势,提高预测模型的预测准确性和模型泛化外推能力稳定性, Van der Laan^[43]等人提出了一种基于损失函数的学习方法——**Super learner**。Super learner 的基本原理是将适用于不同数据类型和具有其特定优势的单一模型组合起来,基于损失函数最小化原理赋予不同的权重,构建组合预测模型,从而使**交叉验证**风险最小化^[46]。该方法的简要流程为:1)整理数据并选择相应的算法集合;2)将数据随机分组,为交叉验证做准备;3)在训练集中基于选择的算法建立预测模型,并于验证集中得到预测概率;4)在验证集中利用真实结局与预测概率计算风险(由相应的损失函数定义),从而得到每一种算法的交叉验证风险;5)对选择的算法进行加权组合,通过调整权重向量 α ,达到交叉验证风险最小化;6)在完整的数据集中拟合每个算法,并与上一步中获得的权重相结合,生成 Super learner 组合模型。为此,本研究首先通过统计模拟,产生不同分布、预测因子与结局之间关联强度、预测因子的相关模式(协方差矩阵)、结局截尾程度的数据集;进而,将数据集分为训练集和测试集,分别评价 Cox 比例风险模型、随机生存森林、加法风险模型、Weibull 回归模型、指数回归模型、对数正态回归模型、对数 logistic 回归模型及条件推理森林 8 种单一预测模型和 Super learner 组合预测模型的预测准确性(C-index)和校准能力(O/E)。然后,在理论模拟的基础上,利用来自不同种族、不同地区真实世界研究的 5 个结直肠癌预后队列数据集,并根据预测因子一致性原则通过数据集间的两两组合,构建真实世界场景下的训练集和验证集,进行 9 种预测模型的预测实效性比较和验证。旨在筛选结直肠癌预后预测的稳健、准确和高效的预测模型,为临床结直肠癌预后评估和个性化干预提供方法和工具。

资料与方法

1. 产生模拟数据集

1.1 完整生存数据模拟生成的步骤

目前模拟产生完整生存数据大多采用 Bender 等人在 2005 年提出的模拟方法^[47]。该方法的基本思想是从某一时刻风险函数的一般表达式入手, 利用死亡累积分布函数、累积生存函数和累积风险函数的相互关系, 通过设定的回归系数 β 和非零基准风险函数 $h_0(t)$ 产生生存时间。其理论推导过程如下:

某一时刻风险函数:

$$h(t|X) = h_0(t)\exp(\beta^T X) \quad (1)$$

当前时刻仍存活的概率为:

$$S(t|X) = \exp[-H_0(t) \exp(\beta^T X)] \quad , \quad H_0(t) = \int_0^t h_0(u) du \quad (2)$$

死亡累积分布函数或累计死亡概率为:

$$F(t|X) = 1 - S(t|X) = 1 - \exp[-H_0(t) \exp(\beta^T X)] \quad (3)$$

假设 Y 是函数 F 的自变量, 由概率知识可以得知分布函数 $F(Y)$ 服从在 $[0,1]$ 区间上的均匀分布, 同样可以得知, $1-F(Y)$ 也服从在 $[0,1]$ 上的均匀分布, 即 $U = \exp[-H_0(t) \exp(\beta^T X)]$ 服从 $[0,1]$ 上的均匀分布 $U[0,1]$ 。

假设生存时间为 T , 对前式取反函数, 得到:

$$T = H_0^{-1}[-\log(U)\exp(-\beta^T X)] \quad (4)$$

基于上述基本思想, 首先根据目标生存分布所对应的累积风险函数表达式 $H_0(t)$, 获得其反函数 $H_0^{-1}(t)$, 进而利用随机数发生器随机模拟产生服从均匀分布的 U , 然后根据设定的回归系数向量 β 和协变量向量 X , 利用公式 (4) 产生服从特定分布的生存时间 T 。指数分布累积风险函数的反函数为 $H_0^{-1}(t) = \lambda^{-1}t$, 将其代入公式(4)则 $T = -\frac{\log(U)}{\lambda \exp(\beta^T X)}$; Weibull 分布累积风险函数的反函数为 $H_0^{-1}(t) = (\lambda^{-1}t)^{\frac{1}{\gamma}}$, 将其代入公式 (4) 则 $T = (-\frac{\log(U)}{\lambda \exp(\beta^T X)})^{1/\gamma}$ 。

1.2 模拟生成含特定比例删失生存数据的方法和步骤

删失 (censoring) 是模拟产生生存数据过程中必须考虑的问题, 按照研究对

象删失发生与否与研究对象的其他特征是否有关,删失可分为随机删失和非随机删失两类。由于非随机删失影响因素众多,因此本研究在模拟产生生存数据时,将删失假定为完全随机删失。

在模拟产生的完整生存数据基础上,产生特定比例的随机删失,具体方法如下:1)首先按照完整生存数据模拟生成的一般步骤生成服从特定分布、样本量为 N 的完整生存数据;2)按照预先设定的删失比例,在完整生存数据中随机抽取 $N \cdot P$ 个研究对象作为“删失观测”;3)由于本研究预先假定删失分布为均匀删失,因此删失在随访开始至真实生存时间 T_i 之间随机发生,删失发生时间即为删失时间 C_i ;4)将产生的 $N \cdot P$ 个删失观测的删失时间与其他未删失观测真实生存时间整合为新的观察时间变量;同时,增加结局变量 I , $I=1$ 表示观察到结局发生, $I=0$ 表示删失。

1.3 模拟产生生存数据集

在结直肠癌预后随访队列中,随访观察一段时间,观察死于结直肠癌的结局发生情况。假定根据前期的单因素 Cox 比例风险模型或 Log-rank 检验,筛选出与结直肠癌预后有关的若干预测变量,根据其效应大小,结合专业知识及临床可及性,选定了具有预测价值的 P 个预测因子 $X = (x_1, x_2, x_3, \dots, x_p)$, 如与结直肠癌预后相关的肿瘤浸润深度、阳性淋巴结数据、送检淋巴结数据、脉管浸润、年龄、术前 CEA 水平、肿瘤位置等。

基于队列实际数据,计算预测因子向量 $X = (x_1, x_2, x_3, \dots, x_p)$ 中各预测因子的均值及其协方差阵,以此作为总体均值向量和总体协方差的估计

$$\mu = (\mu_1, \mu_2, \dots, \mu_p), \quad \Sigma^2 = \begin{bmatrix} \sigma_{11}^2 & \sigma_{12}^2 & \cdots & \sigma_{1p}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \cdots & \sigma_{2p}^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1}^2 & \sigma_{p2}^2 & \cdots & \sigma_{pp}^2 \end{bmatrix} \quad (5)$$

则令 X 服从多元正态分布 $X \sim N[\mu, \Sigma^2]$, 并以此为总体产生预测因子向量 $X = (x_1, x_2, \dots, x_p)$ 的数据集,并参照实际关联分析结果设定其效应大小为 $B = (\beta_1, \beta_2, \dots, \beta_p)$ 。然后,依据上述公式(1)至公式(4)的推导方法和特定比例删失数据的产生方法,产生样本量为 n , 删失率为 p 的模拟生存数据。

2. 统计模拟试验设计

本研究选择具有代表性的 8 种单一预测模型, 包括指数回归模型、对数正态回归模型、Weibull 分布回归、对数 logistic 回归模型, Cox 比例风险模型、加法风险模型、随机生存森林和条件推理树, 以及由 8 种单一模型加权的 Super learner 组合模型, 作为模拟研究对象。在给定样本量为 1000 例的前提下, 设定不同的删失率, 以 Weibull 分布为总体分布产生的模拟数据作为为训练集; 再以 Weibull 分布为总体产生同分布测试集, 以探讨训练集删失率不同对模型预测效果的影响。

在样本量 1000 的前提下, 设定删失率 20%, 以 Weibull 分布为总体产生模拟数据, 作为为训练集; 再分别以 Weibull 分布和指数分布为总体, 产生同分布测试集和不同分布测试集。应用上述 8 种单一预测模型和 Super learner 组合预测模型, 在训练集中构建预测模型, 并利用十折交叉验证进行内部验证; 然后, 在测试集中进行外部验证。采用训练集和测试集的预测准确度 (C-index) 和校准能力 (O/E), 分别评价预测模型的内部有效性和泛化外推能力。

3. 实例验证

采用世界不同种族、不同地区的多个数据库相互预测验证的模式, 组合训练集和验证集。包括: ①本课题组构建的结直肠癌病例随访队列; ②由美国癌症基因组图谱计划 (The Cancer Genome Atlas, TCGA) 数据库中, 检索结直肠癌预后数据, 构建结直肠癌病例随访队列; ③由美国国立信息中心 (National Center for Biotechnology Information, NCBI) 创建的基因表达数据库 (Gene Expression Omnibus, GEO) 中, 检索结直肠癌预后数据, 构建结直肠癌随访队列; ④下载 R 语言 “survival” 包中的结肠癌临床试验数据, 构建结直肠癌病例随访队列。

根据不同预测因子组合在各个数据集中的可获得性, 构建如下 6 对训练集和验证集队列: ①第一组队列: 本课题组构建的结直肠癌预后队列为训练集, TCGA-COADREAD 队列为验证集; ②第二组队列: R “survival” 包里的结肠癌预后队列作为训练集, 本课题组构建的结肠癌预后队列为验证集; ③第三组队列: 本课题组构建的结直肠癌预后队列为训练集, TCGA-COADREAD 队列为验证集; ④第四组队列: GEO 数据库中下载的 GSE40967 数据作为训练集, GSE41258 数据作为验证集; ⑤第五组队列: GEO 数据库中下载的 GSE40967 数据作为训练集, TCGA-COAD 数据作为验证集; ⑥第六组队列: 本课题组构建的结肠癌预后队列

为训练集，GEO 数据库中下载的 GSE40967 数据作为验证集。

在上述 6 组训练集和验证集队列中，分别采用指数回归模型、对数正态回归模型、Weibull 分布回归、对数 logistic 回归模型、Cox 比例风险模型、加法风险模型、随机生存森林、条件推理预测 8 种单一预测模型以及由这 8 种单一模型加权而成的 Super learner 组合模型，作为建模工具，在训练集中构建预测模型，并利用十折交叉验证进行内部验证；然后，在测试集中进行外部验证。采用训练集和测试集的预测准确性（C-index）和校准能力（O/E 比值），分别评价预测模型的内部有效性和泛化外推能力。

3.1 现实数据来源

3.1.1 山东结直肠癌病例随访队列

依托山东大学健康医疗大数据队列云平台，链接结直肠癌电子病历、山东省死因数据库、社会医疗保险数据及病案首页数据等，构建结直肠癌预后随访队列。纳入标准：1) 经病理诊断为结直肠癌；2) 患者 18 岁及以上；3) 患者在行结直肠癌切除手术前未接受新辅助化疗；4) 患者行根治性手术治疗；5) 可获得患者术前肿瘤标志物检测数据；6) 可获得随访数据。排除标准：1) 术前接受化疗或免疫治疗；2) 由于广泛转移而无法治疗；3) 合并有其他恶性肿瘤。符合上述纳入排除标准的结直肠癌患者进入随访队列。

由研究对象的电子病历中提取其基线临床病理学指标，包括年龄、性别、婚姻状况、职业、受教育程度、肿瘤位置、组织学类型、脉管浸润、送检淋巴结数目、分化程度、肿瘤浸润深度、远处转移等。T 分期和 N 分期由临床医师根据结直肠癌患者病理确定。由研究对象的化验检测数据中提取肿瘤标志物（CEA、CA19-9）检测数据，依据肿瘤标志物检测日期与手术日期判断其是否为术前 CEA 和 CA19-9 检测结果。

在山东省死亡登记数据库和医疗保险数据库中，检索所有研究对象的预后和治疗信息，如生存状态、死亡日期、死亡原因和放化疗信息等。生存时间定义为研究对象从病理确诊为结直肠癌至死于结直肠癌之间存活的时间；删失定义为研究对象最后的随访记录为存活状态或因其他原因死亡。

3.1.2 TCGA-COADREAD 结直肠癌病例随访队列

由 TCGA 网站上搜索查找与“colon cancer”、“rectal cancer”及“colorectal cancer”

有关的数据信息,获得结直肠癌相关数据,下载随访信息和临床病理学指标。具体包括年龄、肿瘤位置、术前 CEA 水平、浸润深度、阳性淋巴结数据、送检淋巴结数目、组织学类型等。

3.1.3 GSE40967、GSE41258 结直肠癌病例随访队列

从 NCBI 创建并维护的 GEO 数据库以关键词 (colorectal cancer OR colon cancer) AND (prognosis OR prognosis outcome OR survival) AND “Homo sapiens” 进行检索,筛选样本量大于 100、具有预后信息和临床病理学指标的数据集。经过逐个查阅筛选,共筛选出 GSE40967、GSE41258 两个数据集,其临床病理学指标分别包括:年龄、T 分期、N 分期、是否远处转移、肿瘤位置、是否化疗、微卫星稳定性、Kras 基因突变、Braf 基因突变、p53 基因突变等;年龄、性别、T 分期、N 分期、是否远处转移、肿瘤位置、微卫星稳定性及 p53 基因突变。

3.1.4 R “survival” 包里的结肠癌预后队列

R 语言 “survival” 包里的结肠癌数据来源于 20 世纪 90 年代一项关于辅助化疗的临床试验^[48,49],其临床病理学指标包括年龄、性别、化疗方案、送检淋巴结数目、肿瘤浸润深度、分化程度、阳性淋巴结数据等。

3.2 结直肠癌预后预测模型的建模策略

(1) 建模准备:通过文献检索,汇总与结直肠癌预后相关的预测因子。采用单因素 Cox 比例风险模型初筛预测因子,再结合专业知识及预测因子在训练集和验证集中的可获得性,确定纳入预测模型的预测因子。由于现实数据来自不同数据库,所以需要对现实数据进行整理,统一各数据集随访时间单位,统一训练集与验证集的变量赋值,便于预测建模和模型评价。

(2) 模型构建:在上述 6 组训练集和验证集队列中,分别采用指数回归模型、对数正态回归模型、Weibull 分布回归、对数 logistic 回归模型、Cox 比例风险模型、加法风险模型、随机生存森林、条件推理预测 8 种单一预测模型以及由这 8 种单一模型加权而成的 Super learner 组合模型,作为建模工具,在训练集中构建预测模型,并利用十折交叉验证进行内部验证。然后,在测试集中进行外部验证。

(3) 模型评价:采用训练集和测试集的预测准确性 (C-index) 和校准能力 (O/E),分别对预测模型的内部有效性和泛化外推能力进行评价。模型的判别能

力（准确性）是指模型区别结局和非结局的能力。本研究应用 Harrell 一致性指数（C-index）对模型判别能力（Discrimination）进行评价。C-index 主要用于计算生存分析中预测值与真实结局之间的区分度。其计算方法是将所有研究对象随机两两组对，若每个对子中的预测生存概率较高的研究对象，其实际生存时间长于对子中的另外一个研究对象，则认为预测结果与实际结果相符，称为“一致”；反之，则为“不一致”。在所有对子中，预测与实际结果相一致的情况所占的比例即为一致性指数。其具体的计算步骤为：①所有样本随机两两配对，共有 C_N^2 对， N 为数据集样本总数；②若配成对子的两个研究对象，均未发生结局事件或对子中某研究对象还未发生结局事件，即其随访时间短于对子中发生结局事件的另一研究对象；出现以上两种情况时，无法对研究对象实际生存时间进行比较，故将其从配对中去除，剩余对子数记为 M ；③计算剩下的配对中预测结果与实际结果相一致的对子数，记为 K ，即每个对子中的预测生存概率较高的研究对象其实际生存时间长于对子中另一研究对象的数目；④计算一致性指数 $C-index = K/M$ 。

模型校准能力（Calibration）是指模型预测结局事件发生的率与实际发生的率是否相同的能力。本研究采用 O/E 比对模型的校准能力进行评价。O/E 比为所有研究对象某事件发生概率与所有研究对象的预测概率值总和之比值。

4. 预测模型简介

4.1 Cox 比例风险模型

Cox 比例风险回归模型是由英国统计学家 D.R Cox 于 1972 年提出的，其在基准风险率函数未知的情况下，可以估计模型参数，简称为 Cox 回归模型。其基本形式为： $h(t, X) = h_0(t) \exp(\beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_m X_m)$ 。其中 $X = (X_1, X_2, \dots, X_m)'$ 为预测因子，它们通过影响各个时刻的风险率而影响生存率； $h(t, X)$ 表示具有预测因子 X 的个体在时刻 t 时的风险函数； $h_0(t)$ 不需要假定服从特定的分布形状，表示所有预测因子取值均为 0 时的风险函数，即基准风险函数。通过样本数据对模型参数进行估计，Cox 回归模型需满足比例风险假定，即各预测因子的作用（ $h(t, X)/h_0(t)$ ）不随时间变化而变化。

借助偏似然函数，采用最大似然估计法，获得 Cox 比例风险回归模型的偏回归系数；采用 Breslow 非参数方法^[50]，估计基准风险 $h_0(t)$ 以及具有预测因子 $X = (X_1, X_2, \dots, X_m)$ 情况下的风险函数 $h(t, X)$ 。给定预测因子 $X = (X_1, X_2, \dots, X_m)$ 的情

况下, 在随访时间 $T \leq t$ 时间段内某结局事件发生的绝对风险是:

$$P(t) = 1 - S(t, X) \quad (6)$$

生存率与基准生存率 $S_0(t)$ 相关, 而基准生存率又与基准累计风险函数 $H_0(t)$ 相关, 即

$$S(t, X) = [S_0(t)]^{\exp(\beta X)} \quad (7)$$

$$\hat{S}_0(t) = \exp[-H_0(t)] \quad (8)$$

式(8)中 $H_0(t)$ 为 t 时刻的基准累计风险函数, 估计公式为:

$$\hat{H}_0(t) = \sum_{t_k < t_i} \frac{d_k}{\sum_{s \in R(t_1)} \exp(\beta' X_s)} \quad (9)$$

式(9)中 d_k 为在 t 时刻的死亡人数。

4.2 加法风险模型

非参数加法风险模型由挪威奥斯陆大学统计学家 Aalen 于 1989 年提出^[51, 52], 其基本形式如下:

$$h[t|z(t)] = h_0(t) + \sum_{j=1}^p \beta_j(t) z_j(t) = h_0(t) + \beta^T z(t) \quad (10)$$

其中, $h_0(t)$ 为基础风险函数, $Z(t) = [Z_1(t), Z_2(t), \dots, Z_p(t)]^T$ 是时依预测因子矩阵, $Z_j(t)$ 是第 j 个预测因子在时刻 t 的取值, $\beta^T = [\beta_1(t), \beta_2(t), \dots, \beta_p(t)]^T$ 为回归系数矩阵, 回归系数 $\beta_j(t)$ 表示在其它预测因子都不变的情况下, 预测因子 $Z_j(t)$ 每变化一个单位, 具有预测因子 $Z(t)$ 的个体在 t 时刻风险率 $h[t|z(t)]$ 的绝对变化量。Aalen 提出的非参数加法风险模型, 未假定回归函数的具体函数形式, 仅假定具有预测因子 $Z(t)$ 的个体任何时刻的风险率是基础风险与时依预测因子的线性组合, 因此属于非参数方法。

受非参数加法风险模型启发, D.Y.Lin 与 Z.Ying 于 1994 年提出半参数加法风险模型^[53, 54], 其基本形式如下:

$$h[t|z(t)] = h_0(t) + \sum_{j=1}^p \beta_j z_j(t) \quad (11)$$

其中, $h_0(t)$ 为基础风险函数, $Z_j(t)$ 是第 j 个预测因子在时刻 t 的取值, 回归系数 β_j 表示其他预测因子都不变的情况下, 自变量 $Z_j(t)$ 每变化一个单位, 具有预测因子 $Z(t)$ 的个体在 t 时刻风险率 $h[t|z(t)]$ 的绝对变化量。当预测因子与时间相

互独立时,模型构造类似于 Cox 比例风险模型,两模型回归系数均为常数,但半参数加法风险模型是定义在加性尺度上,而 Cox 比例风险模型是定义在乘积尺度上。半参数加法风险模型的参数估计是借鉴 Cox 比例风险模型中计数过程的鞅方法,利用偏极大似然函数法完成的^[55, 56]。

在本研究中,暂不考虑时依预测因子和交互作用,应用的半参数加法风险模型基本形式为:

$$h[t|z] = h_0(t) + \sum_{j=1}^p \beta_j z_j \quad (12)$$

则给定预测因子 $Z = (Z_1, Z_2, \dots, Z_p)$ 的情况下,在随访时间 $T \leq t$ 时间段内某结局事件发生的绝对风险,可参照 Cox 比例风险模型的计算方法进行估计。

4.3 指数回归模型

指数分布是最早广泛应用的一种生存分布类型,指数分布用常数来表示危险函数,其基本形式为:

$$h(t) = \lambda, \lambda > 0, t \geq 0 \quad (13)$$

其中,常数 λ 表示个体在 t 时刻的风险率, λ 作为模型参数决定着指数分布的分散度。具有预测因子 $X = (X_1, X_2, \dots, X_m)$ 的个体,在 t 时刻的风险函数 $h(t, X)$ 可表示为:

$$h(t, X) = \lambda \exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m) \quad (14)$$

采用极大似然估计方法,获取常数 λ 的估计值及偏回归系数向量 $\beta = (\beta_1, \beta_2, \dots, \beta_m)$,由此获得具有预测因子 $X = (X_1, X_2, \dots, X_m)$ 的个体在 t 时刻的风险函数 $h(t, X)$,则给定预测因子 $X = (X_1, X_2, \dots, X_m)$ 的情况下,在随访时间 $T \leq t$ 时间段内某结局事件发生的绝对风险可表示为:

$$P(t) = 1 - S(t, X) = 1 - \exp[-\lambda t \exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)] \quad (15)$$

4.4 Weibull 回归模型

Weibull 分布是目前应用最为广泛的一种生存分布类型,它能够对多种类型的生存数据进行描述。Weibull 回归模型危险率函数的基本形式为:

$$h(t) = \lambda \gamma (\lambda t)^{\gamma-1} \quad (16)$$

其中, $h(t)$ 表示个体在时刻 t 的危险率函数, λ 、 γ 分别为 Weibull 分布的尺度参

数和形状参数, λ 决定 Weibull 分布的分散度, γ 决定 Weibull 分布的形态。具有预测因子 $X = (X_1, X_2, \dots, X_m)$ 的个体, 在 t 时刻的危险率函数 $h(t, X)$ 可表示为:

$$h(t, X) = \lambda \gamma (\lambda t)^{\gamma-1} \exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m) \quad (17)$$

利用 Dempster 等提出的期望-最大值算法, 对含有删失的 Weibull 分布的参数进行估计, 获取模型参数 λ 、 γ 的估计值及偏回归系数向量 $\beta = (\beta_1, \beta_2, \dots, \beta_m)$; 由此, 获得基准风险函数 $h_0(t)$ 以及具有预测因子 $X = (X_1, X_2, \dots, X_m)$ 的个体, 在 t 时刻的风险函数 $h(t, X)$, 则给定预测因子 $X = (X_1, X_2, \dots, X_m)$ 的情况下, 在随访时间 $T \leq t$ 时间段内某结局事件发生的绝对风险可表示为:

$$P(t) = 1 - S(t, X) = 1 - \exp[-(\lambda t)^\gamma \exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)] \quad (18)$$

4.5 对数正态回归模型

对数正态分布是目前应用较为广泛的一种生存分布类型, 对生存时间 T 进行对数转换后, 若 $y = \log T$ 服从正态分布 $N(\mu, \sigma^2)$, 则 T 服从刻度参数为 μ 和形状参数为 σ^2 的对数正态分布, 其概率密度函数为:

$$f(t) = \frac{1}{\sqrt{2\pi}\sigma t} \exp\left[-\frac{1}{2}\left(\frac{\log t - \mu}{\sigma}\right)^2\right] \quad (19)$$

生存函数为:

$$S(t) = \int_1^\infty \frac{1}{\sqrt{2\pi}\sigma t} \exp\left[-\frac{1}{2}\left(\frac{\log t - \mu}{\sigma}\right)^2\right] dt \quad (20)$$

个体在时刻 t 的危险率函数表示为:

$$h(t) = \frac{f(t)}{S(t)} = \frac{\frac{1}{\sqrt{2\pi}\sigma t} \exp\left[-\frac{1}{2}\left(\frac{\log t - \mu}{\sigma}\right)^2\right]}{\int_1^\infty \frac{1}{\sqrt{2\pi}\sigma t} \exp\left[-\frac{1}{2}\left(\frac{\log t - \mu}{\sigma}\right)^2\right] dt} \quad (21)$$

则在给定预测因子 $X = (X_1, X_2, \dots, X_m)$ 的情况下, 在时间 $T \leq t$ 时间段内某结局事件发生的绝对风险可表示为:

$$\begin{aligned} P(t) &= 1 - S(t, X) = 1 - [S(t)]^{\exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)} \\ &= 1 - \left[\int_1^\infty \frac{1}{\sqrt{2\pi}\sigma t} \exp\left[-\frac{1}{2}\left(\frac{\log(t) - \mu}{\sigma}\right)^2\right] dt \right]^{\exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)} \end{aligned} \quad (22)$$

4.6 对数 logistic 回归模型

对数 logistic 分布也是应用较为广泛的一种生存分布类型, 对生存时间 T 进行对数转换后, 若 $y = \log T$ 服从 logistic 分布, 则 T 服从参数为 μ 和 σ 的对数 logistic 分布, 其概率密度函数为:

$$f(t|\mu, \sigma) = \frac{1}{\sigma t} \frac{e^z}{(1+e^z)^2}; \quad t \geq 0, \quad z = \frac{\log(x)-\mu}{\sigma} \quad (23)$$

生存函数为:

$$S(t) = \int_1^\infty \frac{1}{\sigma t} \frac{e^z}{(1+e^z)^2} dt \quad (24)$$

个体在时刻 t 的危险率函数表示为:

$$h(t) = \frac{f(t)}{S(t)} = \frac{\frac{1}{\sigma t} \frac{e^z}{(1+e^z)^2}}{\int_1^\infty \frac{1}{\sigma t} \frac{e^z}{(1+e^z)^2} dt} \quad (25)$$

则在给定预测因子 $X = (X_1, X_2, \dots, X_m)$ 的情况下, 随访时间 $T \leq t$ 时间段内某结局事件发生的绝对风险可表示为:

$$\begin{aligned} P(t) &= 1 - S(t, X) = 1 - [S(t)]^{\exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)} \\ &= 1 - \left[\int_1^\infty \frac{1}{\sigma t} \frac{e^z}{(1+e^z)^2} dt \right]^{\exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)} \end{aligned} \quad (26)$$

4.7 随机生存森林

本研究应用的随机生存森林算法分为两类:基于分类回归树的随机生存森林和基于条件推理树的随机森林(随机条件推理森林)。

分类回归树(classification and regression tree, CART)是 Breiman 等于 1984 年提出的一种基于现有数据进行建树,对数据观测进行分类的算法^[57],又被称为决策树。基于分类数据和连续数据建立的决策树,分别称为分类树与回归树。CART 可以从大量的候选变量中,筛选与结局相关的预测变量。其基本思想是,按照自上而下递归分裂的原则划分自变量。首先,从决策树包含所有观测对象的根节点开始,选择能够使节点不纯度改善最大的变量,作为该节点分枝变量;然后,根据节点不纯度最小的原则分裂为两个子节点,在子节点上按照相同的分裂原则继续分裂,直至满足预先设定的终止条件或没有样本可分而停止生长,使每个亚组内的异质性最小化。决策树的分裂准则,包括信息增益如熵或基尼值、信息增益率等;决策树终点停止条件,包括设定最小节点数据量、设定熵或基尼值的阈值、树的深度达到设定的上限及已无候选变量进行分裂而被动停止等。

条件推理树(conditional inference trees)也是一种基于树的分类算法,其与分类回归树的不同之处主要在于,根据相关的统计检验来进行预测因子与分割点的选择,即在假设所有预测因子与结局变量相互独立的基础上,再对它们进行关联性检验,设定检验显著性的阈值,则检验 p 值小于阈值的预测因子纳入模型,

相关性最强的预测因子作为第一分割点的分枝变量。预测因子选择好后,用置换检验来选择分割点。

随机森林 (random forests, RF) 是 Leo Breiman^[58]于 2011 年提出的一种基于决策树的分类器。其基本原理为通过 bootstrap 重抽样方法,从原始数据集中有放回地随机抽取 M 个观测个体,构成自助样本数据作为训练数据集,建立决策树;进而,应用基于训练集建立的决策树将未抽取的袋外数据 (out-of-bag data, OOB data) 进行分类,评价该树的袋外数据错分率。如此重复 N 次,则获得 N 个训练集及其决策树, N 个决策树组成随机森林,对新数据的预测结果根据随机森林中决策树的投票分数决定。

随机生存森林 (random survival forests, RSF) 是 Ishwaran^[59]于 2008 年在随机森林的基础上加以改进,提出的适用于右截尾生存数据的机器学习算法。与随机森林类似,首先通过 bootstrap 重抽样方法从原始数据集中有放回地随机抽取 N 个自助样本数据集,由此建立 N 个生存树组成随机生存森林,并将 N 个生存树的预测值进行综合,作为预测结果。在生存树生成过程中,对每个节点,只随机抽取部分候选变量作为分类该节点的预测变量;同时,考虑研究对象的生存时间与生存结局两个效应变量,基于最大化子节点生存差异的原则,进行节点分裂。其分裂准则包括 log-rank、事件守恒 (conserve)、log-rank 得分 (log-rank score) 以及随机的 log-rank (log-rank random)。随机生存森林中的每棵生存树都是二分类的生存树。整个生存森林的生存函数就是每棵树的生存函数的平均。

以基于分类回归树随机生存森林为例,介绍其计算步骤:①通过 bootstrap 重抽样方法从原始数据集中有放回地随机抽取 N 个自助样本数据集,在每个 bootstrap 抽样过程中,通常会有约 63% 的原始数据被抽到,构成自助样本数据集;而未被抽到的约 37% 的原始数据,称为袋外数据 (OOB data)。②利用自助样本数据集建立生存树,在树的每个节点随机抽取 q 个候选变量;基于使子节点生存差异最大的原则,在 q 个候选变量选择该节点的分枝变量;通常应用 Log-rank 检验统计量来作为分裂准则,也可根据具体情况选择其他分裂准则。③重复步骤 2,让生存树尽可能的生长,直到每个终节点的样本死亡数不小于设置的参数 node size。④计算每棵树的生存函数,整个随机生存森林的生存函数就是每棵树的生存函数的平均。研究中采用 Kaplan-Meier 估计法计算生存函数。

4.8 Super Learner

Super learner 是 van der laan^[43]等人, 于 2007 年提出的一种基于损失函数的组合预测的学习算法。Super learner 在交叉验证理论的基础上, 集成多种常规通用单一预测算法, 赋予不同单一预测值以不同的权重, 在 Super Learner 框架下, 找到一组使交叉验证风险最小的预测算法最佳组合。

假定当前数据结构为 $O = (W, A, Y) \sim P_0$, O 是代表具有随机变量观测的数据, 其概率分布为 P_0 ; Y 代表二分类结局, 如接受某种治疗方法后五年内是否死亡; $W = \{W_1, W_2, W_3\}$ 表示预测因子向量; A 表示是否接受某种治疗方式, 在多数情况下可将其视为协变量纳入预测因子向量 W 。在预测研究中, 研究者关心的概率分布为 $\bar{Q}_0(A, W) = P_0(Y = 1|A, W)$, 可以应用多种单一预测算法对其进行估计, 如支持向量机、随机森林、人工神经网络等机器学习算法以及 logistic 回归等参数统计模型等。在本研究中“算法”含义为: 算法 Q 将 n 个观测数据 $(W_i, A_i, Y_i), i = 1 \dots n$ 映射至一个预测函数, 可将输入的 (A, W) 映射为 Y 的预测值。这些算法可能在所用预测因子的子集、基础函数、损失函数、搜索算法和调整参数的范围等方面有所不同。使用一般意义上的算法, 来表示从数据到预测器的任何映射。只要算法 Q 能够依据观测数据输出一个拟合的预测函数, 就认为它是一种预测算法。例如, 一组算法可以包括最小二乘回归估计量、使用内部交叉验证来设置微调参数的算法、与筛选过程相结合以减小预测因子向量维数的算法等等。可以肯定的是, 对于特定的数据生成分布 P_0 , 某一个特定的算法要比其他候选估计更好。然而, 在现实世界中, 研究者并不知道先验使用哪一个算法可以得到最佳估计结果。

在选择最佳算法估计函数 $\bar{Q}_0: (A, W) \rightarrow \bar{Q}_0(A, W)$ 之前, 常用损失函数对候选算法 $\bar{Q}$ 的表现进行度量评价。从而, 定义一个最佳算法。该算法在所有候选算法 $\bar{Q}$ 中, 具有对应于该损失函数的最佳预期表现。给定损失函数 L 为 $L: (O, \bar{Q}) \rightarrow L(O, \bar{Q}) \in \mathbb{R}$, 常见的损失函数有 L_1 绝对误差损失函数 $L(O, \bar{Q}) = |Y - \bar{Q}(A, W)|$, L_2 平方误差损失函数 $L(O, \bar{Q}) = (Y - \bar{Q}(A, W))^2$, 适用于二分类因变量 Y 的负对数损失函数 $L(O, \bar{Q}) = -\log(\bar{Q}(A, W)^Y(1 - \bar{Q}(A, W))^{1-Y})$ 。将损失函数值称为风险, 定义最佳算法的过程即为风险最小化的过程。本研究主要进行预测研究, 应用 1 减去受试者工作特征曲线(receiver operator characteristic curve, ROC) 下面积(area under curve, AUC), 即 1-AUC 作为 Super learner 的风险值。

在离散 Super learner 构建过程中, 将对每个算法交叉验证的风险进行估计。整个数据集(学习集)被分为大小为 N/v 的 v 组, 这些组之间是互斥的。假定采用 10 折交叉验证, 则将整个数据集划分为 10 组, 分别命名为第 1、2...10 组。对于某一个算法, 保留第 1 组数据作为验证集, 将剩余的 9 组数据作为训练集。首先, 应用训练集对该算法的某些参数进行估计从而完成建模; 然后, 利用该算法对验证集进行预测, 得到相应因变量的预测概率。这样便可获得第一组大约 10% 的数据的预测概率。其中, 用于获得这些预测概率的预测函数是基于剩余 90% 的数据拟合的。在这个阶段, 使用预测的概率计算验证集内的风险。这一过程是针对所有算法集合中的单一预测算法执行的。因此, 可以用它们相应的预测概率计算每一个算法在验证集(第 1 组)内的风险。同时, 获得各个算法对验证集的预测概率。将上述过程再执行 9 次, 这样每一组数据都能够成为验证集, 可以获得每个单一预测算法的预测概率以及每个算法在该验证集中的风险。对每个算法在十个验证集的风险取平均, 得到该算法交叉验证风险。在算法集合中, 交叉验证风险最小的算法即为最佳算法, 称为离散的 Super learner。

离散的 Super learner 内部交叉验证, 可以防止过度拟合, 也可以防止模型选择偏倚。在 Super learner 中, 交叉验证有多种形式, 考虑到计算量大小, 本文选择 V -折交叉验证法。此外, 也可选用理想有限样本和渐近最优性法等。算法集合内的方法很多, 除了本研究拟采用的上述 8 种单一算法外, 还有众多的算法可供选择。例如, 深度神经网络、支持向量机等。

为了改进和提高离散 Super learner 效率, 可以构建一个包含所有算法加权平均值的算法库, 并预期这些加权平均值中的某一个可能比每个单独算法表现更好。基于此原则, 将一组候选算法映射到这些算法的加权平均值库中, 每个加权平均值均被视为扩充库中的单独算法; 然后, 应用交叉验证风险最小原则, 选择表现最佳的加权平均值。即, 需要在无限的一组候选算法(加权平均值)中, 依据风险最小化交叉验证的原则, 选择出“最佳”算法。用 $\hat{Q}_j, j = 1, 2, \dots, J$ 来表示含有 J 个候选算法的集合; 在 V -折交叉验证中, 用 $V(v) \subset \{1, \dots, n\}$ 及 $T(v) \subset \{1, \dots, n\}, v \in \{1, \dots, V\}$ 分别表示验证集与训练集; $\cup_{v=1}^V V(v) = \{1, \dots, n\}$ 表示全部验证集的集合, 即为完整数据集; $(Y_i, Z_i), i = 1, \dots, n$ 表示新数据集, 其中 $Z_i \equiv (Q_{njv(i)}(X_i): j =$

$1, \dots, J$) 表示在训练集中, 拟合的 J 个候选算法对验证集进行预测得到的预测值向量。为了描述方便, 用 $P_{n,Y,Z}$ 表示新数据集 $\{(Y_i, Z_i), i = 1, \dots, n\}$ 。则可以引入预测算法 $\tilde{Q}$, 根据数据集 $(Y_i, Z_i), i = 1, \dots, n$ 估计 Y 到 Z 的回归 $E(Y|Z)$; 该预测算法交叉验证风险表示为 $R_{cv}(\alpha) \equiv \sum_{i=1}^n (Y_i - m(Z_i|\alpha))^2$, 若 $m(Z_i|\alpha)$ 是线性回归模型, 则 $m(Z_i|\alpha) = \alpha z$; 如果 $Y \in [0,1]$, 预测算法可以用 logistic 回归模型 $m(z|\alpha) = 1/(1 + \exp(-\alpha z))$; 如果 $Y \in \{0,1\}$, 则 $m(z|\alpha_0, \alpha) \equiv I(1/(1+\exp(-\alpha z)) > \alpha_0)$, α_0 为截断值。利用最小二乘法或极大似然估计, 对权重向量进行估计, 也可以使用约束最小二乘回归估计, 如惩罚 L1 回归 (lasso)、惩罚 L2 回归。其中, 通过交叉验证或者限制非负权重总和为 1 来实现约束。此外, 除了拟合参数回归模型外, 还可以将针对特定数据的自适应回归算法 (机器学习), 应用到数据集 $P_{n,Y,Z}$, 如分类回归树、删除/替换/加法回归算法 (D/S/A) 以及多项式样条回归等。本研究应用 1-AUC 作为交叉验证风险, 通过基于 Nelder-Mead、quasi-Newton 和共轭梯度算法的通用优化方法, 获得的最优权重向量, 它包括一个框约束优化和模拟退火的选项, 可以利用非线性优化库 NLOpt 来实现。

Super learner 基本步骤如下: ①整理数据并选择相应的算法集合。②将数据随机分为 10 组, 为十折交叉验证做准备。③在训练集中拟合选择的算法, 建立预测模型, 并通过验证集得到预测概率。④在验证集中, 利用结局和预测概率计算风险(由相应的损失函数定义), 从而得到每一种算法的平均预测风险。⑤对选择的算法进行加权组合, 通过调整权重向量 α , 以期得到使交叉验证风险最小的算法组合。⑥在完整的数据集中拟合每个算法, 并与上一步中获得的权重相结合, 生成 Super learner 组合模型。图 1 为利用 Super learner 进行生存预测的简要示意图。




图 1 Super learner 进行生存预测简易流程图

5. 统计分析工具

本研究应用 R3.5.5 (<https://cran.r-project.org>)，进行数据描述和统计分析，连续型变量以 $\bar{X} \pm S$ 描述，分类变量以频数和构成比描述；采用“Hmisc”R 包计算 C-index；应用表 1 所示的 R 语言包构建 8 种单一预测模型及其 Super learner 组合预测模型。

表 1 构建预测模型所用的 R 包

预测模型	R 包
Cox 比例风险模型	survival
加法风险模型	timereg
Weibull 回归模型	rms
指数回归模型	rms
对数正态回归模型	rms
对数 logistic 回归模型	rms
随机生存森林	randomForestSRC
随机生存森林	pec
Super learner	Superlearner

结 果

1. 统计模拟结果

为了研究 Super learner 在不同分布、不同效应及不同预测因子相关结构的预测效果，本研究采用 Weibull 分布 ($\lambda=2, \gamma=1$)、指数分布 ($\lambda=10$) 两个分布类型产生了模拟数据。参照实际数据的协方差矩阵和各预测因子的效应，设定了三种不同的预测因子效应值向量，即效应向量 1、效应向量 2、效应向量 3，分别为：

$B1 = (\beta_1, \beta_2, \dots, \beta_8) = (0.0316, 0.2184, 0.1520, 0.0200, -1.5440, 0.4512, 0.4532, 0.2212)$

$B2 = (\beta_1, \beta_2, \dots, \beta_8) = (0.0200, 0.3988, 0.2776, 0.0100, -0.5798, 0.6152, 0.3988, 0.6881)$

$B3 = (\beta_1, \beta_2, \dots, \beta_8) = (0.0488, 0.6981, -0.4005, 0.0100, 0.1222, 0.4447, 0.4886, 0.8459)$

同时，基于上述 TCGA-COADREAD 结直肠癌病例随访队列和山东结直肠癌病例随访队列计算其协方差矩阵如表 2 和表 3 所示，用以模拟预测因子间的相关关系。基于上述设定产生样本量为 1000 的模拟数据。

表 2 基于 TCGA-COADREAD 病例随访队列的协方差矩阵估计

变量	变量 1	变量 2	变量 3	变量 4	变量 5	变量 6	变量 7	变量 8
变量 1	191.2843	-0.1054	1.6063	2.6124	0.0062	-11.9551	0.1519	1.1032
变量 2	-0.1054	0.0932	0.0159	0.0294	0.0002	-0.1312	-0.0043	0.0035
变量 3	1.6063	0.0159	0.3855	0.1240	0.0123	0.4910	-0.0188	0.0509
变量 4	2.6124	0.0294	0.1240	0.4857	0.0129	-0.8749	0.0190	0.1663
变量 5	0.0062	0.0002	0.0123	0.0129	0.0626	-0.1200	-0.0022	0.0113
变量 6	-11.9551	-0.1312	0.4910	-0.8749	-0.1200	173.7828	-0.9295	-0.2753
变量 7	0.1519	-0.0043	-0.0188	0.0190	-0.0022	-0.9295	0.1966	0.0052
变量 8	1.1032	0.0035	0.0509	0.1663	0.0113	-0.2753	0.0052	0.2441

表 3 基于山东结直肠癌病例随访队列的协方差矩阵估计

变量	变量 1	变量 2	变量 3	变量 4	变量 5	变量 6	变量 7	变量 8
变量 1	317.0558	0.1595	2.8671	2.3469	0.2531	2.8874	-0.2537	0.2994
变量 2	0.1595	0.1160	0.0280	0.0122	0.0000	-0.2720	-0.0213	-0.0019
变量 3	2.8671	0.0280	0.8361	0.1950	0.0561	0.2159	-0.0768	0.0192
变量 4	2.3469	0.0122	0.1950	0.5901	0.0181	-0.2335	0.0226	0.0319
变量 5	0.2531	0.0000	0.0561	0.0181	0.0834	-0.2643	-0.0078	0.0009
变量 6	2.8874	-0.2720	0.2159	-0.2335	-0.2643	139.2378	-0.0644	0.0291
变量 7	-0.2537	-0.0213	-0.0768	0.0226	-0.0078	-0.0644	0.2295	0.0009
变量 8	0.2994	-0.0019	0.0192	0.0319	0.0009	0.0291	0.0009	0.0429

1.1 训练集中不同删失率对模型预测效果的影响

仿照 TCGA-COADREAD 病例随访队列的分析结果，设定年龄、CEA 水平、T 分期、N 分期、肿瘤位置、组织学类型、神经/脉管浸润、送检淋巴结数据 8 个预测因子，上述预测因子的效应设定为效应向量 1。基于队列实际数据 TCGA-COADREAD 病例随访队列，估计各个预测因子的均值及其协方差矩阵，在 Weibull 分布中，设定参数 $\lambda=2$ 、 $\gamma=1$ ，产生删失率为 10%、20%、30%、40%、50%、60%、70%、80%和 90%的模拟生存数据作为训练集。同理，设定模拟产生独立验证集 1。

图 2 为随着训练集删失率变化，各种预测模型内部验证预测效果的变化趋势。由此可见，随着训练集删失率的增加，基于机器学习算法的随机生存森林与随机条件推理森林的判别准确性（C-index）逐渐升高；Super learner 的判别准确性在删失率超过 50%时 C-index 明显升高，其它预测模型判别准确性（C-index）变化幅度不大；除指数回归模型外，预测模型在训练集中的校准能力（O/E）随着训练集删失率基本保持不变，其中指数回归模型校准（O/E）逐渐降低，表现最差。




图 2 训练集删失率变化对模型内部验证预测效果的影响

图 3 为随着训练集删失率变化，各种预测模型外部验证预测效果的变化趋势。由此可见，随着训练集删失率的增加，各种预测模型在独立验证集中的判别准确性（C-index）逐渐降低。其中，基于机器学习算法的随机生存森林和随机条件推理森林下降幅度最大；当训练集删失率较低时，预测模型的在独立验证集中的校准能力（O/E）略偏离 1；随着训练集删失率逐渐增大，偏离幅度越来越大，表明其错估累计死亡风险；在训练集删失率一定的情况下，Super learner 判别准确性（C-index）和校准（O/E）均较好，略差于金标准模拟数据的 Weibull 分布。




图 3 训练集删失率变化对模型外部验证预测效果的影响

1.2 相同分布情况下不同模型的预测效果比较

仿照 TCGA-COADREAD 病例随访队列分析结果, 设定年龄、CEA 水平、T 分期、N 分期、肿瘤位置、组织学类型、神经/脉管浸润、送检淋巴结数目 8 个预测因子, 上述预测因子的效应设定为效应向量 1。基于 TCGA-COADREAD 病例随访队列实际数据, 估计各个预测因子的均值向量及协方差矩阵; 在 Weibull 分布中, 设定参数 $\lambda=2$ 、 $\gamma=1$ 模拟产生删失率为 20% 的模拟生存队列数据, 作为训练集。进而, 按相同分布和参数设置, 依据上述设定的三种效应向量、两种协方差矩阵, 模拟产生 6 个数据集, 作为独立验证集。即, 基于协方差矩阵 1 产生的数据集, 命名为数据 W11、数据 W12、数据 W13, 对应于变量效应向量 1 至 3; 基于协方差矩阵 2 产生的数据集, 命名为数据 W21、数据 W22、数据 W23, 对应于变量效应向量 1 至 3。在模拟产生的训练集中, 分别采用上述 8 种单一预测模型及其组合 Super learner 组合预测模型建立 9 个训练预测模型; 进而, 在上述 6 个独立验证集中, 进行模型外推泛化能力的检验。

表 4.1 和表 4.2 分别为所建立的 9 个训练预测模型在独立验证集中的预测准确性 (C-index) 和校准能力 (O/E)。由表 4.1 可见, 9 个预测模型表现出相似的判别准确性。由表 4.2 可见, 在 9 个预测模型中, 校准能力 (O/E) 最接近 1 的预测模型, 有对数正态回归模型、Super learner、随机生存森林、对数 logistic 回归模型。Super learner 组合预测模型, 在单一同分布的 Weibull 分布生存数据中, 并未显示出其独特优势。这是因为 Super learner 组合预测的优势是, 应对复杂的多分布混合数据内的复杂结构。此外, 由模拟结果可见, 即使对于相同分布产生的独立外推数据集, 各种预测模型在不同效应、不同变量相关结构数据集集中的预测效果也不尽相同: ①9 个预测模型在数据集 W11 中预测效果 (C-index 和 O/E) 最好, 在数据集 W13 中表现次之, 在数据集 W12 中表现最差; 这表明, 在同分布前提下, 预测因子效应的不同, 也会影响模型预测效果; ②在协方差矩阵结构不同的 W11 与 W21、W12 与 W22、W13 与 W23 外推数据集的模拟结果显示, 即使在同分布前提下, 预测因子间的相关关系不同, 也会对各种预测模型的预测效果产生影响。

表 4.1 预测模型在不同数据集中的预测准确性 C-index 及其 95%置信区间

模型	数据 W11	数据 W12	数据 W13	数据 W21	数据 W22	数据 W23
1	0.734(0.705,0.762)	0.707(0.679,0.735)	0.717(0.688,0.746)	0.740(0.709,0.772)	0.698(0.667,0.730)	0.692(0.658,0.726)
2	0.736(0.707,0.765)	0.707(0.679,0.736)	0.711(0.681,0.741)	0.743(0.712,0.774)	0.697(0.666,0.728)	0.686(0.652,0.719)
3	0.696(0.666,0.727)	0.668(0.638,0.697)	0.685(0.653,0.716)	0.680(0.645,0.715)	0.652(0.618,0.685)	0.647(0.611,0.683)
4	0.731(0.702,0.759)	0.705(0.677,0.733)	0.717(0.688,0.746)	0.743(0.712,0.775)	0.694(0.663,0.726)	0.695(0.662,0.729)
5	0.734(0.706,0.763)	0.710(0.682,0.738)	0.719(0.689,0.748)	0.741(0.710,0.773)	0.700(0.669,0.731)	0.694(0.661,0.728)
6	0.732(0.704,0.761)	0.711(0.683,0.739)	0.722(0.693,0.751)	0.742(0.710,0.773)	0.702(0.671,0.734)	0.698(0.665,0.732)
7	0.736(0.707,0.765)	0.708(0.680,0.736)	0.712(0.682,0.742)	0.743(0.712,0.775)	0.698(0.667,0.729)	0.687(0.654,0.721)
8	0.733(0.704,0.762)	0.708(0.679,0.736)	0.718(0.688,0.747)	0.743(0.711,0.774)	0.702(0.671,0.733)	0.698(0.665,0.732)
9	0.706(0.675,0.737)	0.686(0.656,0.715)	0.701(0.671,0.731)	0.707(0.674,0.740)	0.672(0.640,0.704)	0.666(0.632,0.701)

注：模型 1-9 分别代表 Super learner、Cox 比例风险模型、随机生存森林、加法风险模型、指数回归模型、对数正态回归模型、Weibull 回归模型、对数 logistic 回归模型和随机条件推理森林。

表 4.2 预测模型在不同数据集中的校准能力（O/E）

预测模型	数据 W11	数据 W12	数据 W13	数据 W21	数据 W22	数据 W23
Super learner	1.0389	1.2055	1.1091	1.0110	1.2061	1.0199
Cox 比例风险回归	1.1030	1.2798	1.1774	1.0591	1.2635	1.0684
随机生存森林	1.0421	1.2091	1.1124	1.0074	1.2018	1.0163
加法风险模型	1.1037	1.2807	1.1783	1.0832	1.2922	1.0927
指数回归模型	0.8746	1.0148	0.9336	0.8427	1.0054	0.8501
对数正态回归	0.9845	1.1424	1.0510	0.9560	1.1405	0.9644
Weibull 回归	1.0739	1.2460	1.1464	1.0326	1.2318	1.0416
对数 logistic 回归	1.0459	1.2136	1.1165	1.0148	1.2106	1.0237
随机条件推理森林	1.1372	1.3195	1.2139	1.1566	1.3798	1.1668

1.3 不同分布情况下不同模型的预测效果比较

仿照 TCGA-COADREAD 病例随访队列的分析结果，设定年龄、CEA 水平、T 分期、N 分期、肿瘤位置、组织学类型、神经/脉管浸润、送检淋巴结数目八个预测因子，上述预测因子的效应设定为效应向量 1。同时，基于该队列数据，估计预测因子的均值向量及其协方差矩阵，并在 Weibull 分布中设定参数 $\lambda=2$ 、 $\gamma=1$ ，产生删失率为 20%的模拟生存数据，作为训练集。进一步采用参数 $\lambda=10$ 的指数分布，依据上述设定的三种效应向量、两种协方差矩阵，模拟产生 6 个数据集作为独立验证集。即，基于协方差矩阵 1 产生的数据集，命名为数据 E11、数据 E12、数据 E13，对应于预测因子效应向量 1 至 3；基于协方差矩阵 2 产生的数据集，命名为数据 E21、数据 E22、数据 E23，对应于预测因子效应向量 1 至 3。基于

这些模拟数据集，分别采用上述 8 种单一预测模型及其组合 Super learner 组合预测模型建立 9 个训练预测模型；进而，在上述 6 个独立验证集中，进行模型外推泛化能力的检验。

表 5.1 和表 5.2 分别为所建立的 9 个训练预测模型在独立验证集中的预测准确性（C-index）和校准能力（O/E）。由表 5.1 可见，除随机生存森林和随机条件推理森林外，Super learner 组合预测模型与单一预测模型具有相似的判别准确性。相比而言，Super learner 组合预测模型表现出了较好的预测稳定性。

表 5.1 预测模型在不同数据集中的预测准确性 C-index 及其 95%置信区间

模型	数据 E11	数据 E12	数据 E13	数据 E21	数据 E22	数据 E23
1	0.729(0.701,0.757)	0.716(0.685,0.746)	0.717(0.687,0.746)	0.743(0.713,0.774)	0.697(0.663,0.731)	0.692(0.659,0.726)
2	0.731(0.703,0.759)	0.715(0.685,0.745)	0.711(0.681,0.741)	0.744(0.714,0.774)	0.695(0.661,0.729)	0.686(0.652,0.719)
3	0.693(0.662,0.724)	0.662(0.628,0.695)	0.653(0.619,0.687)	0.691(0.657,0.725)	0.648(0.611,0.685)	0.632(0.594,0.669)
4	0.727(0.698,0.755)	0.712(0.682,0.742)	0.717(0.689,0.746)	0.746(0.715,0.776)	0.692(0.658,0.727)	0.696(0.662,0.729)
5	0.729(0.701,0.758)	0.719(0.689,0.748)	0.719(0.690,0.748)	0.743(0.713,0.773)	0.698(0.664,0.732)	0.694(0.661,0.728)
6	0.727(0.699,0.756)	0.719(0.690,0.749)	0.722(0.693,0.751)	0.742(0.712,0.773)	0.701(0.666,0.735)	0.698(0.665,0.732)
7	0.731(0.703,0.759)	0.716(0.686,0.746)	0.713(0.683,0.742)	0.744(0.714,0.774)	0.696(0.662,0.730)	0.687(0.654,0.721)
8	0.727(0.699,0.756)	0.716(0.686,0.746)	0.718(0.689,0.748)	0.744(0.713,0.774)	0.700(0.666,0.734)	0.698(0.665,0.732)
9	0.696(0.667,0.725)	0.681(0.649,0.712)	0.689(0.658,0.720)	0.699(0.666,0.732)	0.658(0.622,0.694)	0.651(0.615,0.687)

注：模型 1-9 分别代表 Super learner、Cox 比例风险模型、随机生存森林、加法风险模型、指数回归模型、对数正态回归模型、Weibull 回归模型、对数 logistic 回归模型和随机条件推理森林

表 5.2 预测模型在不同分布的数据集中的预测效果（O/E）

预测模型	数据 E11	数据 E12	数据 E13	数据 E21	数据 E22	数据 E23
Super learner	1.0406	0.9624	1.0365	1.0241	0.9450	0.9575
Cox 比例风险模型	1.0788	0.9977	1.0745	1.0504	0.9693	0.9821
随机生存森林	1.0064	0.9308	1.0024	0.9805	0.9048	0.9168
加法风险模型	1.1428	1.0570	1.1383	1.1331	1.0456	1.0594
指数回归模型	0.9061	0.8381	0.9026	0.8828	0.8146	0.8254
对数正态回归	0.9880	0.9138	0.9841	0.9709	0.8959	0.9077
Weibull 回归	1.0571	0.9777	1.0529	1.0303	0.9508	0.9633
对数 logistic 回归	1.0241	0.9472	1.0200	1.0068	0.9291	0.9413
随机条件推理森林	1.1878	1.0986	1.1831	1.2249	1.1303	1.1452

由表 5.2 可见，Super learner 组合预测模型表现出稳健的校准能力（O/E 值接近 1）；而其它单一预测模型在不同结构的外推预测集中呈现出不稳健状态；此外，由模拟结果可见，对于不同分布的独立外推数据集，各种预测模型在不同

效应、不同变量相关结构数据集中的预测效果也不尽相同：①9个预测模型在数据集 E13、E12 中表现次之，这表明，在不同分布前提下，预测因子效应的不同，也会影响模型预测效果；②在协方差矩阵结构不同的 E11 与 E21、E12 与 E22、E13 与 E23 外推数据集的模拟结果显示，预测因子间的相关关系不同，也会对各模型的预测效果造成影响；③在风险分布不同的 W11 与 E11、W12 与 E12、W13 与 E13、W21 与 E21、W22 与 E22、W23 与 E23 外推数据集的模拟结果显示，风险分布不同，也会影响各模型的预测效果。

1.4 不同预测模型综合预测效果的比较

采用预测准确度（C-index）和校准能力（ $|1-O/E|$ ）的均数和标准差，描述和比较 9 种预测模型的预测效果。表 6.1 和表 6.2 分别是 9 种预测模型的预测准确度（C-index）和校准能力（ $|1-O/E|$ ）比较。由表 6.1 可见，Super learner 组合预测模型的预测效果较好，优于参数回归模型和半参数回归模型，仅次于随机生存森林和随机条件推理森林。而由表 6.2 可见，除随机生存森林和随机条件推理森林外，Super learner 组合预测模型外推验证准确性与其他模型基本一致，Super learner 判别准确性（C-index）为 0.715，与加法风险模型相同，在 9 个预测模型中排第四位，但 Super learner 的 C-index 标准差更小；Super learner 外推校准能力（O/E）的综合评价指标 $|1-O/E|$ 为 0.069，在 9 个预测模型中居第二位。

表 6.1 各预测模型训练集内部验证预测效果

预测模型	C-index (95%CI)	O/E
Super learner	0.776 (0.746,0.806)	1.064
Cox 比例风险模型	0.711 (0.675,0.747)	1.015
加法风险模型	0.711 (0.675,0.746)	1.021
随机生存森林	0.906 (0.889,0.923)	1.029
指数回归模型	0.711 (0.676,0.747)	1.273
对数正态回归模型	0.712 (0.677,0.747)	1.061
Weibull 回归模型	0.711 (0.675,0.747)	1.037
对数 logistic 回归模型	0.712 (0.677,0.747)	1.122
随机条件推理森林	0.810 (0.784,0.837)	0.996

表 6.2 各预测模型外部验证预测效果综合评价

预测模型	C-index		1-O/E	
	均值	标准差	均值	标准差
Super learner	0.715	0.018	0.069	0.068
加法风险模型	0.715	0.019	0.134	0.082
随机条件推理森林	0.684	0.019	0.195	0.081
Cox 比例风险模型	0.713	0.021	0.100	0.092
指数回归模型	0.717	0.018	0.112	0.059
对数 logistic 回归模型	0.717	0.017	0.072	0.072
对数正态回归模型	0.718	0.016	0.064	0.048
Weibull 回归模型	0.714	0.020	0.085	0.079
随机生存森林	0.667	0.021	0.072	0.073

2. 结直肠癌预后预测模型的研究结果

本研究共收集和整理了 5 个结直肠癌预后数据库，包括山东结直肠癌数据、TCGA-COADREAD 数据、GSE40967、GSE41258 和 R 语言“survival”包结肠癌数据。由于每个数据集来源不同，包含的变量也不尽相同，所以本研究基于不同预测因子组合构建了 6 对训练集与测试集（表 7），用上述 9 种预测模型建模，考核模型的预测价值和外推泛化能力。表 8 为各实例验证数据集变量赋值表。

表 7 各实例验证数据集基本情况

模型	训练集			验证集		
	数据名称	人数	中位随访时间 (月)	数据名称	人数	中位随访时间(月)
1	省立结直肠癌数据	2087	23.02 (15.00-35.80)	COADRECD 数据	282	22.88 (11.77-35.12)
2	R-colon 数据	886	65.73 (27.51-78.66)	省立结肠癌数据	1168	24.58 (13.11-38.41)
3	省立结直肠癌数据	2390	23.50 (12.99-35.26)	COADRECD 数据	416	24.46 (13.98-37.26)
4	GSE40967	324	65.00 (35.00-87.00)	GSE41258	181	66.00 (25.00-106.00)
5	GSE40967	494	53.00 (27.25-81.00)	COAD 数据	423	24.00 (12.85-37.22)
6	省立结肠癌数据	1632	24.18 (13.08-36.97)	GSE40967	540	55.00 (29.00-83.00)

表 8 各实例验证数据集变量赋值表

变量名	变量标签	赋值
cea	术前癌胚抗原（mmol/L）	连续型变量
age	年龄（岁）	连续型变量
location	肿瘤位置	0=结肠；1=直肠；
nodes	送检淋巴结数目（个）	0 < 10 个；1 ≥ 10 个；
invasion	脉管或神经浸润	0=否；1=是；
nstage	N 分期	0=N0；1=N1；2=N2；
tstage	T 分期	1=T1；2 T2；3 T3；4 T4；
pnodes	阳性淋巴结数目（个）	连续型变量
extent	浸润深度	1=粘膜下层；2=肌层；3=浆膜；4=浆膜外
node4	阳性淋巴结超过 4 个	0=否；1=是；
perfor	分化程度	1=高分化；2=中分化；3=低分化；
chemo	是否接受辅助化疗	0=否；1=是；
nodes	送检淋巴结数目	连续型变量
matage	是否远处转移	0=否；1=是；
histype	组织学类型	0=腺癌；1=粘液腺癌
mmr	微卫星不稳定性	0=否；1=是；
p53	p53 基因突变	0=否；1=是；

2.1 基于第一组结直肠癌预后队列的预测模型及其评价

2.1.1 队列的描述性分析

以本课题组构建的结直肠癌预后队列为训练集，TCGA-COADREAD 队列为验证集。在该组结直肠癌预后队列中，训练集共纳入 2087 人，中位随访时间为 23.02 [Interquartile range, (IQR), 15.00-35.80] 月，随访期间共有 326（15.62%）人死于结直肠癌及其并发症。验证集共纳入 282 人，中位随访时间为 22.88（IQR, 15.00-35.80）月，随访期间共有 32（11.34%）人死于结直肠癌及其并发症。

表 9.1 为第一组结直肠癌预后队列的基线分布特征。在训练队列中，患者平均确诊年龄为 60.15±11.68 岁；在验证队列中，患者平均确诊年龄 65.27±13.07 岁；在验证队列中，患者平均确诊年龄高于训练集患者（ $t=6.81, P<0.001$ ）。在训练队列中，患者平均 CEA 水平为 10.15±17.86 mmol/L；在验证队列中，患者平均 CEA 水平为 6.86±13.51 mmol/L；训练集中患者平均 CEA 水平高于验证集患者（ $t=2.98, P<0.001$ ）。在训练队列中，结肠癌 746 例（35.75%），直肠癌 1341 例（64.25%）；在验证队列中，结肠癌 208 例（73.76%），直肠癌 74 例（26.24%）；两个数据集中结肠癌与直肠癌构成不同（ $\chi^2 = 981.06, P<0.001$ ）。除组织学类型和送检淋巴结数目外，，T 分期、N 分期、神经/脉管浸润在两数据间的差异均有

统计学意义 ($P<0.05$)。

表 9.1 第一组结直肠癌预后队列的基线分布特征

基线变量	训练集($n=2087$)	验证集($n=282$)	t/χ^2	P
年龄(岁)	60.15±11.68	65.27±13.07	6.81	<0.001
CEA (mmol/L)	10.15±17.86	6.86±13.51	2.98	<0.001
T 分期[n (%)]			290.06	<0.001
T1	115 (5.51)	12 (4.26)		
T2	315 (15.09)	58 (20.57)		
T3	508 (24.34)	194 (68.79)		
T4	1149 (55.06)	18 (6.38)		
N 分期[n (%)]			9.15	0.010
N0	1239 (59.37)	177 (62.77)		
N1	471 (22.57)	74 (26.24)		
N2	377 (18.06)	31 (10.99)		
肿瘤位置[n (%)]			981.06	<0.001
结肠	746 (35.75)	208 (73.76)		
直肠	1341 (64.25)	74 (26.24)		
组织学类型[n (%)]			2.39	0.122
腺癌	1803 (86.39)	253 (89.72)		
粘液腺癌	284 (13.61)	29 (10.28)		
神经/脉管浸润[n (%)]			841.21	<0.001
否	1989 (95.30)	168 (59.57)		
是	98 (4.70)	114 (40.43)		
送检淋巴结数目[n (%)]			1.47	0.226
<10	194 (9.30)	20 (7.09)		
≥10	1893 (90.70)	262 (92.91)		

2.1.2 训练队列和验证队列的常规生存分析

在训练队列中，结直肠癌患者的 3 年生存率为 81.78%（95%CI：79.53%~84.10%），5 年生存率为 65.66%（95%CI：61.85%~69.72%）；在验证集中，其 3 年生存率为 89.92%（95%CI：85.53%~94.52%），5 年生存率为 69.36%（95%CI：56.52%~85.10%）。图 4A 和图 4B 分别是该组结直肠癌预后队列中训练队列与验证队列的累积死亡率曲线。

表 9.2 是采用 Cox 模型筛选预测因子的结果。由此可见，单因素 Cox 比例风险回归分析显示，年龄、CEA 水平、N 分期、T 分期、肿瘤位置、组织学类型、神经/脉管浸润、送检淋巴结数目与结直肠癌预后相关 ($P<0.05$)；多因素 Cox 比例风险回归分析显示，上述因素均与结直肠癌术后生存有关 ($P<0.05$)。




图 4 第一组结直肠癌预后队列的训练队列(A)与验证队列(B)的结直肠癌累计死亡率曲线

表 9.2 采用 Cox 比例风险回归模型筛选预测变量的结果

变量	单因素 Cox 分析			多因素 Cox 分析		
	RR	95%CI	P	RR	95%CI	P
年龄	1.02	(1.01,1.03)	<0.001	1.02	(1.01,1.04)	< 0.001
CEA	1.02	(1.01,1.02)	<0.001	1.01	(1.01,1.01)	< 0.001
T 分期						
T1	Ref			Ref		
T2	1.30	(0.53,3.19)	0.561	1.28	(0.52,3.14)	0.597
T3	2.62	(1.13,6.06)	0.025	2.21	(0.94,5.22)	0.069
T4	4.48	(1.99,10.07)	<0.001	3.08	(1.34,7.12)	0.008
N 分期						
N0	Ref			Ref		
N1	2.44	(1.86,3.21)	<0.001	1.96	(1.48,2.60)	< 0.001
N2	4.59	(3.53,5.97)	<0.001	3.42	(2.56,4.55)	< 0.001
肿瘤位置						
结肠	Ref			Ref		
直肠	1.21	(0.96,1.53)	0.106	1.33	(1.04,1.69)	0.022
组织学类型						
腺癌	Ref			Ref		
粘液腺癌	1.42	(1.07,1.90)	0.017	1.49	(1.11,2.01)	0.008
神经/脉管浸润						
否	Ref			Ref		
是	3.62	(2.53,5.19)	<0.001	2.00	(1.37,2.91)	< 0.001
送检淋巴结数目						
<10	Ref			Ref		
≥10	0.72	(0.53,0.98)	0.035	0.56	(0.41,0.78)	< 0.001

2.1.3 结直肠癌预后预测模型的构建及其评价

基于上述 Cox 比例风险回归分析结果，结合专业知识，最终确定的预测因子包括年龄、CEA 水平、N 分期、T 分期、肿瘤位置、组织学类型、神经/脉管浸

润和送检淋巴结数目。考虑到训练队列与验证队列中，结直肠癌的中位随访时间均为 2 年左右，因此该组队列中，设定结直肠癌预后预测模型的预测年限为 2 年和 3 年。表 9.3 是 9 种结直肠癌预后预测模型的预测效果（C-index、O/E）比较结果。

表 9.3 9 种结直肠癌预后预测模型的预测效果（C-index、O/E）比较

预测年限	预测模型	训练集		验证集	
		C-index (95%CI)	O/E	C-index (95%CI)	O/E
2	Super learner	0.823 (0.794,0.853)	0.999	0.800 (0.726,0.875)	1.074
2	Cox 比例风险模型	0.762 (0.726,0.798)	0.997	0.803 (0.727,0.878)	1.017
2	随机生存森林	0.974 (0.969,0.979)	0.999	0.759 (0.675,0.844)	1.117
2	加法风险模型	0.772 (0.735,0.810)	0.996	0.793 (0.718,0.867)	1.088
2	指数回归模型	0.762 (0.726,0.798)	1.023	0.801 (0.723,0.880)	1.039
2	对数正态回归模型	0.768 (0.732,0.804)	1.000	0.814 (0.746,0.882)	1.063
2	Weibull 回归模型	0.762 (0.725,0.798)	0.996	0.802 (0.726,0.878)	1.015
2	对数 logistic 回归模型	0.769 (0.733,0.805)	1.005	0.810 (0.740,0.880)	1.046
2	随机条件推理森林	0.848 (0.822,0.875)	0.996	0.796 (0.715,0.876)	1.053
3	Super learner	0.823 (0.798,0.847)	0.998	0.813 (0.744,0.881)	1.113
3	Cox 比例风险模型	0.762 (0.730,0.794)	0.995	0.808 (0.734,0.881)	1.086
3	随机生存森林	0.770(0.737,0.802)	0.998	0.749 (0.667,0.830)	1.158
3	加法风险模型	0.955 (0.948,0.962)	0.970	0.810 (0.746,0.874)	1.114
3	指数回归模型	0.762 (0.730,0.794)	1.002	0.806 (0.730,0.883)	1.087
3	对数正态回归模型	0.768 (0.736,0.800)	1.006	0.819 (0.753,0.885)	1.156
3	Weibull 回归模型	0.762 (0.730,0.793)	0.999	0.807 (0.733,0.881)	1.088
3	对数 logistic 回归模型	0.768 (0.737,0.800)	1.007	0.815 (0.747,0.883)	1.138
3	随机条件推理森林	0.830 (0.804,0.856)	0.994	0.803 (0.726,0.879)	1.111

当预测年限为 2 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、Weibull 回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.823、0.762、0.974、0.772、0.762、0.768、0.762、0.769、0.848，O/E 分别为 0.999、0.997、0.996、0.999、1.023、1.000、0.996、1.005、0.996；在验证队列中，Super learner、Cox 比例风险模型及对数 logistic 回归模型的 C-index 和 O/E 比分别为 0.800、0.803、0.814 和 1.074、1.017、1.046。

当预测年限为 3 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.823、0.762、0.955、0.770、0.762、0.768、0.762、0.768、0.830，O/E 分别为 0.998、0.995、0.970、

0.998、1.002、1.006、0.999、1.007、0.994；在验证队列中，Super learner、Cox 比例风险模型及对数正态回归模型的 C-index 和 O/E 比分别为 0.813、0.808、0.819 和 1.113、1.086、1.138。表 9.4 是 Super learner 中各预测算法权重系数。

表 9.4 Super learner 中各预测算法权重系数

预测年限	预测模型	权重系数
2	Cox 比例风险模型	0.0277
2	随机生存森林	0.0510
2	加法风险模型	0.5917
2	指数回归模型	0.0000
2	对数正态回归模型	0.0541
2	Weibull 回归模型	0.0000
2	对数 logistic 回归模型	0.2081
2	随机条件推理森林	0.0673
3	Cox 比例风险模型	0.1352
3	随机生存森林	0.0813
3	加法风险模型	0.1434
3	指数回归模型	0.1830
3	对数正态回归模型	0.1383
3	Weibull 回归模型	0.1485
3	对数 logistic 回归模型	0.1289
3	随机条件推理森林	0.0414

2.2 基于第二组结直肠癌预后队列的预测模型及其评价

2.2.1 队列的描述性分析

以 R 语言 “survival” 包里的结肠癌预后队列为训练集，山东结肠癌预后队列作为验证集。在该组结肠癌队列中，训练集共纳入 886 人，中位随访时间为 65.73 (IQR, 27.51-78.66) 月，随访期间共有 428 (48.31%) 人死于结直肠癌及其并发症。验证集共纳入 1168 人，中位随访时间为 24.58 (IQR, 13.11-38.41) 月，随访期间共有 184 (15.75%) 人死于结直肠癌及其并发症。

在训练队列中，患者平均确诊年龄为 59.81±11.92 岁；在验证队列中，患者平均确诊年龄 59.89±13.17 岁；验证队列的患者平均确诊年龄与训练队列的患者相当 ($t=-0.14, P=0.444$)。在训练队列中，患者平均阳性淋巴结数目为 4.64±3.39 个；在验证队列中，患者平均阳性淋巴结数目为 1.51±2.87 个；训练集患者平均阳性淋巴结数目高于验证集患者 ($t=22.63, P<0.001$)。在训练队列中，接受辅助化疗的患者占比 65.58%，高于验证队列中，接受辅助化疗患者占比 46.83% ($\chi^2=71.49, P<0.001$)。在训练队列中，高分化程度、中分化程度、低分化程度患

者分别占比 10.16%、73.70%、14.14%；而在验证队列中，高分化程度、中分化程度、低分化程度患者分别占比 6.68%、71.40%、21.92%，两队列中的分化程度构成不同 ($\chi^2=16.48, P<0.001$)。表 10.1 为第二组结肠癌预后队列的基线特征描述。

表 10.1 第二组结肠癌预后队列的基线分布特征

变量	训练集(n=886)	验证集(n=1168)	t/ χ^2	P
年龄(岁)	59.81±11.92	59.89±13.17	-0.14	0.444
阳性淋巴结数目(个)	4.64±3.39	1.51±2.87	22.63	<0.001
T 分期[n(%)]			780.51	<0.001
T1	19 (2.14)	28 (2.40)		
T2	102 (11.51)	82 (7.02)		
T3	728 (82.17)	316 (27.05)		
T4	37 (4.18)	742 (63.53)		
辅助化疗[n(%)]			71.49	<0.001
否	305 (34.42)	621 (53.17)		
是	581 (65.58)	547 (46.83)		
分化程度[n(%)]			16.48	<0.001
高分化	90 (10.16)	78 (6.68)		
中分化	653 (73.70)	834 (71.40)		
低分化	143 (16.14)	256 (21.92)		
送检淋巴结数目>4[n(%)]			41.30	<0.001
否	651 (73.48)	992 (84.93)		
是	235 (26.52)	176 (15.07)		

2.2.2 训练队列与验证队列的常规生存分析

在训练队列中，3 年生存率为 67.81%（95%CI：64.80%~70.96%），5 年生存率为 56.93%（95%CI：53.75%~60.29%）；在验证队列中，3 年生存率为 83.42%（95%CI：80.74%~86.19%），5 年生存率为 70.47%（95%CI：66.00%~75.24%）。

图 5A 和图 5B 分别是训练队列和验证队列的结肠癌累计死亡率曲线。




图 5 第二组结肠癌预后队列的训练队列(A)与验证队列(B)的结肠癌累计死亡率曲线

表 10.2 是采用 Cox 回归模型筛选预测因子的结果。可见，单因素 Cox 比例风险回归分析显示，阳性淋巴结数目、T 分期、分化程度、辅助化疗、送检淋巴结数目>4 与结直肠癌预后相关 ($P<0.05$)；在多因素 Cox 回归分析中，阳性淋巴结数目、T 分期、辅助化疗、送检淋巴结数目>4 与结直肠癌术后预后显示有统计学意义 ($P<0.05$)，而年龄与分化程度无统计学意义 ($P>0.05$)。

表 10.2 采用 Cox 比例风险回归筛选预测因子的结果

变量	单因素 Cox 分析			多因素 Cox 分析		
	RR	95%CI	P	RR	95%CI	P
年龄	1.00	(0.99,1.01)	0.501	1.01	(1.00,1.02)	0.099
阳性淋巴结数目	1.12	(1.09,1.14)	<0.001	1.06	(1.02,1.10)	0.003
T 分期						
T1	Ref			Ref		
T2	2.41	(0.74,7.84)	0.144	1.94	(0.59,6.31)	0.274
T3	4.24	(1.36,13.21)	0.013	3.20	(1.02,10.02)	0.045
T4	6.81	(2.05,22.63)	0.002	4.54	(1.35,15.20)	0.014
辅助化疗						
否	Ref			Ref		
是	0.80	(0.66,0.97)	0.024	0.78	(0.64,0.94)	0.011
分化程度						
高分化	Ref			Ref		
中分化	1.04	(0.75,1.44)	0.824	0.86	(0.62,1.19)	0.366
低分化	1.57	(1.08,2.29)	0.018	1.11	(0.75,1.62)	0.609
送检淋巴结数目>4						
否	Ref			Ref		
是	2.63	(2.16,3.20)	<0.001	1.81	(1.33,2.46)	<0.001

2.2.3 结肠癌预后预测模型的构建及其评价

根据上述 Cox 比例风险回归分析结果，结合专业知识纳入预测模型构建的预测因子包括年龄、阳性淋巴结数目、T 分期、分化程度、辅助化疗、送检淋巴结数目>4。考虑到验证队列中位随访时间均为 2 年左右，该组结直肠癌预后预测模型的预测年限为 2 年和 3 年。表 10.3 是 9 种结直肠癌预后预测模型的预测效果 (C-index、O/E) 比较结果。

表 10.3 是 9 种结直肠癌预后预测模型的预测效果（C-index、O/E）比较

预测 年限	算法	训练集		验证集	
		C-index (95%CI)	O/E	C-index (95%CI)	O/E
2	Super learner	0.761 (0.732,0.791)	0.985	0.732 (0.685,0.780)	1.177
2	Cox 比例风险模型	0.691 (0.656,0.727)	1.001	0.730 (0.682,0.778)	1.197
2	随机生存森林	0.931 (0.920,0.942)	1.000	0.555 (0.501,0.610)	1.553
2	加法风险模型	0.698 (0.662,0.734)	1.003	0.741 (0.694,0.788)	1.159
2	指数回归模型	0.690 (0.655,0.726)	0.976	0.729 (0.681,0.777)	1.158
2	对数正态回归模型	0.696 (0.661,0.731)	0.970	0.735 (0.687,0.783)	1.172
2	Weibull 回归模型	0.690 (0.655,0.726)	0.962	0.729 (0.681,0.777)	1.137
2	对数 logistic 回归模型	0.698 (0.662,0.733)	0.970	0.733 (0.686,0.781)	1.175
2	随机条件推理森林	0.755 (0.724,0.786)	0.999	0.705 (0.656,0.754)	1.137
3	Super learner	0.765 (0.741,0.789)	0.973	0.723 (0.680,0.766)	1.292
3	Cox 比例风险模型	0.675 (0.645,0.705)	1.004	0.727 (0.684,0.771)	1.332
3	随机生存森林	0.900 (0.887,0.913)	0.998	0.574 (0.526,0.622)	1.626
3	加法风险模型	0.679 (0.648,0.709)	1.007	0.733 (0.690,0.775)	1.252
3	指数回归模型	0.675 (0.645,0.705)	0.945	0.727 (0.683,0.770)	1.235
3	对数正态回归模型	0.679 (0.649,0.709)	0.951	0.730 (0.687,0.773)	1.269
3	Weibull 回归模型	0.674 (0.644,0.704)	0.934	0.727 (0.683,0.770)	1.216
3	对数 logistic 回归模型	0.680 (0.650,0.710)	0.951	0.729 (0.686,0.772)	1.277
3	随机条件推理森林	0.734 (0.707,0.761)	0.999	0.701 (0.658,0.744)	1.213

当预测年限为 2 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.761、0.691、0.931、0.698、0.69、0.696、0.69、0.698、0.755，O/E 分别为 0.985、1.001、1.003、1.000、0.976、0.970、0.962、0.970、0.999；在验证队列中，Super learner、Cox 比例风险模型及加法风险模型的 C-index 和 O/E 比分别为 0.732、0.730、0.741 和 1.177、1.197、1.159。

当预测年限为 3 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.765、0.675、0.900、0.679、0.675、0.679、0.674、0.68、0.734，O/E 分别为 0.973、1.004、1.007、0.998、0.945、0.951、0.934、0.951、0.999；在验证队列中，Super learner、Cox 比例风险模型及对数正态回归模型的 C-index 和 O/E 比分别为 0.723、0.727、0.733 和 1.292、1.332、1.252。表 10.4 是 Super learner 中各预测算法权重系数。

表 10.4 Super learner 中各预测算法权重系数

预测年限	预测模型	权重系数
2	Cox 比例风险模型	0.1249
2	随机生存森林	0.0556
2	加法风险模型	0.1554
2	指数回归模型	0.1297
2	对数正态回归模型	0.1222
2	Weibull 回归模型	0.1303
2	对数 logistic 回归模型	0.1111
2	随机条件推理森林	0.1707
3	Cox 比例风险模型	0.1277
3	随机生存森林	0.1198
3	加法风险模型	0.1377
3	指数回归模型	0.1186
3	对数正态回归模型	0.1354
3	Weibull 回归模型	0.1186
3	对数 logistic 回归模型	0.1262
3	随机条件推理森林	0.1160

2.3 基于第三组结直肠癌预后队列的预测模型及其评价

2.3.1 队列的描述性分析

以本课题组构建的结直肠癌预后队列为训练集，TCGA-COADREAD 队列为验证集。在该组结直肠癌预后队列中，训练集共纳入 2390 人，中位随访时间为 23.50（IQR, 12.99-35.26）月，随访期间共有 495（20.71%）人死于结直肠癌及其并发症。验证集共纳入 416 人，中位随访时间为 24.46（IQR, 13.98-37.26）月，随访期间共有 73（17.55%）人死于结直肠癌及其并发症。

在训练集中，患者平均确诊年龄为 59.81±11.98 岁，在验证集中，患者平均确诊年龄 65.50±12.86 岁；验证集患者平均确诊年龄高于训练集患者（ $t=-8.84$ ， $P<0.001$ ）。在训练集中，患者平均 CEA 水平为 20.81±83.00 mmol/L，在验证集中，患者平均 CEA 水平为 33.78±139.18mmol/L；训练集中患者平均 CEA 水平低于验证集患者（ $t=-2.61$ ， $P<0.001$ ）。在训练集中，患者平均送检淋巴结数目为 15.37±4.78 个，在验证集中，患者平均阳性淋巴结数目为 24.24±12.40 个；训练集中患者平均阳性淋巴结数目低于验证集患者（ $\chi^2=-25.69$ ， $P<0.001$ ）。除远处转移和 N 分期在两数据间无统计学差异外，T 分期和组织学类型均有统计学意义（ $P<0.05$ ）。表 11.1 为训练集与验证集基线变量一般情况。

表 11.1 第三组结直肠癌预后队列的基线分布特征

变量	训练集(n=2390)	验证集(n=416)	t/χ^2	P
年龄(岁)	59.81±11.98	65.50±12.86	-8.84	<0.001
送检淋巴结数目(个)	15.37±4.78	24.24±12.40	-25.69	<0.001
CEA (mmol/L)	20.81±83.00	33.78±139.18	-2.61	0.009
T 分期[n (%)]			401.16	<0.001
T1	84 (3.51)	12 (2.88)		
T2	336 (14.06)	72 (17.31)		
T3	569 (23.81)	288 (69.23)		
T4	1401 (58.62)	44 (10.58)		
N 分期[n (%)]			5.94	0.051
N0	1336 (55.90)	230 (55.29)		
N1	545 (22.80)	114 (27.40)		
N2	509 (21.30)	72 (17.310)		
远处转移[n (%)]			0.64	0.424
否	2075 (13.18)	350 (84.13)		
是	315 (86.82)	66 (15.87)		
组织学类型[n (%)]			4.59	0.032
腺癌	2056 (86.03)	374 (89.90)		
粘液腺癌	334 (13.97)	42 (10.10)		

2.3.2 训练队列和验证队列的常规生存分析

在训练队列中,结直肠癌患者3年生存率为76.05%(95%CI: 73.82%~78.34%),5年生存率为60.06%(95%CI: 56.53%~63.82%);在验证队列中,其3年生存率为85.89%(95%CI: 82.07%~89.89%),5年生存率为63.48%(95%CI: 54.52%~73.91%)。图6A和图6B分别是该组结直肠癌预后队列中训练队列与验证队列的累计死亡率曲线。




图 6 第三组结直肠癌预后队列的训练队列(A)与验证队列(B)的结直肠癌累计死亡率曲线

表 11.2 是采用 Cox 模型筛选预测因子的结果。由此可见,单因素 Cox 比例风险回归分析显示,年龄、送检淋巴结数目、CEA、T 分期、N 分期、远处转移、组织学类型与结直肠癌预后相关 ($P<0.05$);在多因素 Cox 回归分析中,年龄、

送检淋巴结数目、CEA、T 分期、N 分期、远处转移与结直肠癌术后预后显示有统计学意义 ($P<0.05$), 而组织学类型无统计学意义 ($P>0.05$)。

表 11.2 采用 Cox 比例风险回归模型筛选预测变量的结果

变量	单因素 Cox 分析			多因素 Cox 分析		
	RR	95%CI	P	RR	95%CI	P
年龄	1.01	(1.00,1.02)	0.006	1.02	(1.01,1.03)	<0.001
送检淋巴结数目	0.99	(0.97,1.00)	0.099	1.00	(1.00,1.00)	<0.001
CEA	1.003	(1.003,1.004)	<0.001	1.002	(1.002,1.003)	0.002
T 分期						
T1	Ref			Ref		
T2	0.76	(0.34,1.68)	0.496	0.72	(0.33,1.61)	0.427
T3	1.74	(0.84,3.60)	0.139	1.25	(0.60,2.61)	0.558
T4	3.81	(1.89,7.67)	<0.001	2.02	(1.00,4.12)	0.046
N 分期						
N0	Ref			Ref		
N1	2.62	(2.08,3.30)	<0.001	2.01	(1.59,2.54)	<0.001
N2	5.23	(4.23,6.47)	<0.001	3.44	(2.73,4.33)	<0.001
是否远处转移						
否	Ref			Ref		
是	4.58	(3.80,5.51)	<0.001	2.75	(2.25,3.36)	<0.001
组织学类型						
腺癌	Ref			Ref		
粘液腺癌	1.32	(1.04,1.67)	0.025	1.23	(0.96,1.57)	0.095

2.3.3 结直肠癌预后预测模型的构建及其评价

根据上述 Cox 比例风险回归分析结果, 结合专业知识纳入预测模型构建的预测因子包括年龄、送检淋巴结数目、CEA、T 分期、N 分期、远处转移、组织学类型。考虑到训练队列与验证队列中位随访时间均为 2 年左右, 该组结直肠癌预后预测模型的预测年限为 2 年和 3 年。

表 11.3 是 9 种结直肠癌预后预测模型的预测效果 (C-index、O/E) 比较结果。由此可见, 当预测年限为 2 年时, 在训练队列中, Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.870、0.785、0.962、0.786、0.784、0.785、0.785、0.786、0.854, O/E 分别为 0.994、0.993、0.997、1.002、1.012、0.983、0.980、0.990、0.994; 在验证队列中, Super learner、

Cox 比例风险模型及对数正态回归模型的 C-index 和 O/E 比分别为 0.814、0.809、0.813 和 1.007、0.998、1.000。

表 11.3 9 种结肠直肠癌预后预测模型的预测效果（C-index、O/E）比较

预测 年限	算法	训练集		验证集	
		C-index (95%CI)	O/E	C-index (95%CI)	O/E
2	Super learner	0.870 (0.855,0.885)	0.994	0.814 (0.756,0.871)	1.007
2	Cox 比例风险模型	0.785 (0.760,0.811)	0.993	0.809 (0.749,0.869)	0.998
2	随机生存森林	0.962 (0.956,0.967)	1.002	0.781 (0.715,0.847)	1.060
2	加法风险模型	0.786 (0.761,0.812)	0.997	0.792 (0.727,0.857)	1.011
2	指数回归模型	0.784 (0.759,0.810)	1.012	0.807 (0.747,0.867)	1.012
2	对数正态回归模型	0.785 (0.760,0.811)	0.983	0.813 (0.756,0.871)	1.000
2	Weibull 回归模型	0.785 (0.760,0.811)	0.980	0.809 (0.749,0.869)	0.987
2	对数 logistic 回归模型	0.786 (0.761,0.811)	0.990	0.810 (0.751,0.869)	0.987
2	随机条件推理森林	0.854 (0.836,0.872)	0.994	0.791 (0.729,0.853)	1.005
3	Super learner	0.877 (0.864,0.891)	0.986	0.816 (0.759,0.872)	1.077
3	Cox 比例风险模型	0.785 (0.762,0.808)	0.989	0.812 (0.754,0.870)	1.054
3	随机生存森林	0.942 (0.935,0.949)	0.999	0.794 (0.730,0.857)	1.111
3	加法风险模型	0.788 (0.765,0.810)	0.964	0.804 (0.747,0.861)	1.084
3	指数回归模型	0.784 (0.761,0.807)	0.988	0.810 (0.752,0.868)	1.054
3	对数正态回归模型	0.785 (0.762,0.807)	0.993	0.816 (0.761,0.872)	1.071
3	Weibull 回归模型	0.785 (0.762,0.808)	0.988	0.812 (0.754,0.870)	1.053
3	对数 logistic 回归模型	0.785 (0.763,0.808)	0.996	0.813 (0.756,0.870)	1.054
3	随机条件推理森林	0.846 (0.829,0.864)	0.989	0.796 (0.734,0.859)	1.070

当预测年限为 3 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.877、0.785、0.942、0.788、0.784、0.785、0.785、0.785、0.846，O/E 分别为 0.986、0.989、0.964、0.999、0.988、0.993、0.988、0.996、0.989；在验证队列中，Super learner、Cox 比例风险模型及对数正态回归模型的 C-index 和 O/E 比分别为 0.816、0.812、0.816 和 1.077、1.054、1.071。表 11.3 是各预后预测模型预测效果（C-index、O/E），表 11.4 是 Super learner 中各预测算法权重系数。

表 11.4 Super learner 中各预测算法权重系数

预测年限	预测算法	权重系数
2	Cox 比例风险模型	0.1250
2	随机生存森林	0.1264
2	加法风险模型	0.1252
2	指数回归模型	0.1247
2	对数正态回归模型	0.1245
2	Weibull 回归模型	0.1251
2	对数 logistic 回归模型	0.1245
2	随机条件推理森林	0.1247
3	Cox 比例风险模型	0.0952
3	随机生存森林	0.2068
3	加法风险模型	0.2125
3	指数回归模型	0.0715
3	对数正态回归模型	0.1076
3	Weibull 回归模型	0.0839
3	对数 logistic 回归模型	0.0000
3	随机条件推理森林	0.2226

2.4 基于第四组结直肠癌预后队列的预测模型及其评价

2.4.1 队列的描述性分析

以 GEO 数据库中下载的 GSE40967 数据作为训练集，GSE41258 数据作为验证集。在该组结直肠癌预后队列中，训练集共纳入 324 人，中位随访时间为 65.00（IQR, 35.00-87.00）月，随访期间共有 118（36.42%）人死于结直肠癌及其并发症。验证集共纳入 181 人，中位随访时间为 66.00（IQR, 25.00-106.00）月，随访期间共有 93（51.38%）人死于结直肠癌及其并发症。

在训练集中，患者平均确诊年龄为 66.78±13.09 岁；在验证集中，患者平均确诊年龄 63.23±13.88 岁；验证集患者平均确诊年龄高于训练集患者（ $t=2.83$ ， $P=0.005$ ）。在训练集中，有 10.69%的患者发生远处转移，10.69%患者存在微卫星不稳定性，54.40%的患者存在 p53 基因突变，而在验证集中，发生远处转移的患者占比 32.20%，存在微卫星不稳定性的患者占比 19.21%，存在 p53 基因突变的患者占比 66.10%，上述变量构成情况在两数据集间均存在统计学差异（ $P<0.05$ ）。在训练集中，T 分期为 T2、T3、T4 的患者分别占比 8.18%、73.58%、18.24%，而验证集中分别为 19.21%、73.45、7.34；T 分期构成在两数据集间不同（ $\chi^2=20.40$ ， $P<0.001$ ）。N 分期构成情况在两数据集间无统计学差异（ $P>0.05$ ）。表 12.1 为第四组结直肠癌预后队列的基线分布特征。

表 12.1 第四组结直肠癌预后队列的基线分布特征

变量	训练集(n=318)	验证集(n=177)	t/ χ^2	P
年龄(岁)	66.78±13.09	63.23±13.88	2.83	0.005
T 分期[n (%)]			20.40	<0.001
T2	26 (8.18)	34 (19.21)		
T3	234 (73.58)	130 (73.45)		
T4	58 (18.24)	13 (7.34)		
N 分期[n (%)]			1.61	0.448
N0	155 (48.74)	89 (50.28)		
N1	96 (30.19)	45 (25.42)		
N2	67 (21.07)	43 (24.29)		
远处转移[n (%)]			35.07	<0.001
否	284 (89.31)	120 (67.8)		
是	34 (10.69)	57 (32.20)		
微卫星不稳定[n (%)]			6.96	0.008
否	284 (89.31)	143 (80.79)		
是	34 (10.69)	34 (19.21)		
p53 突变[n (%)]			6.41	0.011
否	145 (45.60)	60 (33.90)		
是	173 (54.40)	117 (66.10)		

2.4.2 训练队列与验证队列的常规生存分析

在训练队列中，结直肠癌患者的3年生存率为79.18%（95%CI：74.76%~83.86%），5年生存率为68.14%（95%CI：63.01%~73.68%）；在验证队列中，其3年生存率为70.86%（95%CI：64.36%~78.01%），5年生存率为62.73%（95%CI：55.81%~70.51%）。图7A和图7B分别是该组结直肠癌预后队列中训练队列与验证队列的累计死亡率曲线。




图 7 第四组结直肠癌预后队列的训练队列(A)与验证队列(B)的结直肠癌累计死亡率曲线

表 12.2 是采用 Cox 模型筛选预测因子的结果。由此可见，单因素 Cox 比例

风险回归分析显示，年龄、N 分期、远处转移与结直肠癌预后相关 ($P<0.05$)；在多因素 Cox 模型回归分析中，年龄、N 分期、远处转移与结直肠癌术后预后存在统计学意义 ($P<0.05$)，而 T 分期、微卫星稳定性及 p53 突变在多因素 Cox 比例风险回归分析中无统计学意义 ($P>0.05$)。

表 12.2 采用 Cox 比例风险回归模型筛选预测变量的结果

变量	单因素 Cox 分析			多因素 Cox 分析		
	RR	95%CI	P	RR	95%CI	P
年龄	1.03	(1.01,1.05)	<0.001	1.04	(1.02,1.06)	<0.001
T 分期						
T2	Ref			Ref		
T3	1.22	(0.56,2.64)	0.614	1.12	(0.51,2.43)	0.783
T4	2.08	(0.91,4.77)	0.084	1.77	(0.74,4.19)	0.197
N 分期						
N0	Ref			Ref		
N1	1.24	(0.80,1.91)	0.337	0.93	(0.58,1.49)	0.768
N2	2.35	(1.51,3.65)	<0.001	1.79	(1.09,2.91)	0.020
是否远处转移						
否	Ref			Ref		
是	4.40	(2.81,6.90)	<0.001	4.00	(2.40,6.67)	<0.001
微卫星不稳定性						
否	Ref			Ref		
是	0.70	(0.35,1.38)	0.299	0.64	(0.31,1.31)	0.220
p53 突变						
否	Ref			Ref		
是	1.21	(0.84,1.75)	0.307	1.16	(0.79,1.72)	0.446

2.4.3 结直肠癌预后预测模型的构建及其评价

根据上述 Cox 比例风险回归分析结果，结合专业知识，预后预测模型纳入的预测因子包括年龄、N 分期、远处转移、T 分期、微卫星不稳定性、p53 突变。考虑到训练队列与验证队列中位随访时间均为 5 年左右，该组结直肠癌预后预测模型的预测年限为 3 年和 5 年。

表 12.3 是 9 种结直肠癌预后预测模型的预测效果 (C-index、O/E) 比较结果。由此可见，当预测年限为 3 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.747、0.724、0.944、0.725、0.724、0.731、0.724、0.731、0.795，O/E 分别为 0.908、0.912、0.913、0.908、0.908、0.907、0.903、0.909、0.910；在验证队列中，Super learner、

Cox 比例风险模型及随机条件推理森林的 C-index 和 O/E 比分别为 0.836、0.790、0.855 和 0.866、0.857、0.873。

当预测年限为 5 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.775、0.703、0.918、0.705、0.703、0.706、0.703、0.706、0.770，O/E 分别为 0.856、0.862、0.863、0.861、0.850、0.852、0.848、0.853、0.861；在验证队列中，Super learner、Cox 比例风险模型及随机条件推理森林的 C-index 和 O/E 比分别为 0.818、0.777、0.821 和 0.878、0.872、0.886。表 12.3 是各预后预测模型预测效果（C-index、O/E），表 12.4 是 Super learner 中各预测算法权重系数。

表 12.3 9 种结直肠癌预后预测模型的预测效果（C-index、O/E）比较

预测 年限	算法	训练集		验证集	
		C-index (95%CI)	O/E	C-index (95%CI)	O/E
3	Super learner	0.747 (0.682,0.812)	0.908	0.836 (0.794,0.879)	0.866
3	Cox 比例风险模型	0.724 (0.656,0.793)	0.912	0.790 (0.734,0.846)	0.857
3	随机生存森林	0.944 (0.928,0.960)	0.908	0.823 (0.770,0.877)	0.919
3	加法风险模型	0.725 (0.655,0.794)	0.913	0.844 (0.803,0.884)	0.870
3	指数回归模型	0.724 (0.656,0.792)	0.908	0.792 (0.736,0.848)	0.853
3	对数正态回归模型	0.731 (0.662,0.800)	0.907	0.825 (0.777,0.872)	0.867
3	Weibull 回归模型	0.724 (0.656,0.792)	0.903	0.792 (0.736,0.848)	0.848
3	对数 logistic 回归模型	0.731 (0.662,0.800)	0.909	0.821 (0.772,0.871)	0.867
3	随机条件推理森林	0.795 (0.742,0.847)	0.910	0.855 (0.813,0.897)	0.873
5	Super learner	0.775 (0.728,0.821)	0.856	0.818 (0.777,0.859)	0.878
5	Cox 比例风险模型	0.703 (0.646,0.760)	0.862	0.777 (0.727,0.827)	0.872
5	随机生存森林	0.918 (0.899,0.936)	0.861	0.795 (0.745,0.846)	0.929
5	加法风险模型	0.705 (0.647,0.762)	0.863	0.820 (0.778,0.861)	0.875
5	指数回归模型	0.703 (0.646,0.760)	0.850	0.779 (0.729,0.829)	0.858
5	对数正态回归模型	0.706 (0.649,0.764)	0.852	0.810 (0.767,0.853)	0.871
5	Weibull 回归模型	0.703 (0.646,0.759)	0.848	0.779 (0.729,0.829)	0.857
5	对数 logistic 回归模型	0.706 (0.648,0.764)	0.853	0.806 (0.762,0.851)	0.874
5	随机条件推理森林	0.770 (0.725,0.815)	0.861	0.822 (0.779,0.864)	0.886

表 12.3 Super learner 中各预测算法权重系数

预测年限	预测模型	权重系数
3	Cox 比例风险模型	0.0783
3	随机生存森林	0.0000
3	加法风险模型	0.1972
3	指数回归模型	0.0724
3	对数正态回归模型	0.1913
3	Weibull 回归模型	0.0724
3	对数 logistic 回归模型	0.1516
3	随机条件推理森林	0.2368
5	Cox 比例风险模型	0.0955
5	随机生存森林	0.1024
5	加法风险模型	0.1374
5	指数回归模型	0.0835
5	对数正态回归模型	0.1648
5	Weibull 回归模型	0.0835
5	对数 logistic 回归模型	0.1643
5	随机条件推理森林	0.1686

2.5 基于第五组结直肠癌预后队列的预测模型及其评价

2.5.1 队列的描述性分析

以 GEO 数据库中下载的 GSE40967 数据作为训练集，TCGA-COAD 数据作为验证集。在该组结直肠癌队列中，训练集共纳入 494 人，中位随访时间为 53.00（IQR, 27.25-81.00）月，随访期间共有 158（31.98%）人死于结直肠癌及其并发症。验证集共纳入 423 人，中位随访时间为 24.00（IQR, 12.85-37.22）月，随访期间共有 89（21.04%）人死于结直肠癌及其并发症。

在训练队列中，患者平均确诊年龄为 66.79±13.44 岁，验证集患者平均确诊年龄 67.01±12.83 岁；验证集患者平均确诊年龄与训练集患者相当（ $t=-0.25$ ， $P=0.802$ ）。在训练队列中，有 11.34%的患者发生远处转移，14.17%患者存在微卫星不稳定性，而在验证队列中，发生远处转移的患者占比 15.50%，存在微卫星不稳定性患者占比 17.43%，上述变量构成情况在两数据集间均存在统计学差异（ $P<0.05$ ）。在训练队列中，T 分期为 T1、T2、T3、T4 的患者分别占比 2.43%、9.31%、68.42%、19.84%，而在验证队列中，其分别为 1.94%、16.71%、70.70%、10.65%，T 分期构成在两数据集间不同（ $\chi^2=22.24$ ， $P<0.001$ ）。在训练队列中，N 分期为 N1、N2、N3 的患者分别占比 52.23%、27.94%、19.84%，而在验证队

列中，其分别为 60.77%、22.03%、17.19%，N 分期构成情况在两数据集间不同 ($\chi^2=6.88, P=0.032$)。表 13.1 为第五组结直肠癌预后队列的基线分布特征描述。

表 13.1 第五组结直肠癌预后队列的基线分布特征

变量	训练集(n=494)	验证集(n=413)	t/χ^2	P
年龄(岁)	66.79±13.44	67.01±12.83	-0.25	0.802
T 分期[n (%)]			22.24	<0.001
T1	12 (2.43)	8 (1.94)		
T2	46 (9.31)	69 (16.71)		
T3	338 (68.42)	292 (70.70)		
T4	98 (19.84)	44 (10.65)		
N 分期[n (%)]			6.88	0.032
N0	258 (52.23)	251 (60.77)		
N1	138 (27.94)	91 (22.03)		
N2	98 (19.84)	71 (17.19)		
是否远处转移[n (%)]			3.39	0.066
否	438 (88.66)	349 (84.50)		
是	56 (11.34)	64 (15.50)		
微卫星不稳定性[n (%)]			1.81	0.178
否	424 (85.83)	341 (82.57)		
是	70 (14.17)	72 (17.43)		

2.5.2 训练队列与验证队列的常规生存分析

在训练队列中，3 年生存率为 79.20% (95%CI: 75.55%~80.03%)，5 年生存率为 68.14% (95%CI: 63.01%~73.68%)；在验证队列中，3 年生存率为 81.30% (95%CI: 77.00%~85.84%)，5 年生存率为 62.73% (95%CI: 55.81%~70.51%)。图 8A 和图 8B 分别是第五组结直肠癌预后队列中训练队列与验证队列的累计死亡率曲线。




图 8 第五组结直肠癌预后队列的训练队列(A)与验证队列(B)的结直肠癌累计死亡率曲线

表 13.2 是采用 Cox 回归模型筛选预测因子的结果。由此可见，单因素 Cox 比例风险回归分析显示，年龄、T 分期、N 分期、远处转移与结直肠癌预后相关 ($P<0.05$)；在多因素 Cox 回归分析中，年龄、N 分期、远处转移与结直肠癌术后预后存在统计学意义 ($P<0.05$)，而 T 分期、微卫星稳定性无统计学意义 ($P>0.05$)。

表 13.2 采用 Cox 比例风险回归模型筛选预测因子的结果

变量	单因素 Cox 分析			多因素 Cox 分析		
	RR	95%CI	P	RR	95%CI	P
年龄	1.03	(1.01,1.04)	<0.001	1.04	(1.02,1.05)	<0.001
T 分期						
T1	Ref			Ref		
T2	2.32	(0.29,18.59)	0.427	1.82	(0.23,14.60)	0.574
T3	3.82	(0.53,27.41)	0.182	2.67	(0.37,19.28)	0.329
T4	7.47	(1.03,54.20)	0.047	4.36	(0.59,32.11)	0.148
N 分期						
N0	Ref			Ref		
N1	1.33	(0.91,1.94)	0.139	0.98	(0.66,1.45)	0.901
N2	2.32	(1.59,3.37)	<0.001	1.70	(1.13,2.54)	0.010
是否远处转移						
否	Ref			Ref		
是	5.08	(3.48,7.41)	<0.001	4.85	(3.16,7.44)	<0.001
微卫星不稳定性						
否	Ref			Ref		
是	0.70	(0.35,1.38)	0.299	0.82	(0.49,1.38)	0.458

2.5.3 结直肠癌预后预测模型的构建及其评价

根据上述 Cox 比例风险回归分析结果，结合专业知识，预后预测模型纳入的预测因子包括年龄、N 分期、远处转移、T 分期、微卫星稳定性。考虑到验证队列中位随访时间均为 2 年左右，该组结直肠癌预后预测模型的预测年限为 2 年和 3 年。

表 13.3 是 9 种结直肠癌预后预测模型的预测效果 (C-index、O/E) 比较效果。由此可见，当预测年限为 2 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.750、0.733、0.951、0.74、0.733、0.735、0.734、0.737、0.808，O/E 分别为 0.948、0.947、0.948、0.945、0.953、0.946、0.945、0.949、0.947；在验证队列中，Super learner、Cox

比例风险模型及加法风险模型的 C-index 和 O/E 比分别为 0.779、0.774、0.781 和 0.921、0.921、0.916。

当预测年限为 3 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.816、0.742、0.922、0.746、0.742、0.745、0.742、0.748、0.807，O/E 分别为 0.913、0.918、0.917、0.917、0.912、0.907、0.905、0.910、0.918；在验证队列中，Super learner、Cox 比例风险模型及加法风险模型的 C-index 和 O/E 比分别为 0.770、0.771、0.785 和 0.973、0.980、0.975。表 13.3 是各预后预测模型预测效果（C-index、O/E），表 13.4 是 Super learner 中各预测模型权重系数。

表 13.3 9 种结直肠癌预后预测模型的预测效果（C-index、O/E）比较

预测 年限	算法	训练集		验证集	
		C-index (95%CI)	O/E	C-index (95%CI)	O/E
2	Super learner	0.750 (0.687,0.814)	0.948	0.781 (0.721,0.841)	0.921
2	Cox 比例风险模型	0.733 (0.665,0.801)	0.947	0.774 (0.714,0.835)	0.921
2	随机生存森林	0.951 (0.936,0.966)	0.945	0.674 (0.602,0.746)	0.920
2	加法风险模型	0.740 (0.675,0.806)	0.948	0.781 (0.721,0.841)	0.916
2	指数回归模型	0.733 (0.665,0.802)	0.953	0.775 (0.715,0.836)	0.927
2	对数正态回归模型	0.735 (0.667,0.802)	0.946	0.775 (0.714,0.836)	0.924
2	Weibull 回归模型	0.734 (0.665,0.802)	0.945	0.776 (0.716,0.837)	0.920
2	对数 logistic 回归模型	0.737 (0.670,0.804)	0.949	0.775 (0.714,0.836)	0.922
2	随机条件推理森林	0.808 (0.760,0.856)	0.947	0.758 (0.690,0.826)	0.918
3	Super learner	0.816 (0.777,0.855)	0.913	0.775 (0.717,0.833)	0.973
3	Cox 比例风险模型	0.742 (0.688,0.796)	0.918	0.774 (0.715,0.832)	0.980
3	随机生存森林	0.922 (0.904,0.939)	0.917	0.674 (0.605,0.743)	0.979
3	加法风险模型	0.746 (0.694,0.799)	0.917	0.790 (0.735,0.845)	0.975
3	指数回归模型	0.742 (0.688,0.795)	0.912	0.774 (0.716,0.833)	0.972
3	对数正态回归模型	0.745 (0.692,0.799)	0.907	0.774 (0.716,0.833)	0.970
3	Weibull 回归模型	0.742 (0.688,0.796)	0.905	0.775 (0.717,0.833)	0.964
3	对数 logistic 回归模型	0.748 (0.695,0.800)	0.910	0.774 (0.715,0.832)	0.967
3	随机条件推理森林	0.807 (0.766,0.847)	0.918	0.759 (0.697,0.821)	0.981

表 13.4 Super learner 中各预测模型权重系数

预测年限	预测模型	权重系数
2	Cox 比例风险模型	0.0599
2	随机生存森林	0.0000
2	加法风险模型	0.1797
2	指数回归模型	0.1797
2	对数正态回归模型	0.1198
2	Weibull 回归模型	0.1797
2	对数 logistic 回归模型	0.1198
2	随机条件推理森林	0.1612
3	Cox 比例风险模型	0.1286
3	随机生存森林	0.0975
3	加法风险模型	0.1187
3	指数回归模型	0.1347
3	对数正态回归模型	0.1325
3	Weibull 回归模型	0.1338
3	对数 logistic 回归模型	0.1280
3	随机条件推理森林	0.1263

2.6 基于第六组结直肠癌预后队列的预测模型及其评价

2.6.1 队列的描述性分析

以本课题组构建的结直肠癌预后队列作为训练集，GEO 数据库中下载的 GSE40967 数据作为验证集。在该组结直肠癌预后队列中，训练集共纳入 1632 人，中位随访时间为 24.18（IQR, 13.08-36.97）月，随访期间共有 402（24.63%）人死于结直肠癌及其并发症。验证集共纳入 540 人，中位随访时间为 55.00（IQR, 29.00-83.00）月，随访期间共有 173（32.04%）人死于结直肠癌及其并发症。

在训练队列中，患者平均确诊年龄为 59.53±13.28 岁，在验证队列中，患者平均确诊年龄 66.59±13.39 岁，验证队列的患者平均确诊年龄高于训练集患者（ $t=10.69, P<0.001$ ）。在训练集队列中，有 19.61%的患者发生远处转移，53.37%患者接受辅助化疗，而在验证队列中发生远处转移的患者占比 10.93%，接受辅助化疗的患者占比 41.48%，上述变量构成情况在两数据集间均存在统计学差异（ $P<0.05$ ）。在训练队列中，T 分期为 T1、T2、T3、T4 的患者分别占比 2.51%、5.58%、24.69%、67.22%，而在验证队列中，其分别为 2.22%、8.52%、68.15%、21.11%，T 分期构成在两数据集间不同（ $\chi^2=376.25, P<0.001$ ）。N 分期构成情况在两数据集间无统计学意义（ $\chi^2=0.30, P=0.860$ ）。表 14.1 为第六组结直肠癌预

后队列的基线特征描述。

表 14.1 第六组结直肠癌预后队列的基线分布特征

变量	训练集(n=1632)	验证集(n=494)	t/ χ^2	P
年龄(岁)	59.53±13.28	66.59±13.39	10.69	<0.001
T 分期[n (%)]			376.25	<0.001
T1	41 (2.51)	12 (2.22)		
T2	91 (5.58)	46 (8.52)		
T3	403 (24.69)	368 (68.15)		
T4	1097 (67.22)	114 (21.11)		
N 分期[n (%)]			0.30	0.860
N0	909 (55.70)	301 (55.74)		
N1	409 (25.06)	140 (25.93)		
N2	314 (19.24)	99 (18.33)		
是否远处转移[n (%)]			21.17	<0.001
否	1312 (80.39)	481 (89.07)		
是	320 (19.61)	59 (10.93)		
辅助化疗[n (%)]			22.94	<0.001
否	761 (46.63)	316 (58.52)		
是	871 (53.37)	224 (41.48)		

2.6.2 训练队列与验证队列的常规生存分析

在训练队列中，3 年生存率 79.84%（95%CI： 76.39%~83.45%），5 年生存率 70.30%（95%CI： 66.24%~74.60%）；在验证队列中，3 年生存率 73.00%（95%CI： 70.32%~75.79%），5 年生存率为 56.61%（95%CI： 52.66%~60.86%）。图 9A 和图 9B 分别是第六组结直肠癌预后队列中训练队列和验证队列的累计死亡率曲线。




图 9 第六组结直肠癌预后队列的训练队列(A)和验证队列(B)的结直肠癌累计死亡率曲线

表 14.2 是采用 Cox 回归模型筛选预测因子的结果。可见，单因素 Cox 比例

风险回归分析显示，年龄、T 分期、N 分期、远处转移、辅助化疗与结直肠癌预后相关 ($P<0.05$)；在多因素 Cox 回归分析中，年龄、N 分期、远处转移、辅助化疗与结直肠癌术后预后存在统计学意义 ($P<0.05$)，而 T 分期无统计学意义 ($P>0.05$)。

表 14.2 采用 Cox 比例风险回归筛选预测因子的结果

变量	单因素 Cox 分析			多因素 Cox 分析		
	RR	95%CI	P	RR	95%CI	P
年龄	1.01	(1.00,1.02)	0.018	1.01	(1.00,1.02)	0.002
T 分期						
T1	Ref			Ref		
T2	1.13	(0.23,5.60)	0.881	0.87	(0.18,4.34)	0.869
T3	3.07	(0.75,12.54)	0.119	1.71	(0.41,7.01)	0.459
T4	6.76	(1.68,27.16)	0.007	3.02	(0.75,12.22)	0.121
N 分期						
N0	Ref			Ref		
N1	2.73	(2.15,3.48)	<0.001	2.31	(1.81,2.97)	< 0.001
N2	4.34	(3.41,5.52)	<0.001	3.10	(2.41,3.98)	< 0.001
是否远处转移						
否	Ref			Ref		
是	4.22	(3.46,5.14)	<0.001	3.40	(2.73,4.22)	< 0.001
辅助化疗						
否	Ref			Ref		
是	1.32	(1.08,1.62)	0.006	0.80	(0.64,1.00)	0.045

2.6.3 结直肠癌预后预测模型的构建及其评价

根据上述 Cox 比例风险回归分析结果，结合专业知识，预测模型纳入的预测因子包括年龄、N 分期、远处转移、T 分期、辅助化疗。考虑到验证队列中位随访时间均为 2 年左右，该组结直肠癌预后预测模型的预测年限为 2 年和 3 年。

表 14.3 是 9 种结直肠癌预后预测模型的预测效果 (C-index、O/E) 比较结果。由此可见，当预测年限为 2 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.749、0.749、0.869、0.743、0.749、0.75、0.749、0.749、0.772，O/E 分别为 1.093、1.096、1.071、1.101、1.093、1.093、1.084、1.101、1.098；在验证队列中，Super learner、Cox

比例风险模型及随机条件推理森林的 C-index 和 O/E 比分别为 0.734、0.735、0.744 和 0.994、0.999、0.990。

当预测年限为 3 年时，在训练队列中，Super learner、Cox 比例风险模型、加法风险模型、随机生存森林、指数回归模型、对数正态回归模型、对数 logistic 回归模型及基于条件推理树的随机森林的 C-index 分别为 0.783、0.749、0.878、0.744、0.749、0.75、0.749、0.75、0.776，O/E 分别为 0.977、0.980、0.958、0.984、0.977、0.977、0.969、0.984、0.982；在验证队列中，Super learner、Cox 比例风险模型及随机条件推理森林的 C-index 和 O/E 比分别为 0.725、0.720、0.733 和 0.990、0.987、0.990。表 14.3 是各预后预测模型预测效果（C-index、O/E），表 14.4 是 Super learner 中各预测算法权重系数。

表 14.3 9 种结直肠癌预后预测模型的预测效果（C-index、O/E）比较

预测 年限	算法	训练集		验证集	
		C-index (95%CI)	O/E	C-index (95%CI)	O/E
2	Super learner	0.749 (0.719,0.780)	1.093	0.734 (0.667,0.800)	0.994
2	Cox 比例风险模型	0.749 (0.719,0.780)	1.096	0.735 (0.668,0.802)	0.999
2	随机生存森林	0.869 (0.852,0.887)	1.101	0.718 (0.661,0.774)	0.979
2	加法风险模型	0.743 (0.711,0.775)	1.071	0.720 (0.652,0.788)	1.022
2	指数回归模型	0.749 (0.719,0.780)	1.093	0.736 (0.670,0.803)	1.006
2	对数正态回归模型	0.750 (0.719,0.780)	1.093	0.731 (0.663,0.798)	0.994
2	Weibull 回归模型	0.749 (0.719,0.779)	1.084	0.736 (0.670,0.803)	0.982
2	对数 logistic 回归模型	0.749 (0.719,0.780)	1.101	0.731 (0.664,0.798)	0.985
2	随机条件推理森林	0.772 (0.743,0.800)	1.098	0.745 (0.683,0.807)	0.990
3	Super learner	0.783 (0.758,0.807)	0.977	0.725 (0.673,0.777)	0.990
3	Cox 比例风险模型	0.749 (0.722,0.777)	0.980	0.720 (0.666,0.774)	0.987
3	随机生存森林	0.878 (0.862,0.893)	0.984	0.686 (0.638,0.734)	0.978
3	加法风险模型	0.744 (0.716,0.773)	0.958	0.707 (0.651,0.762)	1.017
3	指数回归模型	0.749 (0.722,0.777)	0.977	0.721 (0.667,0.774)	0.986
3	对数正态回归模型	0.750 (0.722,0.777)	0.977	0.716 (0.662,0.770)	0.998
3	Weibull 回归模型	0.749 (0.722,0.776)	0.969	0.721 (0.667,0.775)	0.976
3	对数 logistic 回归模型	0.750 (0.722,0.777)	0.984	0.715 (0.661,0.769)	0.985
3	随机条件推理森林	0.776 (0.750,0.801)	0.982	0.733 (0.683,0.784)	0.990

表 14.4 Super learner 中各预测算法权重系数

预测年限	预测模型	权重系数
2	Cox 比例风险模型	0.1944
2	随机生存森林	0.0000
2	加法风险模型	0.0101
2	指数回归模型	0.2376
2	对数正态回归模型	0.1703
2	Weibull 回归模型	0.2290
2	对数 logistic 回归模型	0.1583
2	随机条件推理森林	0.0003
3	Cox 比例风险模型	0.1279
3	随机生存森林	0.0941
3	加法风险模型	0.1343
3	指数回归模型	0.1279
3	对数正态回归模型	0.1204
3	Weibull 回归模型	0.1267
3	对数 logistic 回归模型	0.1242
3	随机条件推理森林	0.1444

2.7 不同预测模型综合预测效果的比较

采用预测准确度（C-index）和校准能力（|1-O/E|）的均数和标准差，描述和比较 9 种预测模型的预测效果. 表 15.1 和表 15.2 分别是 9 种预测模型的测准确度（C-index）和校准能力（|1-O/E|）比较。由 15.1 可见，Super learner 组合预测模型的预测效果表现优异，其判别准确性（C-index）均值为 0.795，在 9 个预测模型中排名第三位，优于参数回归模型和半参数回归模型；除指数回归模型、对数 logistic 回归模型表现较差外，其它模型校准（O/E）能力无明显差距。而由表 15.2 可见，Super learner 组合预测模型也具有较好的外推准确性和校准能力。在外部验证中，Super learner 判别准确性（C-index）均值为 0.780，与对数正态回归模型相同，在 9 个预测模型中排名第一位；Super learner 校准能力（O/E）的综合评价指标|1-O/E|为 0.092，各预测模型校准能力差异不大。综合考虑预测模型内部交叉验证及外部验证的判别准确性（C-index）和校准能力（O/E），Super learner 具有较好的准确性与校准能力。表 15.3 为预测年限 3 年时 9 种预测模型在六组队列中外部验证准确性(C-index)排名情况，可以看出，相对于其他单一预测模型，Super learner 外推泛化能力更加稳定。

总之，在较为复杂的真实队列中，单一预测模型往往表现较不稳定，其预测准确性表现出忽高忽低的趋势；而 Super learner 组合预测模型无论在何种情况下

均表现出较为稳健的预测效果，且外推泛化能力稳定。

表 15.1 各预测模型内部验证预测效果综合评价

预测模型	C-index		1-O/E	
	均值	标准差	均值	标准差
Super learner	0.795	0.046	0.046	0.047
加法风险模型	0.741	0.035	0.042	0.047
随机条件推理森林	0.800	0.039	0.041	0.050
Cox 比例风险模型	0.738	0.035	0.046	0.042
指数回归模型	0.738	0.035	0.052	0.045
对数 logistic 回归模型	0.741	0.034	0.051	0.046
Weibull 回归模型	0.738	0.035	0.055	0.046
对数正态回归模型	0.742	0.034	0.050	0.047
随机生存森林	0.929	0.033	0.042	0.048

表 15.2 各预测模型在外部验证集中预测效果综合评价

预测模型	C-index		1-O/E	
	均值	标准差	均值	标准差
Super learner	0.780	0.042	0.092	0.083
加法风险模型	0.778	0.043	0.089	0.099
随机条件推理森林	0.772	0.047	0.160	0.205
Cox 比例风险模型	0.771	0.035	0.093	0.071
指数回归模型	0.771	0.034	0.083	0.073
对数 logistic 回归模型	0.778	0.040	0.092	0.082
Weibull 回归模型	0.772	0.035	0.081	0.067
对数正态回归模型	0.780	0.042	0.093	0.081
随机生存森林	0.715	0.086	0.079	0.064

表 15.3 9 种模型在六组队列中外部验证准确性(C-index)排名情况

数据集	第一组	第二组	第三组	第四组	第五组	第六组
Super learner	3	5	1	3	2	2
加法风险模型	4	1	7	2	1	7
对数 logistic 回归模型	2	3	3	6	3	6
Cox 比例风险模型	5	4	4	9	3	4
对数正态回归模型	1	2	1	4	3	5
Weibull 回归模型	6	4	5	7	2	3
指数回归模型	7	4	6	7	3	3
随机条件推理森林	8	6	8	1	8	1
随机生存森林	9	7	9	5	9	8

讨 论

结直肠癌是危害人类健康的恶性肿瘤之一，在全肿瘤死亡谱中位居第二位^[60]，其所造成的疾病负担正在不断增加。目前，TNM 分期依然是临床判断结直肠癌预后的主要依据，但该分期系统仅包含了肿瘤病理浸润深度、淋巴结阳性数目及是否远处转移三个方面，预后预测效果并不理想。为了提高结直肠癌预后预测效果以期更好地指导临床诊疗，许多研究利用常见的结直肠癌预后指标构建结直肠癌预后预测模型。本研究利用统计模拟数据和真实世界结直肠癌生存数据队列数据，验证和比较了 8 种单一预测模型以及由这 8 种单一预测模型组合而成的 Super Learner 组合预测模型。研究结果发现与单一预测模型相比，Super learner 组合预测模型在训练队列与验证队列中表现均较为稳定，预测效果较好。应用独立验证队列进行外部验证时，其 C-index 优于多数的单一预测模型，泛化外推能力较为稳定，是构建结直肠癌预测模型的理想选择。

1. Super learner 组合预测模型与单一预测模型的比较

本研究在统计模拟中设定了两种风险分布类型、两种协方差矩阵及三种效应向量，设计了一系列统计模拟试验，利用依据特定分布、特定协方差矩阵及特定变量效应产生的模拟数据为训练集拟合预测模型，进而在依据不同风险分布、不同协方差矩阵及不同变量效应产生的验证数据中进行模型的预测效果比较。一般认为，样本量是影响模型预测效果的重要因素，有研究基于经验提出 EPV (events per variable) 这个测算样本量指标^[61]，认为单个预测因子对应的疾病阳性例数在十例以上时，构建的预测模型比较稳定^[62, 63]，而实际工作中普遍认为样本量越多越好。然而本课题组关于心脑血管病风险预测理论方法的模拟研究^[64]中，利用统计模拟试验系统探讨了样本量对预测模型预测效果的影响，其结果显示，当样本量达到 1000 时，随着样本量的增大，各种预测模型的预测效果 (C-index 和 O/E) 已趋于稳定，提示预测模型对样本量可能并不敏感。基于我们这一研究结果，本研究在统计模拟时将样本量设定为 1000，仅探讨删失率对 Super learner 及其他预测模型预测效果的影响。删失是生存预测研究中不可避免的问题，本研究经过统计模拟发现，随着删失率的增大，预测模型在独立验证集中的判别准确性 (C-index) 逐渐降低，机器学习方法随机生存森林和随机条件推理森林下降幅度最

大；当训练集删失率较低时，预测模型在训练集中的校准能力（O/E）略偏离 1，随着删失率逐渐增大，偏离幅度越来越大，表明其错估累计死亡风险。

通过对模型在数据集 E11、E12、E13 中的预测效果进行比较可以看出，各种预测模型在数据集 E11 中预测效果（C-index 和 O/E）最好，在数据集 E13、E12 中表现次之，表明验证数据集变量效应不同对模型预测效果会产生影响；数据集 E11 与 E21、E12 与 E22、E13 与 E23 协方差矩阵不同，通过比较模型在上述数据集中的预测效果，可以发现验证数据集变量间相关性不同也可对模型预测效果产生影响。一般认为变量间相关性对模型的预测效果有较大影响，当变量间相关性很强时，变量间的多重共线性可能影响建模效果。有研究表明对于 Weibull 回归、Cox 比例风险回归等回归预测模型，当变量间相关系数大于 0.8 或者方差膨胀因子大于 10 时，变量间的共线性可能会导致偏回归系数不稳定^[65]。也有研究报道，随机生存森林能够有效应对和利用变量间的共线性问题，从而使预测效果得到改善^[66,67]。然而本论文的模拟结果显示，若验证集协方差矩阵与训练集协方差矩阵相同时，随机生存森林模型在验证集中的预测效果最好，当验证集协方差矩阵与训练集协方差矩阵不同时，随机生存森林模型在验证集中的预测效果会不同程度的降低。本研究统计模拟产生的数据集 W11 与 E11、W12 与 E12、W13 与 E13、W21 与 E21、W22 与 E22、W23 与 E23 风险分布不同，通过比较模型在上述数据集中的预测效果，可以发现在变量相关性及效应相同时，验证数据风险分布类型对模型预测效果产生影响较小。

研究中应用不同分布、不同变量间相关及不同效应的模拟验证集进行模型外部验证时，发现 Super learner 预测效果优于随机生存森林、随机条件推理森林、加法风险模型、Cox 比例风险模型及 Weibull 回归模型，但稍逊于对数正态回归模型、对数 logistic 回归模型及指数回归模型，这可能与验证集是按照相应参数分布产生的有关。在结直肠癌预后的建模中，本研究综合了不同来源的独立队列数据，变量间的关系更加复杂，并基于不同的变量组合构建了 6 组预测模型。应用十折交叉验证进行模型内部交叉验证发现，机器学习方法（随机生存森林、随机条件推理森林）判别准确性（C-index）优于 Super learner，而 Super learner 判别准确性（C-index）优于 Cox 比例风险模型在内的半参数、参数预测模型；在利用验证集进行模型外部验证时发现，Super learner 判别准确性（C-index）与对

数正态回归模型相当,均优于其它模型,但 Super learner 校准 (O/E) 优于对数正态回归模型,综合考虑校准和判别能力, Super learner 表现优于对数正态回归模型。值得注意的是,虽然随机生存森林在内部验证中判别准确性 (C-index) 表现最佳,但在外部验证中,其判别准确性 (C-index) 表现最差,表明随机生存森林容易过拟合,模型的泛化外推能力较差。此外,在研究中,对数正态回归模型在统计模拟及实例验证中,在验证集中的判别准确性 (C-index) 均表现最好,表明对数正态回归模型有较好的稳健性。在构建预测模型过程中,受数据来源限制,各数据集变量数目有限且均为常见的临床病理学指标。因此,本研究统一利用 Cox 比例风险模型筛选变量,并结合相关专业知识确定了纳入模型的预测变量。然后,在变量较多的数据或组学等高维数据中应用 Super learner 进行预测时,则针对不同的预测模型应用不同的变量筛选策略,甚至于同一预测方法可以应用多种变量筛选策略确定预测变量从而构建多个候选预测模型,将上述候选模型纳入 Super learner 框架从而产生新的预测模型,有利于改善 Super learner 的预测效能。

2. 结直肠癌预后的影响因素及其预测价值

由于结直肠癌预后随访队列数据来源不同,包含的预测变量不同,本研究根据不同数据集的变量组合构建了多个预后预测模型。本研究预测模型中纳入的变量有年龄、T 分期、N 分期、送检淋巴结数目、组织学类型、术前 CEA 水平、神经/脉管浸润、分化程度、微卫星稳定性及 p53 突变。以下对相关因素对预后的影响及其预测验证展开讨论。

在本研究中应用的 5 个独立数据集中,结直肠癌患者平均确诊年龄大多在 60~65 岁,这与张明刚等报道的结直肠癌中位诊断年龄 62 岁一致^[68]。在构建模型过程中,单因素及多因素 Cox 比例风险模型分析结果均表明年龄为结直肠癌预后的影响因素 ($P<0.05$),即年龄为结直肠癌预后的预测因子,这与其他学者的研究结果相同^[69,70]。值得注意的是,安大立^[71]等人报道 40 岁以下青年结直肠癌患者五年生存率仅为 37.5%,而中老年结直肠癌患者五年生存率为 62.3%,这可能与两组患者的临床病例特征不同相关。有研究报道^[72,73],相较于老年结直肠癌患者,青年结直肠癌患者有粘液腺癌、印戒细胞癌比例更高、神经侵犯发生率高、分化程度低及恶性程度高的特点,这可能是青年结直肠癌患者预后不好的原因。目前关于病理分化程度的分类标准并不统一,比较细化的分类标准是高分化、

中分化、低分化及未分化,但在实际应用中,由于高分化程度患者较少,多与中分化合并称为中高分化;也有研究人员将未分化程度并入低分化程度类别。在本研究中,其分类采用三分类,即高分化程度、中分化程度和低分化程度,分别占 10.16%、73.70%和 16.14%,该数据中高分化程度比例明显高于其他同类型报道^[74]。本研究单因素 Cox 比例回归分析显示病例分化程度与结直肠癌预后相关,低分化程度的结直肠癌患者预后较中高分化的患者差,这与其他类似研究结果一致^[75]。鉴于此,虽然多因素 Cox 比例风险回归分析显示病例分化程度无统计学意义($P>0.05$),本研究仍将其纳入模型 2 中。国际抗癌联盟和美国肿瘤联合会联合制定的 TNM 分期系统涵盖了结直肠癌患者肿瘤局部浸润深度、阳性淋巴结数目和部位及远处转移的信息,是目前临床上判断结直肠癌预后及制定治疗方案的主要依据^[76]。有文献报道^[77],中国结直肠癌患者 I、II、III、IV 期的 5 年生存率分别为 90.1%、72.6%、53.8%、10.4%,但对于 II、III 期各亚组患者,II C 期的五年生存率(44.8%)相较于 IIIA、IIIB 期的五年生存率反而更低,而 Lu AT 等^[78, 79]进行的 Meta 分析也得出了类似的结果,结直肠癌 II B 期患者五年生存率(72.20%)低于 IIIA 期五年生存率(83.40%),这说明肿瘤原发灶浸润深度对患者预后的提示意义更加显著。为进一步提高模型预测效果,本研究将 TNM 分期分为三个变量纳入模型,即 T 分期、N 分期及 M 分期。T 分期主要是根据结直肠癌患者肿瘤局部浸润深度进行分期,浸润深度越深,尤其是肿瘤浸出浆膜后,患者五年生存率下降更加显著。N 分期主要根据转移淋巴结数目进行分期,而值得注意的是无论淋巴结有无转移,切除淋巴结数目对结直肠癌患者预后保护作用^[80-84],究其原因可能是切除的淋巴结数目越多,意味着切除潜在的转移淋巴结的可能性越大,进而检出转移淋巴结的数目可能越多,有利于精准分期。M 分期指是否远处转移,在远处转移的结直肠癌患者中,肝脏是最为常见的转移部位,其次是肺转移、骨转移等^[85]。

除常见的临床病理学指标外,本研究在第四组和第五组队列中纳入了包含个体遗传信息的变量微卫星不稳定性与 p53。微卫星主要是指基因组中的简单重复序列,一般以 2 个核苷酸组成的重复序列最为常见,简单重复序列的改变可导致多态性,其增加或丢失即称为微卫星不稳定性,在临床上主要通过检测微卫星位点 BAT-25、BAT-26、D5S346、D2S123、D17S250 的不稳定性来判断个体微

卫星不稳定程度^[86]。Gryfe 等^[21]通过对 607 例结直肠癌患者预后进行生存分析,发现高度微卫星不稳定性的结直肠癌患者预后优于无微卫星不稳定性的患者;而 Popat 等^[23]进行的 Meta 分析提示高微卫星不稳定性的结直肠癌患者死亡风险低于无微卫星不稳定性的患者。在本研究中,Cox 比例风险回归分析显示高微卫星不稳定性无统计学意义,这可能与数据来源有关。由于受到数据来源的限制,本研究只能将微卫星不稳定性定义为存在微卫星不稳定性与无微卫星不稳定性二分类变量,而结合以往文献,高微卫星不稳定患者预后优于微卫星稳定的患者,而在实例验证数据中,将高微卫星不稳定性与低微卫星不稳定合并为微卫星不稳定,相较于高卫星不稳定,新变量对生存预后的影响降低。但结合专业知识,为提高模型预测准确性,仍然将其纳入预后预测模型。p53 基因是常见的抑癌基因之一,与人类肿瘤联系密切,野生型 p53 能够在 DNA 损伤时激活 DNA 修复酶系统,修复 DNA 损伤或诱导细胞凋亡,其突变后,抑癌活性丧失,可诱发癌变。有研究表明,p53 基因过度表达与多种肿瘤的不良预后有关^[87],而 Haseba 等^[88]研究表明,携带突变型 p53 的结直肠癌患者预后较差。

3. 结直肠癌预后预测模型的适用性

目前大部分研究利用 Cox 比例风险模型构建预后预测模型,其建模流程大多为首先利用单因素 Cox 比例风险模型或者 log-rank 检验进行变量筛选,将单因素回归分析有意义的变量纳入多因素 Cox 比例风险模型,最后基于多因素 Cox 比例风险模型的结果构建预后预测模型或预测列线图,并对模型进行评价,但其预测的准确性并不令人满意。Valentini 等^[89]利用 2795 例直肠癌患者的资料,基于 Cox 比例风险回归模型利用年龄、性别、T 分期、N 分期、辅助化疗、手术方式及放疗剂量的常见的临床病理学指标建立了针对欧洲人群的结直肠癌预后预测列线图,预测模型的 C-index 在训练组和验证组分别为 0.680 和 0.700。Peng 等^[90]利用 883 例直肠癌患者生存数据开发了一个针对中国人群的结直肠癌预后列线图来预测 II-III 期直肠癌患者的生存预后,纳入的变量包括年龄、性别、CEA 水平,肿瘤位置、T 分期、N 分期、淋巴结转移比率及辅助放化疗,但该预测模型的在训练集中 C-index 仅达到 0.700,在验证集中外部验证 C-index 为 0.760。Jiang 等^[39]利用 822 例结直肠癌患者临床资料和生存随访数据,基于 Cox 比例风险模型构建了非转移性结直肠癌预后预测模型,纳入的变量包括年龄、一级亲属

癌症史、分化程度、血管/神经侵犯、TNM 分期、CEA、CA19-9 和 PNI，该模型内部验证 C-index 为 0.750，利用独立数据进行外部验证 C-index 为 0.790。少部分研究应用机器学习的方法进行结直肠癌预后预测研究^[44, 45]。

在本研究的第一组、第三组和第六组队列中，均采用了本课题组构建的山东结直肠癌预后队列数据作为训练集，基于 Super learner 构建了结直肠癌预后预测模型。在第一组队列中，纳入变量包括年龄、CEA、T 分期、N 分期、肿瘤位置、组织学类型、神经/脉管浸润及送检淋巴结数目，预测年限为 3 年时，十折交叉内部验证显示，模型的 C-index 为 0.823，O/E 为 0.998；采用 TCGA-COADREAD 数据进行外部验证，模型的 C-index 为 0.813，O/E 为 1.113。在第三组队列中，纳入变量包括年龄、送检淋巴结数目、CEA、T 分期、N 分期、远处转移及组织学类型，预测年限为 3 年时，采用十折交叉验证进行内部验证，Super learner 的 C-index 为 0.877，O/E 为 0.986；采用 TCGA-COADREAD 数据进行外部验证，Super learner 的 C-index 为 0.816，O/E 为 1.077；在第六组队列中，纳入的变量包括年龄、T 分期、N 分期、远处转移及辅助化疗，预测年限为 3 年时，采用十折交叉验证进行内部验证，Super learner 的 C-index 为 0.783，O/E 为 0.977；采用 GSE40967 数据进行外部验证，Super learner 的 C-index 为 0.725，O/E 为 0.990。以上三个模型基于不同的变量组合构建，均经过独立验证集进行外部验证，有较好的判别准确性（C-index）和校准（O/E），相较于 TNM 分期，预测模型利用了更多的临床病理学因素，有利于更好地解释肿瘤患者异质性，从而提供了更加个性化的预后，可用于山东乃至中国结直肠癌患者预后预测，为患者及临床医生进行术后生存预测提供了工具。

结 论

1. 数据结构相对简单和预测变量数目较少的模拟情境下, Super learner 预测效果较好。

2. 针对较为复杂的真实世界结直肠癌预后队列, 单一预测模型表现较不稳定, 其预测准确性呈忽高忽低的趋势; 而 Super learner 组合预测模型无论在何种情况下均表现出较为稳健的预测效果, 且外推泛化能力稳定。

3. 基于 Super learner 组合预测策略的结直肠癌预后预测模型, 具备稳健性好、准确性高以及外推泛化能力强的优良特征, 为临床结直肠癌预后预测提供了新方法。

创新与不足

创新：

1. 提出了基于 Super learner 建立结直肠癌预后组合预测模型的新思想，为疾病预测模型的建立提供了新策略。
2. 通过统计模拟和多源异质性队列数据库之间的外推预测比较，阐明了在真实世界的复杂情形下，单一预测模型往往表现较不稳定，其预测准确性表现出忽高忽低的趋势；而 Super learner 组合预测模型具有稳健和外推泛化能力强的优点。
3. 采用 Super learner 组合预测策略，构建了适于不同预测因子可及性的结直肠癌预后预测模型，为临床上结直肠癌预后预测、评估和个性化干预提供了新工具。

不足之处：

1. 本研究受限于数据来源，实例验证中数据样本量较小，且随访时间较短，只能构建预测年限较短的预后预测模型。
2. 由于数据来源不同，各数据集包含的变量各不相同，为了进行外部验证，预测模型纳入的变量受到限制。
3. 数据来源各不相同，各变量的测量尺度或检测方法可能各不相同，对模型预测效果产生影响。

参考文献

- [1] Brenner H, Kloor M, Pox CP. Colorectal cancer[J]. Lancet, 2014,383(9927):1490-1502.
- [2] Arnold M, Sierra MS, Laversanne M, et al. Global patterns and trends in colorectal cancer incidence and mortality[J]. Gut, 2017,66(4):683-691.
- [3] Chen W, Zheng R, Baade PD, et al. Cancer statistics in China, 2015[J]. CA Cancer J Clin, 2016,66(2):115-132.
- [4] 陈琼, 程兰平. 2003~2007 年中国结直肠癌发病与死亡分析[J]. 中国肿瘤, 2012,21(3):179-182.
- [5] 张思维, 郑荣寿. 2003~2007 年中国癌症死亡分析[J]. 中国肿瘤, 2012,21(3):171-178.
- [6] Alizadeh AA, Aranda V, Bardelli A, et al. Toward understanding and exploiting tumor heterogeneity[J]. Nat Med, 2015,21(8):846-853.
- [7] Locker GY, Hamilton S, Harris J, et al. ASCO 2006 update of recommendations for the use of tumor markers in gastrointestinal cancer[J]. J Clin Oncol, 2006,24(33):5313-5327.
- [8] Carter, Darryl. TNM Classification of Malignant Tumors[J]. Cancer, 2012,61(1):101.
- [9] Nagtegaal ID, Quirke P, Schmoll HJ. Has the new TNM classification for colorectal cancer improved care?[J]. Nat Rev Clin Oncol, 2012,9(2):119-123.
- [10] Mlecnik B, Bindea G, Pagès F, et al. Tumor immunosurveillance in human cancers[J]. Cancer & Metastasis Reviews, 2011,30(1):5-12.
- [11] 陈蕾, 姜北海, 邸佳柏, 等. CA199 在判断 CEA 正常的中晚期结直肠癌患者预后中的价值[J]. 中国肿瘤临床, 2015,42(15):743-750.
- [12] Duffy MJ, Van DA, Haglund C, et al. Clinical utility of biochemical markers in colorectal cancer: European Group on Tumour Markers (EGTM) guidelines[J]. Eur J Cancer, 2003,39(6):718-727.
- [13] 朱磊, 韩仕峰. 术前血清 CEA 和 CA19-9 水平检测对结肠癌术后早期复发转移的预测价值[J]. 中国普通外科杂志, 2015,24(8):1170-1174.
- [14] Yang KM, Ja PI, Wook KC, et al. The prognostic significance and treatment modality for elevated pre- and postoperative serum CEA in colorectal cancer patients[J]. Annals of Surgical Treatment & Research, 2016,91(4):165-171.
- [15] Nakagoe T, Sawai T, Tsuji T, et al. Preoperative serum level of CA19-9 predicts recurrence after curative surgery in node-negative colorectal cancer patients[J]. Hepatogastroenterology, 2003,50(51):696-699.
- [16] Perletti G, Montanari E, Vral A, et al. Inflammation, prostatitis, proliferative inflammatory atrophy: 'Fertile ground' for prostate cancer development?[J]. Mol Med Rep, 2010,3(1):3.
- [17] Angell H, Galon J. From the immune contexture to the Immunoscore: the role of prognostic and predictive immune markers in cancer[J]. Curr Opin Immunol, 2013,25(2):261-267.
- [18] Yuan Z, Zhou GQ, Xu L, et al. Exploration and Validation of C-Reactive Protein/Albumin Ratio as a Novel Inflammation-Based Prognostic Marker in Nasopharyngeal Carcinoma[J]. J Cancer, 2016,7(11):1406-1412.
- [19] Song Y, Yang Y, Gao P, et al. The preoperative neutrophil to lymphocyte ratio is a superior indicator of prognosis compared with other inflammatory biomarkers in resectable colorectal cancer[J]. BMC Cancer, 2017,17(1):744.
- [20] Kubo H, Murayama Y, Arita T, et al. The Prognostic Value of Preoperative Neutrophil-to-Lymphocyte Ratio in Colorectal Cancer[J]. World J Surg, 2016,40(11):2796-2802.
- [21] Gryfe R. Tumor Microsatellite Instability and Clinical Outcome in Young Patients with Colorectal Cancer — NEJM[J]. N Engl J Med, 2000,342(2):69-77.
- [22] Merok MA, Ahlquist T, Rå, Yrvik EC, et al. Microsatellite instability has a positive prognostic impact on

- stage II colorectal cancer after complete resection: results from a large, consecutive Norwegian series[J]. *Ann Oncol*, 2013,24(5):1274-1282.
- [23] Popat S, Hubner R, Houlston RS. Systematic review of microsatellite instability and colorectal cancer prognosis[J]. *J Clin Oncol*, 2005,23(3):609-618.
- [24] Liang JT, Chang KJ, Chen JC, et al. Hypermethylation of the p16 gene in sporadic T3N0M0 stage colorectal cancers: association with DNA replication error and shorter survival[J]. *Oncology*, 1999,57(2):149-156.
- [25] Lin S, Yeh K, Chen WT, et al. Promoter CpG Methylation of Caveolin-1 in Sporadic Colorectal Cancer[J]. *台湾消化医学杂志*, 2004,21(3):209-209.
- [26] Popovici V, Budinska E, Tejpar S, et al. Identification of a Poor-Prognosis BRAF-Mutant-Like Population of Patients With Colon Cancer[J]. *J Clin Oncol*, 2012,30(12):1288-1295.
- [27] Beatriz PV, Alejandro RL, Susana HP, et al. Colon cancer molecular subtypes identified by expression profiling and associated to stroma, mucinous type and different clinical behavior[J]. *BMC Cancer*, 12,1(2012-06-19), 2012,12(1):260-260.
- [28] Salazar R, Roepman P, Capella G, et al. Gene Expression Signature to Improve Prognosis Prediction of Stage II and III Colorectal Cancer[J]. *J Clin Oncol*, 2011,29(1):17-24.
- [29] Mettu RK, Wan YW, Habermann JK, et al. A 12-gene genomic instability signature predicts clinical outcomes in multiple cancer types[J]. *Int J Biol Markers*, 2010,25(4):219-228.
- [30] Bandra[©]S E, Malumbres R, Cubedo E, et al. A gene signature of 8 genes could identify the risk of recurrence and progression in Dukes' B colon cancer patients[J]. *Oncol Rep*, 2007,17(5):1089-1094.
- [31] Peng J, Wang Z, Wei C, et al. Integration of genetic signature and TNM staging system for predicting the relapse of locally advanced colorectal cancer[J]. *Int J Colorectal Dis*, 2010,25(11):1277-1285.
- [32] Andersen CL. Metastasis-associated gene expression changes predict poor outcomes in patients with Dukes stage B and C colorectal cancer[J]. *Clinical Cancer Research An Official Journal of the American Association for Cancer Research*, 2009,15(24):7642.
- [33] Fritzmann J, Morkel M, Besser D, et al. A colorectal cancer expression profile that includes transforming growth factor beta inhibitor BAMBI predicts metastatic potential[J]. *Gastroenterology*, 2009,137(1):165-175.
- [34] SMITH, Joshua J, DEANE, et al. Experimentally Derived Metastasis Gene Expression Profile Predicts Recurrence and Death in Patients With Colon Cancer[J]. *Gastroenterology*, 2010,138(3):958-968.
- [35] Merlossuárez A, Barriga FM, Jung P, et al. The intestinal stem cell signature identifies colorectal cancer stem cells and predicts disease relapse[J]. *Cell Stem Cell*, 2011,8(5):511-524.
- [36] Oh SC, Park YY, Park ES, et al. Prognostic gene expression signature associated with two molecularly distinct subtypes of colorectal cancer[J]. *Gut*, 2012,61(9):1291.
- [37] 徐芳英. 结直肠癌预后评估及预测模型的建立[D]:浙江大学医学院 浙江大学医学部 浙江大学,2009.
- [38] Wang X, Chi P, Lin H, et al. [Establishment of a prognostic nomogram to predict long-term survival in non-metastatic colorectal cancer patients][J]. *Zhonghua Wei Chang Wai Ke Za Zhi*, 2017,20(6):654-659.
- [39] Jiang H, Tang E, Xu D, et al. Development and validation of nomograms for predicting survival in patients with non-metastatic colorectal cancer[J]. *Oncotarget*, 2017,8(18):29857-29864.
- [40] Nieder C, Hintz M, Grosu AL. Predicted survival in patients with brain metastases from colorectal cancer: Is a current nomogram helpful?[J]. *Clinical Neurology & Neurosurgery*, 2016,143:107-110.
- [41] Zhang ZY, Gao W, Luo QF, et al. A nomogram improves AJCC stages for colorectal cancers by introducing CEA, modified lymph node ratio and negative lymph node count[J]. *Sci Rep*, 2016,6.
- [42] Huang YQ, Liang CH, He L, et al. Development and validation of a radiomics nomogram for preoperative prediction of lymph node metastasis in colorectal cancer[J]. *J Clin Oncol*, 2016,34(4):2157-2164.
- [43] Mj VDL, Polley EC, Hubbard AE. Super learner[J]. *Statistical Applications in Genetics & Molecular Biology*,

- 2007,6(3):1-23.
- [44] 洪远芳. 随机生存森林在结直肠癌预后分析的应用[D]: 中山大学, 2010.
- [45] 王宇燕, 王杜娟, 王延章, 等. 改进随机森林的集成分类方法预测结直肠癌存活性[J]. 管理科学, 2017,30(01):99-110.
- [46] Pirracchio R, Petersen ML, Carone M, et al. Mortality prediction in intensive care units with the Super ICU Learner Algorithm (SICULA): a population-based study[J]. Lancet Respir Med, 2015,3(1):42-52.
- [47] Bender R, Augustin T, Blettner M. Generating survival times to simulate Cox proportional hazards models[J]. Stat Med, 2005,24(11):1713-1723.
- [48] Laurie JA, Moertel CG, Fleming TR, et al. Surgical adjuvant therapy of large-bowel carcinoma: an evaluation of levamisole and the combination of levamisole and fluorouracil. The North Central Cancer Treatment Group and the Mayo Clinic[J]. J Clin Oncol, 1989,7(10):1447-1456.
- [49] Lin DY. Cox regression analysis of multivariate failure time data: the marginal approach[J]. Stat Med, 2010,13(21):2233-2247.
- [50] 李晓松. 卫生统计学[M]. 第三版 :高等教育出版社,2014.
- [51] Aalen OO. Further results on the non-parametric linear regression model in survival analysis[J]. Stat Med, 2010,12(17):1569-1588.
- [52] Aalen OO. A linear regression model for the analysis of life times[J]. Stat Med, 2010,8(8):907-925.
- [53] 王慧. 生存分析中半参数模型的变量选择方法及其模拟研究[D] :山西医科大学,2013.
- [54] Lin DY, Ying Z. Semiparametric Analysis of General Additive-Multiplicative Hazard Models for Counting Processes[J]. The Annals of Statistics, 1995,23(5):1712-1734.
- [55] 金凌辉, 郭丽莎. 加法风险模型的半参数估计方法[J]. 淮阴师范学院学报(自然科学版), 2015,(1):9-13.
- [56] 曹志强, 王杨, 李卫, 等. 半参数与非参数可加风险模型对达菲和中药治疗 H1N1 流感效果的比较[J]. 中国卫生统计, 2015,32(1):22-25.
- [57] Loh WY. Classification and regression trees[J]. Wiley Interdisciplinary Reviews Data Mining & Knowledge Discovery, 2011,1(1):14-23.
- [58] Breiman L. Random Forests[J]. Machine Learning, 2001.
- [59] Ishwaran H, Kogalur UB, Blackstone EH, et al. Random survival forests[J]. Journal of Thoracic Oncology Official Publication of the International Association for the Study of Lung Cancer, 2008,2(3):841-860.
- [60] Siegel RL, Miller KD, Fedewa SA, et al. Colorectal cancer statistics, 2017[J]. Ca A Cancer Journal for Clinicians, 2017,67(3):104-117.
- [61] Concato, John, Peduzzi, et al. Importance of events per independent variable in proportional hazards analysis I. Background, goals, and general strategy[J]. J Clin Epidemiol, 1995,48(12):1495-1501.
- [62] Peduzzi P, Concato J, Kemper E, et al. A simulation study of the number of events per variable in logistic regression analysis ☆[J]. J Clin Epidemiol, 1996,49(12):1373-1379.
- [63] Peduzzi P, Concato J, Feinstein AR, et al. Importance of events per independent variable in proportional hazards regression analysis. II. Accuracy and precision of regression estimates[J]. Estuaries & Coasts, 2007,30(4):618-626.
- [64] 丁荔洁. 心脑血管病风险预测的理论方法及其个性化健康管理工具研究[D]: 山东大学,2016.
- [65] Lyles RH. Regression Methods in Biostatistics: Linear, Logistic, Survival, and Repeated Measures Models[J]. Publications of the American Statistical Association, 2006,101(473):403-404.
- [66] Unnikrishnan P, Kumar DK, Poosapadi AS, et al. Development of Health Parameter Model for Risk Prediction of CVD Using SVM:[J]. Comput Math Methods Med, 2016,2016:1-7.
- [67] Motwani M, Dey D, Berman DS, et al. Machine learning for prediction of all-cause mortality in patients with

- suspected coronary artery disease: a 5-year multicentre prospective registry analysis[J]. *Eur Heart J*, 2016,38(7):500.
- [68] 张明刚, 李靖涛, 杨华元, 等. 1134 例大肠癌临床病例分析[J]. *中华医学杂志*, 2003,83(23):2087-2088.
- [69] Keith Naylor MD, James Ward MD, Polite BN. Interventions to Improve Care Related to Colorectal Cancer Among Racial and Ethnic Minorities: A Systematic Review[J]. *J Gen Intern Med*, 2012,27(8):1033-1046.
- [70] 王晓娜, 梁寒, 王家仓, 等. 1829 例结直肠癌患者的临床病理特征及预后分析[J]. *中华胃肠外科杂志*, 2004,7(6):439-442.
- [71] 安大立, 李志霞. 青年人与中老年人结直肠癌的临床病理及预后对照研究[J]. *中华胃肠外科杂志*, 2001,4(2):91-93.
- [72] 吉猛. 青年结直肠癌临床病理特征分析[D]. 第二军医大学,2016.
- [73] 赵菲, 李世拥, 于波, 等. 青年与老年结直肠癌临床病理特征的对比分析[J]. *第三军医大学学报*, 2007,29(6):544-546.
- [74] 王晓娜, 梁寒, 丁学伟, 等. 青年与老年结直肠癌临床病理与预后比较[J]. *中华肿瘤防治杂志*, 2007,14(2):148-150.
- [75] Winn B, Tavares R, Fanion J, et al. Differentiating the undifferentiated: immunohistochemical profile of medullary carcinoma of the colon with an emphasis on intestinal differentiation[J]. *Hum Pathol*, 2009,40(3):398-404.
- [76] 刘荫华, 徐玲. 第七版《AJCC 肿瘤分期手册》结直肠癌内容的更新与解读[J]. *中华胃肠外科杂志*, 2010,13(8):629-631.
- [77] 易呈浩, 葛维挺, 黄彦钦, 等. 1368 例结直肠癌 TNM 分期及预后分析[J]. *中国肿瘤临床*, 2012,39(09):597-601.
- [78] Mori T. A comparison of the new (planned) TNM classification and Japanese general rule for staging colorectal cancer[J]. *Cancer Invest*, 2010,28(4):387-392.
- [79] Lu AT, Salpeter SR, Reeve AE, et al. Gene expression profiles as predictors of poor outcomes in stage II colorectal cancer: A systematic review and meta-analysis[J]. *Clin Colorectal Cancer*, 2009,8(4):207-214.
- [80] Le VT, Sigurdson ER, Hanlon AL, et al. Colon cancer survival is associated with increasing number of lymph nodes analyzed: a secondary survey of intergroup trial INT-0089[J]. *J Clin Oncol*, 2003,21(15):2912-2919.
- [81] Freedman LS, Macaskill P, Smith AN. Multivariate analysis of prognostic factors for operable rectal cancer[J]. *Lancet*, 1984,324(8405):733-736.
- [82] May M, Herrmann E, Bolenz C, et al. Association between the number of dissected lymph nodes during pelvic lymphadenectomy and cancer-specific survival in patients with lymph node-negative urothelial carcinoma of the bladder undergoing radical cystectomy[J]. *Ann Surg Oncol*, 2011,18(7):2018-2025.
- [83] Vather R, Sammour T, Kahokehr A, et al. Lymph Node Evaluation and Long-Term Survival in Stage II and Stage III Colon Cancer: A National Study[J]. *ANZ J Surg*, 2009,79(Supplement s1):585-593.
- [84] Groth SS, Virnig BA, Whitson BA, et al. Determination of the minimum number of lymph nodes to examine to maximize survival in patients with esophageal carcinoma: data from the Surveillance Epidemiology and End Results database[J]. *Journal of Thoracic & Cardiovascular Surgery*, 2010,139(3):612-620.
- [85] Siegel R, Naishadham D, Jemal A. Cancer statistics, 2013[J]. *Ca A Cancer Journal for Clinicians*, 2013.
- [86] Boland CR, Thibodeau SN, Hamilton SR, et al. A National Cancer Institute Workshop on Microsatellite Instability for Cancer Detection and Familial Predisposition: Development of International Criteria for the Determination of Microsatellite Instability in Colorectal Cancer[J]. *Cancer Res*, 1998,58(22):5248-5257.
- [87] 吴小明. p73 基因与 p53 抑癌基因的比较[J]. *惠州学院学报*, 2003,23(6):56-62.
- [88] Haseba M, Hidaka S, Tsuji T, et al. Detection of p53 Gene Mutations by Nonisotopic RNase Cleavage Assay as a Predictor of Poor Prognosis in Colorectal Cancers[J]. *Digestive Diseases & Sciences*, 2003,48(10):1984-

1989.

- [89] Valentini V, van Stiphout RG, Lammering G, et al. Nomograms for predicting local recurrence, distant metastases, and overall survival for patients with locally advanced rectal cancer on the basis of European randomized clinical trials[J]. Journal of Clinical Oncology Official Journal of the American Society of Clinical Oncology, 2011,29(23):3163.
- [90] Peng J, Ding Y, Tu S, et al. Prognostic Nomograms for Predicting Survival and Distant Metastases in Locally Advanced Rectal Cancers[J]. PLoS One, 2014,9(8):e106344.

致 谢

时光飞逝，光阴荏苒，眨眼间三年的硕士研究生生涯已渐入尾声。在此毕业论文完成之际，向所有关心、帮助、帮助、指导和陪伴我的老师、同学和家人表示诚挚的感谢。

首先，衷心感谢我的导师薛付忠教授。三年前，蒙师不弃，得入门下，这是我毕生的荣幸！是您给了我进入生物大家庭的机会，让我有机会参与到多项课题的学习中，培养了我的科学思维，开拓了我的学术视野，也锻炼了我的实践技能；是您给我提供了良好的工作生活环境，提供了强大数据科研平台，让我有充足的数据资源进行科学研究。您兢兢业业的工作态度、积极进取的工作精神、认真细致的工作作风和渊博深厚的专业知识，使我受益匪浅，是我毕生学习的楷模。

感谢生物统计系的袁中尚老师、刘言训老师、张涛老师、孙秀彬老师、刘云霞老师、李秀君老师、刘静老师、王淑康老师、季晓康老师，感谢你们在平时生活学习中给与我的帮助和指导，让我感受到了生物统计教研室浓厚的学术氛围和谐友爱的师生关系，给予了我勇敢前行的动力。

感谢李向一师姐、陈亚飞师姐、申振伟师兄、朱茜师姐、阿力木师兄、李洪凯师兄、于媛媛师姐，是你们平时耐心地解疑答惑，让我少走了很多弯路，你们为我树立了优秀的学习榜样。感谢 2016 级的诸位同门，是你们的陪伴让我的研究生生涯更加丰富多彩，我们互相帮助、学习和鼓励，共同度过了美好的研究生时光。感谢师弟师妹给予我的帮助，你们积极努力、勤奋进取的精神也不断激励着我。

感谢我的爸爸妈妈，感谢你们对我的教诲和鼓励，是你们给了我强大的精神动力，让我有勇气面对学习生活中的困难；感谢我的女朋友李悦一直支持鼓励我，陪我度过求学生涯的难熬时刻。

最后，再次感谢所有帮助关心我的老师、同学、朋友，你们的关爱我定铭记于心！

攻读学位期间发表的学术论文目录

1. **李吉庆**,赵焕宗,宋炳红,张理纯,李向一,陈亚飞,王萍,薛付忠.基于健康管理队列的心血管事件风险预测模型[J].山东大学学报(医学版), 2017(06):62-66+71.
2. **Li J**, Li X, Gu J, et al. A competing-risks nomogram for predicting probability of death from CRC in Chinese Han patients with Stage I–III CRC[J]. Japanese Journal of Clinical Oncology, 2018.
3. **Jiqing L**, Jianhua G, Xiaotian M, et al. Development and validation of a nomogram for predicting survival in Chinese han patients with resected colorectal cancer[J]. Journal of Surgical Oncology, 2018.
- 4.顾建华,马晓天,**李吉庆**,薛付忠,王家林.健康管理队列慢性阻塞性肺疾病风险预测模型[J].山东大学学报: 医学版,2017.
- 5.张丹丹,王旭,许勤勤,郑兆磊,王珮竹,**李吉庆**,刘静,许青,李秀君. 菏泽市与威海市气温对流行性腮腺炎发病的影响 [J]. 山东大学学报(医学版), 2018, v.56;No.312(08):94-100+119.

学位论文评阅及答辩情况表

论文评阅人	姓 名		专业技术 职 务	是否博导 (硕导)	所 在 单 位		总 体 评 价 ※
	王洁贞		教授	博导	山东大学		优秀已达
	吴学森		教授	博导	蚌埠医学院		优秀已达
答辩委员会成员	姓 名		专业技术 职 务	是否博导 (硕导)	所 在 单 位		
	主席	郭秀花	教授	博导	首都医科大学		
	委 员	张景肖	教授	博导	中国人民大学		
		王洁贞	教授	博导	山东大学		
		李士雪	教授	博导	山东大学		
		詹思延	教授	博导	北京大学		
答辩委员会对论文的 总体评价※			A	答辩秘书	王兴洲	答辩日期	2019.05.19
备注							

※优秀为“A”；良好为“B”；合格为“C”；不合格为“D”。